

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生数学建模竞赛

学　　校		中 南 大 学
参赛队号		26105330291
队员姓名	1.	吴禄谦
	2.	宋柏辰
	3.	何沛宇

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生数学建模竞赛

题　目： 广义标度律框架下大语言模型的算力资源配置与能力前沿预测

摘　要：

本文围绕算力约束下大语言模型的资源配置问题，建立了一套从数据刻画、规律纳入、配置求解到历史检验的模型体系。四个子问题共用同一套数据口径与参数体系，前一问的输出构成后一问的输入。

针对问题一，本文对 22 个质量指标统一方向后合成质量评分。方向表按可信度分三层推得：题面或原文明示者可核验，字段定义与指标间一致性支持者可推证，两者皆不足者列为待定。按 token 求和的对数似然比属外延量，与文档长度的秩相关约为 -0.93，逐 token 归一化后其与教育价值打分的秩相关由 -0.499 转为 $+0.374$，方向依据由建模判断升为数据可证。合成采用门控形式 $Q = V(1-P)$，使污染类指标以乘性惩罚进入而不与价值类指标在平均中相互抵消；冲突相应定义为同一文本在高价值与高污染两侧同时取高分，阈值按分位数锚定。在全部 272 486 行质量信号上，门控合成使可分辨域对由 19/21 增至 21/21，权重扰动下的域序 Kendall τ 由 0.9595 升至 0.9976，二者差值区间不含零；域序最高一档为 $\{\text{arxiv}, \text{c4}, \text{commoncrawl}\}$，档内位次依语义分组而变，故不作断言。主冲突判据在 $p75$ 锚点下给出冲突率 0.0408（$p70$ 与 $p80$ 分别为 0.0687 与 0.0208），其样本画像与其余判据近乎不相交。配比建模以去尺度偏移后的决定系数与秩相关为验证口径，主方法在 1m 尺度上优于线性基线 $+0.0703$，在 60m 与 1B 上分别低 0.0050 与 0.0464，不构成跨尺度优势。引入域级 Q 的去偏决定系数增量在三个尺度上均不显著，区间均含零；成因是 Q 的构造本身含配比，二者存在构造性相关。这一零结果是对题目「是否以及如何引入 Q」的有证据回答。

针对问题二，本文把质量与配比并入数据量项，建立 $L = E_s + AN^{-\alpha} + B(DQ^{\gamma}\exp(\boldsymbol{b}^{\top}\boldsymbol{z_p}))^{-\beta}$，在 $Q = 1$ 且配比均匀时逐项退回经典标度律。数据条件决定估计顺序：主拟合轨迹无质量变化，含质量的半合成网格只有 5 个数据量取值，两者不能在同一份数据上同时辨识，故先由真实轨迹定 β、再由网格反解 γ。三项预声明判据全部通过（退化相对差 1.01×10^{-8}；超越性降幅 0.0419，区间不含零；弹性符号两侧成立）。核心结论是质量指数 $\gamma = 0.9659$，自助区间 $[0.8839, 1.0555]$ 含 1.0，即质量的相对变化按比例放大有效 token 数；但该结论以「数据量指数可跨源共享」为前提，而该前提未通过检验（γ 位移达其区间宽的 1.246 倍）。若该指数改在含质量网格上自由估计，$\gamma = 1.1798$，区间不含 1.0。两条路线本文一并报告。质量增加 0.1 所补偿的参数量，在参照点 $N = 1.0\text{B}$、$D = 150.0\text{B}$、$Q = 0.5$ 上为 -0.1341B，B7 侧为 -0.0945B，符号为负表示提质可减少参数量。

针对问题三，本文在预算约束 $kND + D[g(Q) - g(Q_0)]_+ \le C$（$k = 6 + \eta L_{\text{ctx}}$）下最小化损失。内点条件不足以刻画最优解；本文按活跃约束集分支枚举，KKT 五项判据在三个预算锚点与 57 点扫描上全部通过。本文把结构性转移定义为三种并逐一识别，发现定义决定结论：活跃约束集变化给出位置 $\log_{10} C = 21.4052$ 且不依赖阈值与网格步长；成本分项占比排序变化给出 22.625 且依赖步长；分配份额突变在阈值 0.05 下判不出，步长减半即由存在翻转为不存在。合读的结论是转移存在、形态为连续饱和而非突跳。成本函数的影响集中在预算紧张时：$C = 10^{19}$ 档三类形式给出 0.6460、0.5390 与 1.0 三种最优质量，10^{22} 与 10^{24} 档完全一致。上下文长度跨越 $6/\eta = 30000$ 时显著压缩可负担规模（N^* 降 54.8%、D^* 降 53.4%）而几乎不改变相对配比（N:D 极差 3.22%）。

针对问题四，本文把窗口内的能力提升拆为规模通道与规模之外的技术通道，并如实报告口径敏感性。稳健口径为趋势法：两通道月斜率之比为 9.98，规模份额 0.0911 的自助区间含零。据此本文主张：窗口 2024 年 6 月至 2025 年 3 月内能力提升约 5.4865–6.6592 分（四种端点/规格算法的极差），由非规模技术/数据工程综合进步主导，规模通道贡献与零不可区分。本文同时发现任何具体百分比分割都不稳定——端点定义变动使规模份额极差达 0.2875 并发生符号翻转，故不给出百分比。同期高分段模型规模在收缩（参数量 0.9 分位由 46.703B 降至 14.770B），而前沿由 25.9201 分升至 41.3875 分。预测环节中性情景 12 个月中位数为 56.330 分，但同口径的纯趋势基线给出 60.290 分，主方法在点值与区间宽度上均不优于基线，本文同表列出。算力增长放缓对短期预测影响很小：情景极差随规模份额严格缩放，为 11.786、4.1408 与 0 分。

本文的创新在于：以门控形式解决方向相反指标共存时的合成问题，并由此自然导出冲突的定义；把不可检验的跨源共享前提显式化为条件，同时给出该前提成立与不成立两条读数；以三种定义的对照识别结构性转移，指出「存在」这一判断的成立范围；把点值的不稳定性归因到重抽样、函数规格与样本端点三个来源并分别扰动，据此撤回不可主张的百分比分割。

关键词： 标度律；数据质量；领域配比；算力约束优化；KKT 条件；结构性转移；前沿预测

目录

1 问题重述 5

1.1 问题背景 5
1.1.1 资源要素与标度律 5
1.1.2 数据墙与数据质量 5
1.1.3 上下文长度与配比的成本 5
1.2 数据条件 5
1.3 任务说明 6

2 问题分析 7

2.1 总体思路 7
2.2 问题一的分析 7
2.3 问题二的分析 8
2.4 问题三的分析 8
2.5 问题四的分析 8
2.6 关键难点与应对 9

3 模型假设与符号说明 9

3.1 模型假设 9
3.1.1 全局假设 9
3.1.2 方法性假设 9
3.2 符号说明 10
3.2.1 全局符号 10
3.2.2 数据与附件编号 12
3.2.3 指标与领域的简称 12

4 问题一：数据质量评价、冲突消解与领域配比建模 12

4.1 任务分解与整体口径 12
4.2 22 个质量指标的方向统一与规范化 12
4.3 门控合成与域级质量评分 14
4.4 质量冲突的定义与消解 17
4.5 配比建模与质量评分的增量检验 17
4.6 局限与适用范围 20

5 问题二的建模与求解 21

5.1 广义标度律的形式与设计动机 21
5.2 数据条件与参数辨识顺序 22
5.3 三项预声明判据与判据的替换 23
5.4 质量指数的双路线结论与参数共享检验 24
5.5 边际效用、弹性与等价条件 24
5.6 域间关系与跨源迁移验证 25

6 问题三的建模与求解 28

6.1 优化模型与成本结构 28
6.2 分段 KKT 约减与解析结构 29
6.3 锚点解与最优性核验 30
6.4 结构性转移的三种定义与识别 30

6.5 成本函数与上下文长度的敏感性 . . . 33
6.6 与基线的对照 . . . 34
6.7 配比的边际方向 . . . 36
7 问题四的建模与求解 . . . 36
7.1 样本口径与两个核心定义 . . . 36
7.2 归因模型的设定与识别性 . . . 38
7.3 分解结果与口径敏感性 . . . 38
7.4 趋势法读数与规模—前沿的同期走势 . . . 40
7.5 子组分解与规模通道的度量口径 . . . 41
7.6 从损失到得分的桥接与误差传播 . . . 41
7.7 前沿预测与基线对照 . . . 42
7.8 基准内部的逐任务聚合 . . . 44
8 模型评价 . . . 44
8.1 模型的优点与创新点 . . . 44
8.1.1 方法层面 . . . 44
8.1.2 建模层面 . . . 44
8.2 模型的缺点与适用范围 . . . 45
8.2.1 数据条件带来的限制 . . . 45
8.2.2 方法选择的代价 . . . 45
8.3 模型的推广 . . . 46
参考文献 . . . 46
附录 A 图表目录 . . . 48
附录 B 结果数据 . . . 52
B.1 问题一：领域级质量评分与冲突率 . . . 52
B.2 问题二：领域比值与跨源验证 . . . 55
B.3 问题三：成本函数对照与配比边际方向 . . . 56
B.4 问题四：逐月轨迹、情景与子组分解 . . . 58
附录 C 核心算法程序 . . . 59
C.1 问题一：质量指标规范化与门控合成 . . . 59
C.2 问题二：广义标度律的参数估计 . . . 64
C.3 问题三：分段 KKT 求解与结构性转移识别 . . . 66
C.4 问题四：演进分解、桥接与前沿预测 . . . 71

1 问题重述

1.1 问题背景

1.1.1 资源要素与标度律

大语言模型（large language model, LLM）的训练可看作在有限算力下对若干资源要素的联合配置：参数量 N 决定模型容量，训练 token 数 D 决定数据规模，总算力 C 决定可支付的训练成本，数据质量 Q 刻画语料的可用程度，领域配比 $\boldsymbol{p}$ 则决定算力在各训练领域之间的分配。经典标度律（scaling law）以幂律形式描述验证集交叉熵损失 L 随 N、D 的变化，其常见形式为

$$L(N, D) = E + A\,N^{-\alpha} + B\,D^{-\beta}, \tag{1.1}$$

其中 E 为不可约损失，A, α, B, β 为待估参数 [1, 2]。(1.1) 并不显式包含数据质量与领域配比，而这两者恰恰是当前语料工程的主要着力点。

1.1.2 数据墙与数据质量

高质量语料的增长远慢于算力与模型规模的扩张，可用干净数据的稀缺已构成所谓数据墙（data wall）问题，在数据受限条件下继续扩大训练量的收益会显著衰减 [3]。与此同时，数据筛选与质量治理的收益被反复观察到：以检索增强方式构造科学文献问答的小规模模型，可以在部分任务上超过参数量高出一个量级以上的通用模型 [4]；而在固定算力预算下，数据筛选策略本身也服从标度关系，筛选比例并非越高越好 [5]。这提示在算力受限时，把预算投向数据质量而非单纯堆叠参数量或 token 数，可能获得更高的边际收益。

1.1.3 上下文长度与配比的成本

扩大规模、提升质量与延长上下文长度都需要付出算力代价，三者相互挤占。长文本带来的注意力计算与 KV 缓存开销随上下文长度线性增长，构成一项与 N、D 同时相关的额外成本；而调整领域配比本身不增加总算力，但会改变算力在各领域间的分配效果。围绕数据配比已有若干可操作的经验规律：配比可用回归方法在较小规模上预测 [6]，领域权重可在训练过程中动态优化 [7]，领域与技能之间的结构性差异也会改变最优配比 [8]，而数据选择方法的整体图景见 Albalak 等 [9]。本赛题要求以公开数据与已标注可信度的半合成数据为据，建立 N、D、Q、$\boldsymbol{p}$ 与 L 的关系，并在此基础上研究算力约束下的资源配置。

1.2 数据条件

赛题附件共 40 个文件、约 551 MB，按所服务的问题分为三组（附件编号与文件名的对照见《数据说明》）。图 1.1 给出数据的整体构成与本队的处理路径。

附件 A（质量信号与配方实验）服务问题一。其中 A1 为质量主样本（51 230 条 × 27 字段），A2、A3 为 arxiv 与 github 两个域的扩展集（17 523 条与 203 752 条），三者合为 22 个质量指标的全量记录；A4–A11 为 1M、60M、1B 三个尺度下的训练与检验配方及其对应 Loss；A12–A15 为 10B、70B 的外推表，其配比取自训练集子集、Loss 由三尺度幂律外推；A16 为质量域与配方域之间的人工映射参考，A18 为对原文抽样得到的文本统计量。

附件 B（标度律轨迹）服务问题二。B1、B3 为 Pythia 真实训练轨迹 [10]，B2 为经真实数据校准并注入噪声的半合成轨迹，B4 为跨模型族收敛点，B5 为文献标度律数值；B6–B8 为基于真实数据校准的半合成因子设计网格，是附件中唯一含数据质量因子的部分；B9、B10 给出百亿参数以上的报告值与外推值，用于讨论外推可信度边界。

附件 C（评测榜单）服务问题四。C1 为 Open LLM Leaderboard 的投榜记录 [11]，C3 为其时间序列版本，C4 为模型元数据（含参数量与开源权重字段），C5、C6 为 Loss 与榜分的桥接数据，C7 为架构元数据并给出上下文长度的可行取值，C8 为 BBH 等基准的逐任务评测明细。

按题目要求的可信度分级，A4–A11、B1、B4、B5、C1–C4、C8 等属真实观测；A12–A15、

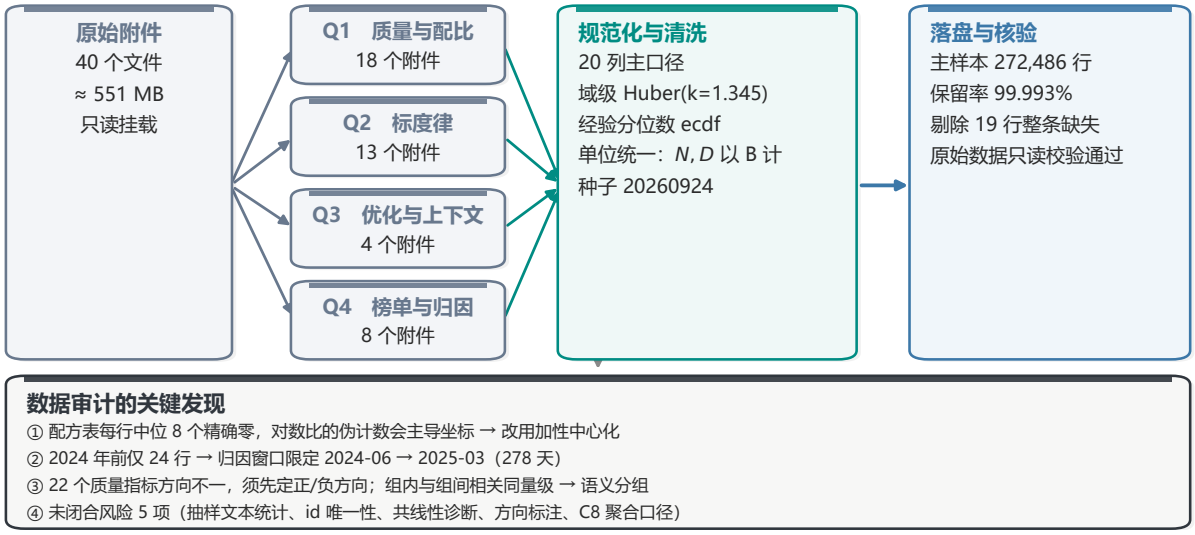


图 1.1：附件数据的构成、按问映射与规范化流程。左侧为 40 个原始附件（只读），中部为按子问题划分的输入集，右侧为规范化、清洗与一致性核验环节。

A13、A15 与 B10 为外推或子集；B2、B6、B7、B8 为半合成数据。后两类在后续各节首次使用时均标明其性质，其结论仅作补充分析，不作为直接实验观测。

1.3 任务说明

赛题四问构成一条递进主线，前一问的输出是后一问的输入。

问题一要求在统一 22 个质量指标方向的前提下建立综合评价模型，给出样本级、语料级或领域级的质量评分 Q；定义并分析指标之间的冲突，给出消解规则；并利用配方实验数据建立 17 域配比 $\boldsymbol{p}$（满足单纯形约束）与交叉熵损失之间的定量关系，同时在检验集上验证、在外推表上讨论稳健性。是否以及如何把质量评分引入配比模型，由本队论证。

问题二要求综合问题一输出的 Q 与 $\boldsymbol{p}$，建立同时包含 N、D、Q、$\boldsymbol{p}$ 的广义标度律，说明其相对经典形式的退化行为，分析各因素的边际效用与弹性，讨论领域之间的替代或互补关系，并推导提升数据质量与扩大模型规模可相互替代的条件。

问题三要求在总算力预算 C 的约束下求解 N、D、Q、$\boldsymbol{p}$ 的最优配置。算力消耗由基础训练开销 $C_{\text{train}} = 6ND$、质量提升开销 $C_Q = D\,[g(Q) - g(Q_0)]_+$ 与长文本注意力开销 $C_{\text{attn}} = \eta N D L_{\text{ctx}}$ 三部分构成，其中 $\eta = 2 \times 10^{-4}$，L_{ctx} 由架构与任务需求外生给定。本问还要求讨论成本函数 g 的选取对最优解的影响，并分析预算跨越不同量级时资源分配是否发生结构性转移，且须给出该转移的数学定义与识别方法。

问题四要求利用评测榜单数据分离并量化规模扩张与非规模技术进步对模型能力的贡献，在算力增长放缓的情景下预测未来 12 个月或 24 个月开源模型的能力前沿并给出不确定性分析；还要求建立交叉熵损失与多维基准得分之间的映射，并讨论映射误差对结论的影响。

四个子问题共享同一套数据与参数体系：问题一的 Q 与 $\boldsymbol{p}$ 进入问题二，问题二的标度律参数进入问题三与问题四的预测环节，问题三的优化结果又反过来解释问题四所观察到的规模变化。本文的整体框架与证据链见图 2.1。

2　问题分析

2.1　总体思路

四个子问题沿「刻画数据—纳入规律—求解配置—检验外推」的顺序展开，前一问的输出构成后一问的输入，因此建模设计上需要保证接口的可用性：问题一输出的质量评分必须定义在可比较的尺度上并能聚合到领域级，问题二估计的标度律参数必须与问题三的成本约束在单位与量纲上一致，问题四的预测则要求把损失尺度上的规律可靠地换算到基准得分尺度。本文的整体框架、各问的方法要点以及证据的追溯路径见图 2.1。

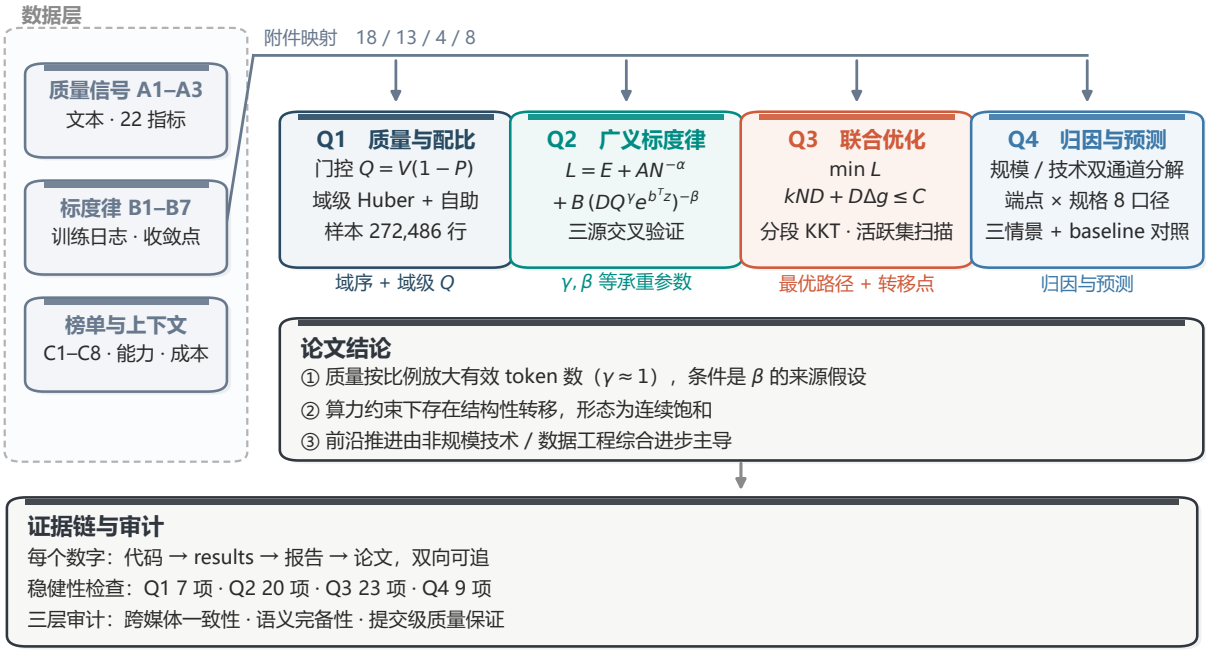


图 2.1：全文框架。上排为数据层（附件 A、B、C 三组，按问映射为 18/13/4/8 个文件），中部四列为四个子问题的方法要点与相互依赖，下方为汇总结论与证据链。

在方法选择上，本文遵循两条原则。其一是**可检验优先**：凡进入主结论的量，都必须给出可机械判定的判据与重抽样区间，而不是依赖拟合优度的直观好坏。其二是**退化一致**：问题二的广义标度律在数据质量取参照值、领域配比取均匀时须退回经典形式，问题三的最优解在质量不可提升时须退回经典的经验配置，以此作为各自的形式约束。

2.2　问题一的分析

问题一包含三项彼此耦合但目标不同的任务，其难点不在于单件技术的复杂度，而在于三者的口径必须自洽。

质量评价的首要障碍是**指标方向未在数据中标注**。赛题附录指向《数据说明》给出方向说明，但该处并无方向标注，因此方向表只能由本队依据字段定义、指标间的一致性与可核验的文本证据推得，并按可信度分层。其次是**列表型指标不能取均值**：二分类与有序分类的判别器输出是 logits，直接取均值会自我抵消，须分别按 logit 差与 softmax 期望类别压缩为标量。第三是**长度混淆**：按 token 求和的字段与文档长度高度相关，其表观方向是长度效应的产物。

在合成方式上，本文取「价值组均值 × 污染组的补」的门控形式，使两类方向相反的指标各司其职：污染类指标进入门控，从而在合成值上产生乘性惩罚，而不是与价值类指标在均值中互相抵消。冲突的定义随之自然给出：**同一文本在价值维度与污染维度上同时**

取高分即为冲突，本文将两个维度分别按分位数锚定，使冲突率不随样本量漂移。

配比建模的困难来自数据的稀疏性与目标变量的构造。配方表每行中位约有半数的域取精确零，对数比变换不可用；可用的质量域只有 6 个，与配比域部分不相交。更关键的是，若以配比加权的域间损失作为目标，配比会同时出现在等式两侧，构成部分循环。本文的处理是：如实声明该循环，并用简单平均作为对照口径，以检验域效应的量级排序是否依赖目标口径的选择。

2.3　问题二的分析

问题二的形式设计受两条约束牵制。一方面，题目要求新形式在质量取参照值时退回经典标度律，这排除了把质量作为独立加性项的写法；另一方面，数据条件限制了什么可估：主拟合数据没有质量变化，配备质量的半合成网格则只有 5 个不同的数据量取值。这意味着**数据量指数与质量指数不可在同一份数据上同时良好辨识**，必须先由真实数据把数据量指数钉住，再由半合成网格反解质量指数。因此本文采用「先定 β、后解 γ」的估计顺序，并把该顺序的代价——结论对共享假设的依赖——作为一个独立的可检验问题单独报告，而不是把它藏在拟合过程里。

领域配比项的处理同样受数据限制。全部含配比列的附件中无一与 (N, D) 联合观测，故配比的效应形状无法跨源验证，只能作为一个声明的承重假设；相应地，本文对配比项只报告各域边际效应的方向与相对排序，不报告其绝对量级，因为后者含有一个在该数据条件下严格不可辨识的标度常数。

2.4　问题三的分析

问题三是一个带不等式约束的三维非线性规划，但其结构比维度所暗示的更复杂：探针显示，在九个「预算 $\times$ 成本函数」组合中，最优质量有七个顶在上界，说明内点一阶条件在多数情形下并不刻画最优解。因此本文不采用单纯的内点求解，而是**按活跃约束集分支枚举**：内点分支与质量触上界的降维分支分别解析求解，再按 KKT 条件筛选，并用独立数值方法验证分支枚举的完备性。

本问的理论产出在于**结构性转移的数学定义**。「预算跨越量级时最优策略是否质变」在没有定义的情况下不可判定，而不同的定义会给出不同的答案。本文的做法是同时给出三种自然定义并逐一识别，指出哪一种不依赖人为阈值与网格步长，从而说明「转移存在」这一判断的成立范围——这一点比转移点的具体位置更有价值。

2.5　问题四的分析

问题四的核心风险是**不可检验性**。时间窗口只有 9.1 个月，却要求外推 12–24 个月；归因分解中的技术通道无法直接观测，只能由规模项之外的残差吸收，因而它同时包含未观测的数据质量变化与对基准的过拟合，不能被解释为纯粹的算法进步。本文据此把本问的主辩护对象确定为**归因侧的方向与量级**：强调技术通道在全部口径下为正、规模通道的贡献与零不可区分，而**不主张任何具体的百分比分割**——后者在端点定义变动下会发生符号翻转。

分解的可辨识性依赖于时间与规模不共线。由于窗口内高分段模型的规模反而在收缩，规模效应与时间效应在方向上部分背离，这反而有利于二者分离；但也正因如此，规模项的线性规格会给出符号相反的份额，本文对规格与端点两种不确定性分别报告，把「点值不稳定」这一事实本身作为结论的一部分。

预测环节还需要把损失尺度上的规律换算到基准得分尺度。桥接样本中高可比层级只有 7 个点，映射误差与得分尺度同量级，因此预测区间必然很宽。本文不掩饰这一点，而是把该宽度作为数据条件的结果如实报告，并同时给出不分解、不外推衰减的纯趋势基线作为对照。

2.6 关键难点与应对

表 2.1：四个子问题的主要难点与本文的应对方式

子问题	主要难点	应对方式
一	指标方向无标注；列表型指标不可取均值；长度混淆	分层方向表并报敏感性；logit 差与 softmax 期望类别压缩；逐 token 归一化
一	配方表稀疏且质量域部分不相交；目标含配比、存在循环	不施对数比变换；显式声明循环并给出对照口径
二	质量指数与数据量指数不可同时辨识；配比效应形状不可跨源验证	先定数据量指数、后解质量指数；只报配比效应的方向与排序
三	最优解多数触上界，内点条件不刻画最优	按活跃约束集分支枚举，并以独立数值方法验证完备性
三	「结构性转移」无公认定义	并报三种定义，标明哪一种不依赖阈值与步长
四	窗口不足以外推；技术通道不可直接观测	主辩护改为方向与量级，不主张百分比分割；技术通道只作综合表述
四	损失与得分尺度之间的映射样本极少	映射误差作独立随机项传播，并给出纯趋势基线对照

3 模型假设与符号说明

3.1 模型假设

3.1.1 全局假设

A1. 损失由配置决定。在给定模型族与训练配方下，验证集交叉熵损失 L 由参数量 N、训练 token 数 D、数据质量 Q 与领域配比 $\boldsymbol{p}$ 共同决定，训练过程中的超参数调整与随机波动不构成系统性的解释变量。

A2. 附件可信度分级可采信。各附件所标注的真实观测、外推子集与半合成性质被采信；半合成数据只用于补充分析，其结论不表述为直接实验观测。

A3. 尺度可迁移性有限成立。配比到损失的响应形状可跨训练尺度迁移，但水平项随尺度平移。因此跨尺度验证一律在按尺度去除水平偏移之后进行，或改用秩相关度量。

A4. 算力近似成立。$C_{\text{train}} = 6ND$ 作为前向与反向传播算力的近似，在附件 B 的真实轨迹上该口径与报告的算力值一致。

A5. 损失与得分单调负相关。多维基准的综合得分与验证集交叉熵损失单调负相关，这是问题四在两种尺度之间建立映射的前提；该关系本身的拟合误差作为独立随机项处理。

A6. 时间轴以提交日期计。问题四按模型在榜单上的提交日期归入月份，并把投榜模型视为同期开源前沿的代表性样本，而非开源模型的总体。

3.1.2 方法性假设

除上述全局假设外，各问还依赖若干会被结论直接继承的前提，此处一并声明。

B1. 质量指标方向表由本队推得（问题一）。附件未给出 22 个指标的方向标注，方向依

据字段定义、指标间一致性与可核验的文本证据推得，并按可信度分三层；方向不确定的层次承重项由本队裁定，其影响以敏感性方式报告。

B2. 配比效应的形状可跨来源迁移（问题二）。附件中没有任何一个文件同时给出配比与 (N, D) 的联合观测，故 b 的取值只能由问题一的配比模型引入。该假设不可在本数据上检验，且被结论直接继承。

B3. 数据量指数可跨来源共享（问题二）。质量指数的反解依赖于该前提。本文对该前提单独做了检验并如实报告结果，质量指数的解释因此带有条件性。

B4. 领域配比由前两问固定（问题三）。配比项对配比是线性的，在单纯形约束下最优解落于顶点，故本问把配比作为既有配置而非寻优变量。

B5. 基线质量取固定值（问题三）。Q_0 的取值未经外部确认，本文在其合理范围内做扫动并报告结论的稳定性。

B6. 榜单得分与算力元数据可经名称连接（问题四）。两个附件中的模型经名称规范化后视为同一模型，该连接是承重的；名称无法匹配的记录作缺失处理，不参与分解。

3.2 符号说明

3.2.1 全局符号

表 3.1 列出全文通用符号。凡涉及同一符号在不同子问题中含义不同的情形，本文在首次出现处以下标或修饰符区分，并在表中注明。

表 3.1：全文通用符号与单位

符号	含义	单位	说明
N	模型参数量	十亿（B）	全文以十亿为单位；代入 $C = 6ND$ 时须乘以 10^9
D	训练 token 数	十亿（B）	同上
C	算力预算	FLOPs	问题三沿 10^{18}–10^{25} 扫描，以 10^{19}、10^{22}、10^{24} 三档锚定
L	验证集交叉熵损失	nats/token	全文的损失尺度
Q	数据质量评分	无量纲	取值于 $(0, 1]$；问题一给出，问题二、三沿用
Q_0	基线质量	无量纲	问题三中不投入质量提升时的质量水平
$\boldsymbol{p}$	领域配比向量	无量纲	$\boldsymbol{p} = (p_1, \ldots, p_{17})$，$p_i \geq 0$ 且 $\sum_i p_i = 1$
E	不可约损失	nats/token	经典标度律的截距项
A, α	参数量项的系数与指数	—	由真实轨迹拟合得到
B, β	数据量项的系数与指数	—	β 亦记作数据量弹性
γ	质量指数	无量纲	$D_{\text{eff}} = D\,Q^{\gamma}$ 中的指数
D_{eff}	有效 token 数	十亿（B）	$D_{\text{eff}} = D\,Q^{\gamma}$，把质量折算为等效数据量

续表 3.1

符号	含义	单位	说明
$\boldsymbol{b}$	配比项的系数向量	无量纲	$\boldsymbol{b}=\kappa(\boldsymbol{\theta}-\bar{\theta})$，$\kappa<0$，在附件 B 上不可辨识
$\boldsymbol{z_p}$	配比的中心化偏离	无量纲	均匀配比对应 $\boldsymbol{z_p}=\mathbf{0}$
κ	配比项的标度常数	—	在附件 B 上不可辨识，故只报比值 b_i/b_j
$g(Q)$	单位数据质量的提升成本函数	—	问题三给出三类候选形式
g_{c}，g_{r}	成本函数的幅值系数与速率参数	—	仅在问题三讨论第四类 g 时使用，避免与质量指数 γ 同名
L_{ctx}	上下文窗口长度	token	外生给定，取值依据附件 C7
η	注意力开销系数	—	$\eta=2\times10^{-4}$
k	单位数据的训练与注意力开销系数	—	$k=6+\eta L_{\mathrm{ctx}}$
k_{H}	Huber M 估计的稳健化参数	—	取 1.345，仅用于问题一的域级聚合
B_{boot}	自助重抽样次数	—	仅用于问题一的区间估计，与数据量项系数 B 无关
τ（问题一，无下标）	域序的 Kendall 秩相关系数	无量纲	仅用于问题一的域序稳定性；问题四的 τ_t 是月度效应，二者不同
Q^*, N^*, D^*	最优配置	无量纲 / B / B	问题三在给定预算下的解
S	模型综合能力得分	分	仅用于问题四，为六维基准的等权平均
S_{q90}	能力前沿	分	每月综合能力的 0.90 分位
N_{q90}	前沿模型规模	十亿（B）	每月参数量的 0.90 分位
$f(N)$	规模通道函数	分	问题四分解中的规模项
τ_t	第 t 月的技术通道效应	分	吸收规模之外的全部月度共同变动
V，P	价值维度、污染维度得分	无量纲	问题一门控合成的两个分量
θ_d	第 d 个配方域的损失水平系数	nats/token	问题一配比模型的系数；问题二的 $\boldsymbol{b}$ 由其中心化得到

3.2.2 数据与附件编号

附件编号沿用《数据说明》：A1–A3 为质量信号的全量记录，A4–A11 为三尺度配方与损失，A12–A15 为高尺度外推表，A16 为跨体系映射参考，A17、A18 为辅助摘要与抽样文本统计；B1–B12 为标度律轨迹、收敛点、文献值与半合成网格；C1–C10 为榜单、模型元数据、桥接数据与逐任务评测明细。四问的附件映射见第 1 节图 1.1。

3.2.3 指标与领域的简称

质量侧的 22 个指标与配比侧的 17 个领域均以附件原名引用。为便于行文，表 3.2 给出正文中反复出现的少数简称。

表 3.2：正文使用的简称对照

简称	全称或含义
门控合成	质量评分 $Q = V \cdot (1 - P)$，V 为价值维度均值，P 为污染维度污染度均值
可分辨域对	两个领域的质量区间（自助 95%）不重叠，故其高低可在统计上区分
冲突率	由所采用的冲突判据判定为冲突的样本占全体的比例
去偏 R^2	在各尺度上先扣除水平偏移后再计算的决定系数
去源偏 RMSE	先扣除各来源的截距偏移后再计算的均方根误差
端点法	仅用窗口首月与末月的读数做差分以定义通道贡献
趋势法	用窗口内全部十个月的斜率定义通道贡献
活跃约束集	在最优解处取等号的约束集合
结构性转移	最优策略随预算发生质变；其数学定义见第 6 节

4 问题一：数据质量评价、冲突消解与领域配比建模

4.1 任务分解与整体口径

问题一的三项任务共享同一批质量信号，输出对象却不同：质量评价须给出可跨样本比较、可聚合到领域层的评分 Q；冲突分析须识别指标之间方向相反的张力并给出消解规则；配比建模须建立 17 个配方域权重 $\boldsymbol{p}$ 与交叉熵损失的定量关系，并论证是否以及如何引入 Q。三者若各用一套预处理，量表便无法拼接：领域级 Q 是问题二的输入，配比侧的损失须与问题三的成本口径对齐。本节先固定一套口径，再分别求解，整体流程见图 4.1。质量主样本由 A1、A2、A3 拼合，共 272 505 行；19 行（18 行出自 A1、1 行出自 A3）有某个列表型字段整条缺失（该字段为 6 维向量，如 ModernBERT 推理与专业性两列），不含质量信息，予以剔除，保留 272 486 行，占 99.993%，与独立的缺失审计一致。22 个原始指标经规范化后合并为 20 列：三个 DSIR 字段在逐 token 归一化后互相关仍高于 0.996，合并为一个代表量。归一化以合并总体上的经验分位数为主口径，以按域分别归一化作为消融臂。领域级聚合取 Huber M 估计（稳健化参数 $k_{\mathrm{H}} = 1.345$），区间由 $B_{\mathrm{boot}} = 400$ 次自助重抽样给出，并对聚合估计量、随机种子与扰动幅度分别作替换检验。

4.2 22 个质量指标的方向统一与规范化

22 个指标中，教育价值与整洁度等打分出自现代网页语料管线的判别器 [12, 13]，其余为文本统计量与 DSIR 式对数似然比 [14]；其方向并不一致，教育价值与流畅度越高越好，模板化重复与噪声占比越低越好。赛题附录把方向标注指向《数据说明》，但该处可见文本中并无逐字段说明，方向表只能自行推得：题面或原文明示者可核验，字段定义与指

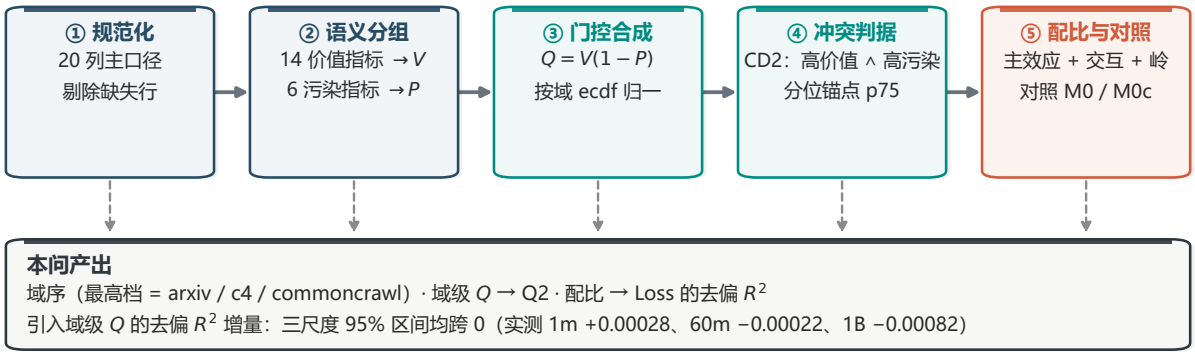


图 4.1：问题一的方法流程。□—□ 为依次执行的五个环节：规范化（20 列主口径并剔除缺失行）、语义分组（14 个价值指标归入 V、6 个污染指标归入 P）、门控合成 $Q = V(1-P)$、冲突判据 CD2（高价值且高污染，分位数锚定）与配比建模（主效应加二阶交互，以岭回归正则化）。下方为本节交付物：领域序及其最高一档、领域级 Q（供问题二对照，其刻度对齐见问题二）、配比到损失的拟合优度，以及域级 Q 增量在三尺度上的实测值与区间。

标间一致性支持者可推证，两者皆不足以判定者列为方向待定。待定者恰为三个长度类字段（词数、句数与平均词长）。长度与质量的关系本不单调，过长与过短皆劣，这与数据剪枝文献中样本统计量与有用性之间的非单调关系同源 [15]，而按区间而非固定阈值使用长度也是语料过滤的通行做法 [16]；三项长度指标因此不取线性方向，而按到域内中位数的距离处理，两端受罚、中间得优。

DSIR 三列须单独讨论。原始字段是按 token 求和的对数似然比，属外延量，与长度高度绑定：log(−dsir) 与 log(词数) 的 Pearson 相关为 0.937—0.939，与词数的 Spearman 相关为 −0.93 左右，直接用该字段排序几乎等同于按长度排序。逐 token 归一化后，三个字段彼此的互相关升至 0.996 以上，名义上是三个域的相似度，实际已高度接近同一构念，故合并为一个代表量。该处置同时修正了方向证据：归一化前该字段与教育价值打分的 Spearman 为 −0.499，归一化后为 +0.374，方向依据由建模判断升级为数据可证。

另一处长度纠缠落在一对统计量上：唯一词占比与一元词熵对 log(词数) 的 Spearman 分别为 −0.85 与 +0.95，方向相反。纯由长度即可生成约 −0.81 的负相关；把二者的长度分量各自剔除后，相关由 −0.68 翻转为 +0.92，可见原始负相关是长度诱导的伪矛盾，二者在同等长度下度量的是同一构念，即词汇多样性。本节未施加校正，因为校正会同时制造冗余：残差化后二者相关为 +0.92，在等权平均中近乎重复计入同一构念。

归一化取经验分位数，即以合并总体上的中位秩作单调映射（式 (4.1)）：

$$z_j(x) = \frac{R_j(x) + 1/2}{n+1}, \qquad R_j(x) = \tfrac{1}{2}\big(\#\{i : x_{ij} < x\} + \#\{i : x_{ij} \le x\}\big), \tag{4.1}$$

$z_j \in (0,1)$ 且对单调变换不变。取分位数而非字面极差，是因若干字段量纲跨度极大，例如 DSIR 原始值的中位数为 -2.4×10^3、最小值为 -2.0×10^6，字面 Min–Max 会把几乎全部样本压进贴近 0 的窄带；对照实现为 1%–99% 截尾后的 Min–Max。方向统一按式 (4.2) 施加：

$$u_j(x) = \begin{cases} z_j(x), & s_j = +1, \\ 1 - z_j(x), & s_j = -1, \\ 1 - 2\,|z_j(x) - \tfrac{1}{2}|, & s_j = 0, \end{cases} \tag{4.2}$$

$s_j = 0$ 即前述非单调的长度类指标。五个污染类指标（非字母词占比、最高频 2-gram 与 3-gram 字符占比、大写字母占比、数字字符占比）方向为负，统一取 $1 - z_j$；广告判别器的输出是两类对数几率之差 $\text{pos}_1 - \text{pos}_0$，该差值本身已是「不像广告」，方向为正，无须附加转换，其污染贡献在合成时取补。表 4.1 汇总 22 个原始指标的分组、原始方向与统一方式。

表 4.1：22 个质量指标的方向统一与规范化处置。列数按原始字段计，DSIR 三列合并后主口径为 20 列；V、P 为合成时的语义分组。

类别	指标	列数	统一方式
教育/专业度判别器	教育价值、质量评级、ModernBERT 四项（整洁度、可读性、推理、专业性）	6	原始方向为正，直接取 z_j
广告与流畅度	广告性 margin、流畅度 margin	2	差值本身即为「越高越好」，不附加转换
DSIR 相似度	三个域的对数似然比	3	先除以词数逐 token 归一化，再合并为一个代表量
长度类	词数、句数、平均词长	3	方向非单调，按 $1-2\lvert z_j-\frac{1}{2}\rvert$ 处理
词汇多样性	唯一词占比、一元词熵	2	原始方向为正，取 z_j；不做长度校正
污染类	非字母词占比、2-gram 与 3-gram 字符占比、大写字母占比、数字字符占比	5	原始方向为负，取 $1 - z_j$
句子完整性	以终止标点结尾的行占比	1	原始方向为正，直接取 z_j

4.3 门控合成与域级质量评分

方向统一后，V 组 14 列与 P 组 6 列分别度量价值与污染。等权平均把两类信号置于同一尺度相抵：模板化但通顺的推广文案可凭价值分抵消污染分，既不合语料治理的经验，也无法定义冲突。本节改用门控合成：

$$Q(x) = V(x)\,\big[1 - P(x)\big], \qquad V(x) = \frac{1}{|V|}\sum_{j\in V} u_j(x), \qquad P(x) = \frac{1}{|P|}\sum_{j\in P}\big[1 - u_j(x)\big]. \tag{4.3}$$

式 (4.3) 中 P 落在 $(0,1)$ 内，故 $Q \in (0,1)$ 且无须截断，与问题三中 $g(Q) = 5\times 10^9 Q^4$ 一类在非负区间单调的定义相容。分组依据是字段语义而非相关结构：组内平均相关 0.150 与 0.026、组间 -0.013，三者同量级，不能声称其由相关结构导出，这一点在分组扰动检验中会再次出现。

领域级 Q 由域内样本聚合。逐域分布右偏且含少量离群文档，算术均值会被尾部拉动，本节取 Huber M 估计

$$\hat{Q}_d = \arg\min_{m} \sum_{x\in d} \rho_{k_{\mathrm{H}}}\!\left(\frac{Q(x) - m}{\hat{\sigma}_d}\right), \qquad \rho_{k_{\mathrm{H}}}(r) = \begin{cases} r^2/2, & |r| \le k_{\mathrm{H}}, \\ k_{\mathrm{H}}|r| - k_{\mathrm{H}}^2/2, & |r| > k_{\mathrm{H}}, \end{cases} \tag{4.4}$$

式 (4.4) 中 $k_{\mathrm{H}}=1.345$，$\hat{\sigma}_d$ 由中位绝对偏差按 1.4826 折算，区间由 $B_{\mathrm{boot}}=400$ 次自助重抽样给出。表 4.2 同表列出等权平均基线 M_0 与门控合成 M_1 的域级取值与区间。

表 4.2：七个领域的质量评分 Q 与 95% 自助区间（$B_{\mathrm{boot}}=400$，Huber M 估计，合并总体分位数口径）。n 为域内样本量。表中数值保留四位小数，与自助样本的蒙特卡洛精度相称。

领域	n	M_0 等权平均	M_0 区间	M_1 门控合成	M_1 区间
arxiv	18 942	0.6494	(0.6490, 0.6498)	0.3815	(0.3807, 0.3823)
c4	10 000	0.6019	(0.6000, 0.6036)	0.3638	(0.3619, 0.3658)
commoncrawl	9 636	0.6013	(0.5999, 0.6027)	0.3479	(0.3464, 0.3498)
stackexchange	10 000	0.5830	(0.5819, 0.5842)	0.2943	(0.2929, 0.2958)
wikipedia	9 986	0.5326	(0.5310, 0.5343)	0.2556	(0.2542, 0.2572)
book	171	0.5264	(0.5170, 0.5356)	0.2668	(0.2584, 0.2753)
github	213 751	0.4736	(0.4733, 0.4740)	0.2233	(0.2230, 0.2236)

图 4.2 给出预先声明的两项判据。等权平均在 21 个域对中分辨出 19 对，门控合成分辨出全部 21 对，新增的两对正是 book 与 wikipedia、c4 与 commoncrawl。40 次 $\pm10\%$ 列权重扰动下，门控合成的域序 Kendall τ 均值为 0.9976、域序完全不变的重复比为 0.975，等权平均为 0.9595 与 0.625，两者之差的 95% 区间 $[0.019, 0.057]$ 不含零；放宽到 $\pm20\%$ 差值仍为 $+0.0500$（$[0.0262, 0.0762]$），$\pm30\%$ 为 $+0.0357$（$[0.0023, 0.0714]$），该档已超出小扰动的合理范围，仅作探索性报告。

域序须谨慎表述。合并总体口径下的门控合成给出 arxiv $>$ $c4$ $>$ commoncrawl $>$ stackexchange $>$ book $>$ wikipedia $>$ github，等权平均仅在 book 与 wikipedia 处与之相反。该次序与直觉不完全吻合，其中一部分应是真实的：22 个指标大多是面向现代网页文本训练的判别器，book 域的 171 条样本取自 Gutenberg 公版书，其拼写与排版在现代可读性打分上本就吃亏，该偏差不应通过调方向消除，而应作为口径限制保留。可断言的结论有三处。其一，最高一档恒为 $\{\text{arxiv}, \text{c4}, \text{commoncrawl}\}$，在基线与 8 个分组扰动变体共 9 个配置下不变；但 arxiv 居该档之首并不稳固：把污染组中任一列移入价值组后，其档内位次实测取到过 1、2、3，其中两个变体下 c4 的反超裕度达 9.38 倍与 3.92 倍区间半宽和，属统计可分。机理在于 $Q=V(1-P)$ 中同一列置于 V 是加性贡献、置于 P 是乘性门控，归属变更即改变其函数角色，而分组是纯语义划分；故本节只报最高一档，不对档内位次作断言。其二，c4 优于 commoncrawl（裕度 4.37 倍区间半宽和）与 github 居末在基线与全部变体下成立，方向可照常报告。其三，book 与 wikipedia 统计上不可区分：域级 Q 差在等权平均下为 0.00617（wikipedia 略高）、在门控合成下为 0.01113（book 略高），方向随合成方式反转，较大一侧的裕度仅为区间半宽和的 1.12 倍。book 域区间偏宽可由样本量解释：等 n 对照重抽给出的半宽为 0.00880，与表 4.2 中门控合成的自助区间同量级但不同源，是 github 的 25 倍以上；把其余六域各自无放回降采样到 $n=171$ 并重复 40 次，半宽包络为 $[0.00715, 0.01691]$，book 的实测半宽落在包络内且偏窄端，无须归因于域内异质。该域级 Q 供问题二使用时须附说明：book 的取值不可靠，下游环节须为其设置敏感性臂。

一项限制在此处即可确证：用 Q 区分 arxiv 与 github 的 AUC 在门控合成下为 0.9486、等权平均下为 0.9741，即单一标量评分高度可由领域标签还原。这一缺陷并非本规格引入：数据阶段已查明 25 个候选标量中有 15 个近乎完美地分离 arxiv 与 github，全部 22 个指标的最大域对分离度均不低于 0.30。按域归一化虽能把该 AUC 压到 0.50 附近，但域级 Q 同时近乎恒等（域间极差由 0.1582 降至 0.0115）、21 个域对中仅 9 对可分辨，故它只是消融臂，用以量化主口径选择的代价。在这批指标上，单一标量评分不可能同时做到跨域可比

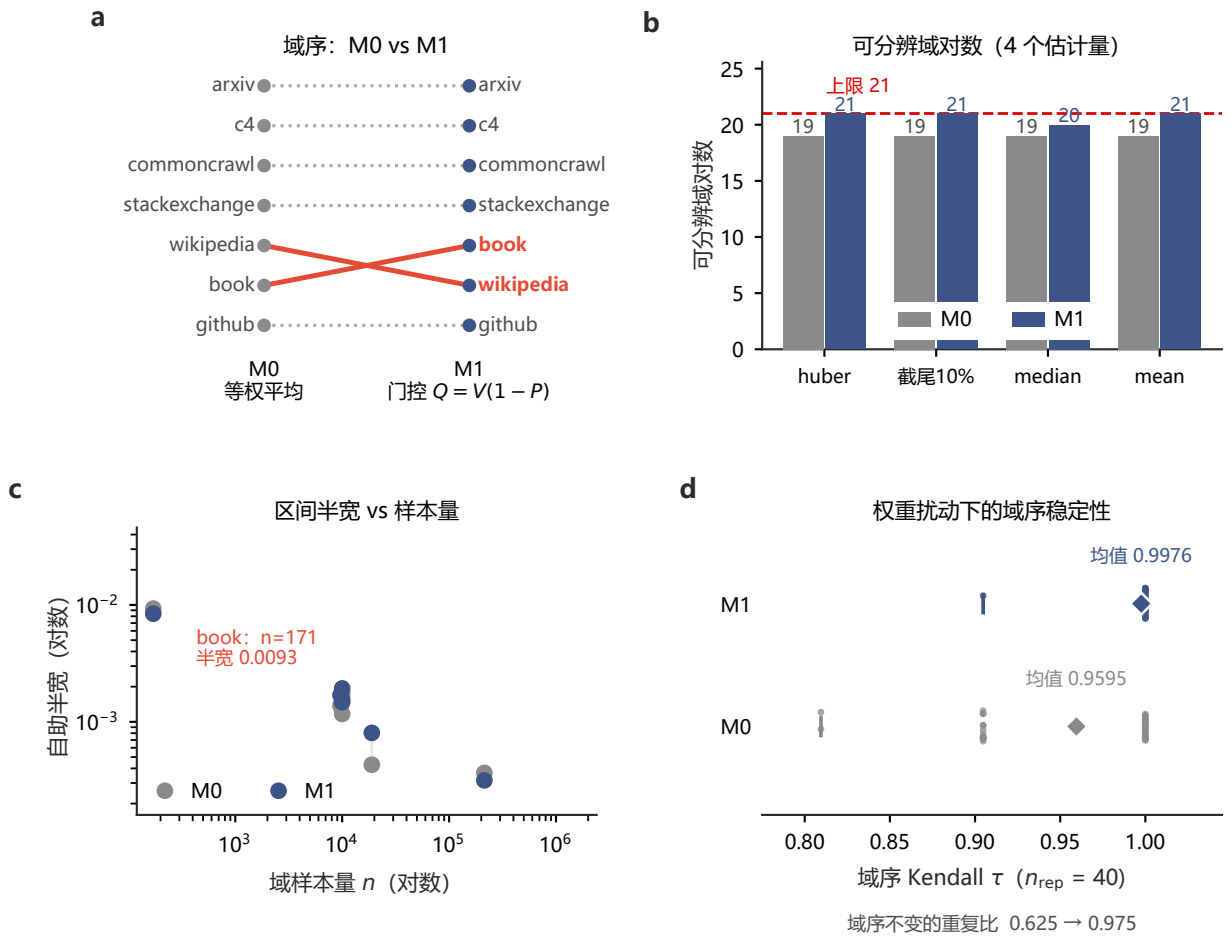


图 4.2：门控合成与等权平均的对照。(a) 两法的领域序，虚线为次序不变，红色横线标出唯一互换的一对；(b) 四个聚合估计量下的可分辨域对数，虚线为上限 21；(c) 域级自助半宽对域样本量（双对数），左下角孤点为 book（$n = 171$，半宽 0.0093）；(d) 40 次权重扰动下的域序 Kendall τ 分布，门控合成均值 0.9976、等权平均 0.9595，域序不变的重复比自 0.625 升至 0.975。

与域去混淆。

4.4 质量冲突的定义与消解

冲突在门控形式下有自然的含义：同一篇文本在价值与污染两类指标上同时取高分，即一端被判为有用，另一端被判为模板化。绝对阈值不适合描述这种现象：把两维阈值都定在 0.75，实测冲突率恰为零，因为两维各自的 75% 分位点都低于该值。本节改以分位数锚定，主判据取式 (4.5)：

$$\text{CD2}: \quad x \text{ 为冲突} \iff V(x) > Q_{0.75}(V) \text{ 且 } P(x) > Q_{0.75}(P), \tag{4.5}$$

即在两维上同时落入上四分位。冲突率对锚点单调，p_{70}、p_{75}、p_{80} 三档分别为 0.0687、0.0408、0.0208，主报值 0.0408 落在 $(0.01, 0.50)$ 内，既非退化也非饱和。消解规则相应地不是删除而是标注：冲突样本保留在样本集中，但在涉及质量提升的成本口径中宜按质量上界处理。本文未对冲突比例另设敏感臂，该处置只作口径声明。

作为对照的另三个判据基于组内指标的异常度，而非两维之间的张力。表 4.3 上半部分给出四判据在三档锚点下的全局冲突率。MAD 锚定判据的全局率恰等于 1 减去锚点（实测 0.3000、0.2500、0.2000），这是「一维离散度取分位数阈值」的恒等式，不含样本信息，故该判据只报告域级分布与子集重叠度；「至少三高且至少三低」判据在 p_{70} 下给出 0.8357，把绝大多数样本判为冲突，同样退化。按 p_{75} 锚点衡量，主判据与其余三者所标识的冲突子集重叠度很低，Jaccard 系数为 0.030、0.036 与 0.045，而两个异常度判据彼此重叠到 0.512，实质是同一子集的不同切法。

主判据的域级取值给出本节最有信息量的一条读数：stackexchange 的冲突率为 0.174，c4 为 0.004，两者相差 43 倍，book 为 0.035 处于低位；两个异常度判据恰在此处失效，它们把 book 域几乎全部判为冲突（CD1 固定阈 0.25 下 0.994，另一判据下 1.000），即 171 条公版书全部进入冲突集，与该域的质量表现明显不符。图 4.3 以热力图给出四判据在两档归一化口径下的完整取值。冲突子集相对全体均值，在可读性、质量评级与整洁度上分别高出 0.263、0.244 与 0.241，在数字字符占比、大写字母占比与最高频 3-gram 字符占比上分别低出 0.198、0.191 与 0.182，广告性 margin 与 2-gram 占比各低 0.122，即这批样本写得规整通顺而模板化程度偏低，与判据的设计意图一致，逐条样本已连同其在原文件中的位置落盘。分组扰动下主判据的冲突率在 0.0236 至 0.0568 之间变动，消融臂给出 0.0550，可见其量级不依赖分组细节，这与域序头名依赖分组细节形成对照。

4.5 配比建模与质量评分的增量检验

配比侧要建立 17 个配方域权重与交叉熵损失之间的关系。17 个域取自 Pile 的域划分 [17]，配比行满足单纯形约束；自变量中位数上约有半数取精确零，对数比变换不可用，故直接以配比作自变量。基线模型对 13 个可观测损失域拟合式 (4.6) 的去截距线性形式，扩展模型在其上加入全部二阶交互项 $p_d p_{d'}$（共 153 个特征）并以岭回归正则化，正则强度取交叉验证选定的 10^{-3}，两个模型分别记为 M_{0c} 与 M_{1c}。

$$\widehat{L} = \sum_{d \in \mathcal{D}} p_d \, \theta_d, \qquad \sum_{d \in \mathcal{D}} p_d = 1, \tag{4.6}$$

去截距是必要的：截距与单纯形约束共同造成设计矩阵近乎奇异，含截距时的条件数为 4773，去截距后降至 61。配比小样本回归已有先例 [6]，领域权重亦可在训练中动态调整 [7]；本节取其静态估计，以便把系数作为可解释的域效应。

跨尺度验证须先澄清口径。原始 R^2 在 1m 尺度为 0.913，到 60m 与 1B 却分别为 -8.412 与 -173.115：偏差占均方根误差的 98.8% 与 99.9%，误差几乎全部来自损失量级随规模的平移，而非拟合失效。去掉按尺度估计的常数偏移后，R^2 回到 0.771 与 0.705，秩相关为

表 4.3：冲突判据的锚点敏感性（上半，合并总体口径的全局冲突率）与主判据的域级冲突率（下半，合并总体口径；p_{75} 锚点下取 CD2 与「至少三高且至少三低」两者，第二列取 CD1 在固定参考阈 0.25 处的衔接对照版，其取值与锚点无关）。上半部分末行为「至少三高且至少三低」判据，在 p_{70} 下已把 83.57% 的样本判为冲突；下半部分用以显示异常度判据的域级退化。

(a) 全局冲突率对锚点的响应

判据	p_{70}	p_{75}	p_{80}
CD2 高价值且高污染（主判据）	0.0687	**0.0408**	0.0208
MAD 锚定（一维离散度）	0.3000	0.2500	0.2000
至少五高且至少五低	0.3951	0.2181	0.1152
至少三高且至少三低	0.8357	0.6561	0.4688

(b) p_{75} 锚点下的域级冲突率

领域	CD2	CD1 固定阈 0.25	至少三高且至少三低
stackexchange	0.174	0.210	0.608
wikipedia	0.090	0.542	0.878
arxiv	0.038	0.878	0.958
github	0.036	0.209	0.606
book	0.035	0.994	1.000
commoncrawl	0.013	0.653	0.820
c4	0.004	0.731	0.822

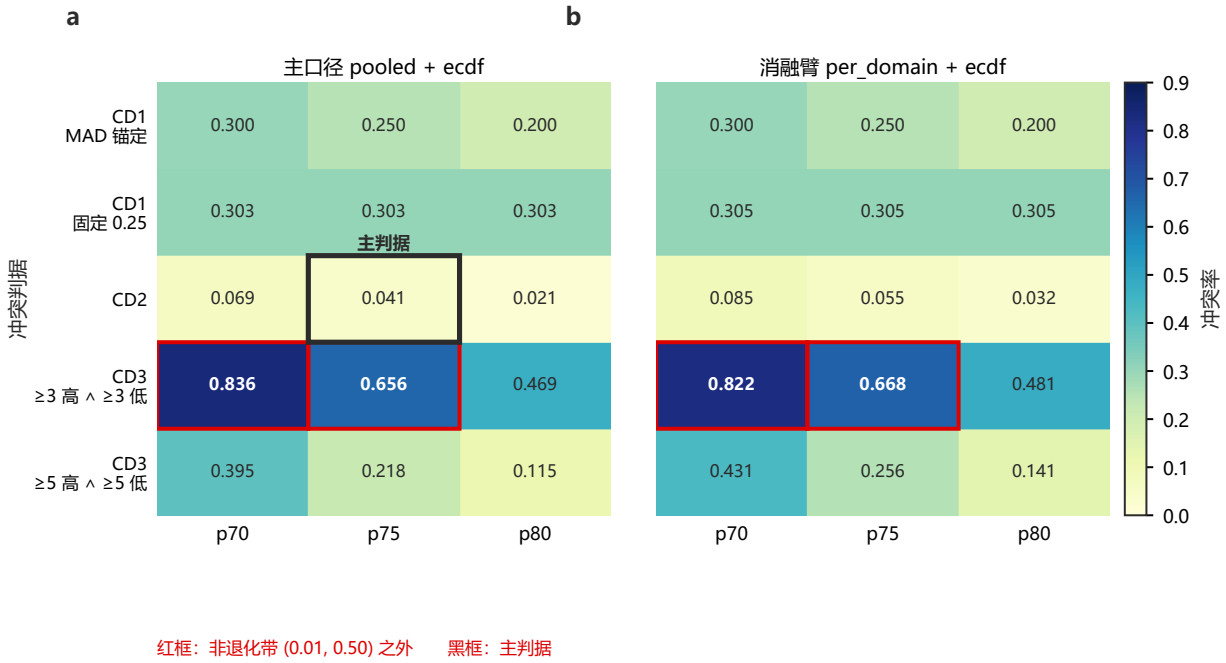


图 4.3：四判据与三档锚点下的全局冲突率热力图，横轴为锚点分位数 p_{70}、p_{75}、p_{80}，纵轴为判据，色标为冲突率。(a) 合并总体口径，(b) 按域归一化的消融臂。黑框标出主判据 CD2 在 p_{75} 处的取值 0.041，红框标出取值越出非退化带 $(0.01, 0.50)$ 的格子；两档口径下越界的格子相同，均为「至少三高且至少三低」判据在 p_{70} 处的 0.836 与 0.822。

0.922 与 0.887。即配比到损失的形状跨尺度可迁移，只有水平随规模平移，故验证一律报告去偏 R^2 与秩相关，原始 R^2 不作单独引用。在去偏口径下，M_{1c} 的增益只在 1m 尺度为正（$+0.0703$），60m 为 -0.0050、1B 为 -0.0464，秩相关增益亦为负，不构成跨尺度优势；本节因此以 M_{0c} 为主模型，M_{1c} 仅作组合效应的辅助证据。M_{0c} 的 17 个主效应系数在自助重抽样下符号全部稳定，平均相对标准误 0.034；M_{1c} 的 153 个特征中符号稳定率不低于 0.95 的只有 84 个，含主效应 17 个全部稳定与交互项 67 个稳定（其中不低于 0.99 的 53 个），其余 69 项不予报告。稳定子集之外的单个交互系数不得解释为领域之间的替代或互补，子集之内也只支持方向性陈述而非定量替代率：正则强度增减一个数量级时稳定子集大小在 80 与 125 之间变动，逐项解释因此不可靠。

目标口径本身需要声明。主目标以配比加权各域的损失，配比同时出现在等式两侧，存在部分循环；本节仍以其为主口径，是其训练 R^2（0.8958）远高于简单平均口径（0.2962），后者自身不是可主报的口径（1B 去偏 R^2 为 -8.667），只作方向对照。两个口径下域效应的量级排序实质相反，系数向量的 Spearman 相关为 -0.5809，故下文关于域效应量级的排序均以加权目标口径为前提。

质量评分是否应引入配比模型，由一次嵌套检验回答：在 17 维配比之上加入域级 Q 按配比加权得到的语料质量项，比较同一子集上的去偏 R^2。表 4.4 下半部分与图 4.4(b) 给出结果，三个尺度的增量为 $+0.00028$、-0.00022、-0.00082，95% 区间均含零，无可检出的增量。成因是构造性的：Q_{corpus} 本身是 $\boldsymbol{p}$ 的函数，17 个配方域中只有 6 个能对应到质量域，映射域的配比质量中位数仅 0.5995；512 个训练行中 5 行在映射域上配比质量全为零，已剔除，两个模型在其余 507 行上拟合与评估，条件数由 60.98 升至 86.07。向一个已含 $\boldsymbol{p}$ 的模型再放进 $\boldsymbol{p}$ 的函数，增量无从产生。判定条件须一并给出：1B 尺度只有 64 个观测，其增量上界仅 $+1.5 \times 10^{-5}$，与自助重抽样的蒙特卡洛波动同量级；把该格的自助次数提高后，$B_{\text{boot}} = 4000$ 与 $B_{\text{boot}} = 40000$ 各跨 8 个独立种子均一致给出含零的区间，而 $B_{\text{boot}} = 400$ 下上界极差为 1.40×10^{-4}，高于上界离零的距离约 5×10^{-5}。故「三尺度区间均含零」成立，

条件是 $B \geq 4000$ 且 $n = 64$；四个不同质量来源的同类检验中，12 个「来源 × 尺度」格子有 11 个区间含零。

表 4.4：配比模型的跨尺度验证与质量评分的增量检验。上半部分为两个模型在三个尺度上的去尺度偏移 R^2、秩相关，以及基线模型的原始 R^2 与偏差占均方根误差之比；下半部分为在 17 维配比之上引入域级 Q 后的去偏 R^2 与增量区间（$B_{\text{boot}} = 400$，「仅 p」与「$p+Q$」在同一 507 行子集上拟合与评估）。增量与区间端点保留五位小数，1B 尺度区间改以科学计数法书写以保留其有效数字。

(a) 跨尺度验证（R^2 已去尺度偏移）

尺度	M_{0c} R^2	M_{1c} R^2	R^2 增益	M_{0c} 秩相关	M_{1c} 秩相关	原始 R^2 / 偏差占比
1m	0.9131	0.9834	$+0.0703$	0.9531	0.9903	0.9130 / 0.035
60m	0.7706	0.7656	-0.0050	0.9221	0.9018	-8.412 / 0.988
1B	0.7047	0.6583	-0.0464	0.8872	0.8488	-173.115 / 0.999

(b) 引入域级 Q 的增量检验

尺度	仅 p	$p+Q$	增量	95% 区间		显著
1m	0.9129	0.9132	$+0.00028$	$(-0.00022,$	$+0.00080)$	否
60m	0.7716	0.7714	-0.00022	$(-0.00066,$	$+0.00013)$	否
1B	0.7075	0.7067	-0.00082	$(-2.06 \times 10^{-3},$	$+1.5 \times 10^{-5})$	否

4.6 局限与适用范围

方向表不是数据自带的信息：《数据说明》未给出 22 个指标的方向标注，该表由本节依据字段定义、指标间一致性与原文抽样推得，并按可信度分层（证据可直接核验者 8 项、由字段定义与指标间一致性推证者 11 项、方向待定者 3 项）；待定的三项恰为长度类指标，凡以该三项为承重项的读数都以本节的裁定为前提，并另报方向替换下的敏感性。A18 的文本统计量由本节自行计算，与 A1–A3 中数据集自带的模型打分不同源，两者只能作趋势与秩一致性的对照，绝对值不可比。

质量侧的结论各有边界。领域序的最高一档 $\{\text{arxiv}, \text{c4}, \text{commoncrawl}\}$、c4 优于 commoncrawl 与 github 居末在基线与分组扰动下均成立；arxiv 是否居首依赖 V/P 分组中个别列的单列归属，本节不作断言。book 域的 171 条样本使该域的域级 Q 带有宽区间，下游使用须附敏感性。单一标量评分无法同时做到跨域可比与域去混淆，是这批指标的性质所决定的可证限制，而非本节规格的缺欠；主口径 Q 与 log 词数 的 Spearman 相关为 0.499，即该标量本身仍带长度暴露，跨域可比同样受各域长度分布约束。相应地，本文对领域间的质量比较只在最高一档的集合层面作出，稳定子集之外交互系数不作解释，域效应的量级排序以配比加权目标口径为前提。

配比侧的读数是样本条件的结果：训练行只有 512 行，损失域只有 13 个，153 个二阶交互特征在该样本量下大部分不可辨识，增益集中于最小尺度也就不难理解。A12–A15 为外推表或训练集子集；其中外推表（A12、A14）的配比行与训练集的重叠率为 1.0，只能检验损失的外推而不能检验配比的泛化，故本节未用它们支持任何定量结论。质量评分的增量检验为零结果，成因是质量项与配比的构造性相关，而非质量信息无用；在本数据条件下，该检验无法把「质量是否有用」与「质量项能否在已含配比的模型中被辨识」分开。三项稳健性检验的结果性质不同：分组扰动是一项真发现，它使领域序的表述被收窄；1B 尺

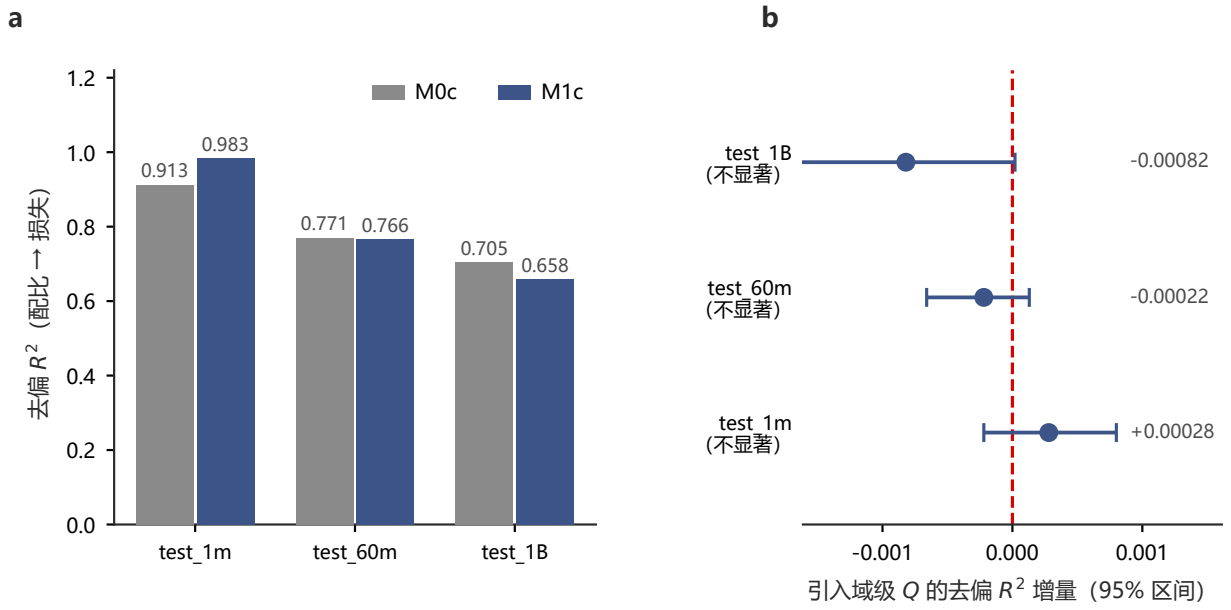


图 4.4：配比模型的跨尺度表现与质量评分的增量。(a) 三个尺度上两模型的去尺度偏移 R^2，1m 尺度上二阶交互模型 0.983 高于线性模型 0.913，60m 与 1B 两尺度上两者互有高低；(b) 引入域级 Q 后去偏 R^2 的增量与 95% 自助区间，三条区间均跨过零线（虚线），1B 尺度的上界仅 $+1.5 \times 10^{-5}$。

度的增量检验反映自助次数不足，该格在 $B_{\text{boot}} = 400$ 下不可判定；目标口径替换检验则判据设计失效，其预声明判据为两口径下系数符号的一致率，而目标取损失、设计矩阵去截距且配比之和为一，每个系数即该域的损失水平，17 个系数必然同号，一致率 1.000 是平凡结果，不构成证据；该检验真正提供信息的是系数向量的排序反转（Spearman -0.5809），它支持的是一条限制，即域效应的量级排序依赖目标口径。

5　问题二的建模与求解

在问题一给出数据质量评分 Q 与领域配比 $\boldsymbol{p}$ 之后，问题二需要把它们纳入同一损失模型。本节先陈述广义标度律的形式及其设计约束，再说明数据条件所决定的参数辨识顺序；随后依次报告三项预声明判据、质量指数的双路线结论、边际效用与等价条件，以及域间关系与跨源迁移验证。全节数值取源工件的落盘精度：参数与指数在正文中保留四位小数，需与落盘表格逐位对照处保留八位，凡作四舍五入均在相应位置说明。

5.1　广义标度律的形式与设计动机

经典标度律把损失分解为不可约项、容量项与数据项之和，见式 (1.1)。数据质量与领域配比并不显式出现在其中，而二者恰是当前语料工程的主要着力点。把质量作为独立加性项追加到 (1.1) 是最自然的写法，但这样会破坏一项形式约束：当质量取参照值、配比取均匀时，模型不应残留任何与二者有关的分量。本文因此采用乘性进入方式，把质量与配比都并入数据量项，得到

$$L = E_s + A\,N^{-\alpha} + B\left(D\,Q^{\gamma}\exp(\boldsymbol{b}^{\top}\boldsymbol{z}_{\boldsymbol{p}})\right)^{-\beta}, \tag{5.1}$$

其中 E_s 为来源专属的不可约损失，$D_{\text{eff}} = D\,Q^{\gamma}\exp(\boldsymbol{b}^{\top}\boldsymbol{z}_{\boldsymbol{p}})$ 为有效 token 数（effective token count），$\boldsymbol{z}_{\boldsymbol{p}}$ 为配比相对均匀配比的中心化偏离。当 $Q = 1$ 且 $\boldsymbol{z}_{\boldsymbol{p}} = \mathbf{0}$ 时，$Q^{\gamma} = 1$、$\exp(\mathbf{0}) = 1$，式 (5.1) 逐项退化为式 (1.1)。这一退化性质是形式设计的硬约束，也是后文判

据 1 的直接检验对象。

两种进入方式的语义并不相同，这是选择乘性写法的实质理由。Q^{γ} 表示质量对有效数据量的放大或折损，指数 γ 刻画放大是否按比例：$\gamma = 1$ 时质量翻倍等价于 token 数翻倍，$\gamma < 1$ 时质量的边际作用递减。在数据受限条件下，重复使用同一批 token 的收益会随重复次数衰减，该效应正是通过把重复次数折算为有效 token 数来刻画的 [3]；数据修剪按信息量排序后保留子集，其效果同样可理解为改变了有效数据规模 [15]。领域配比则经 $\exp(\boldsymbol{b}^{\top}\boldsymbol{z}_{\boldsymbol{p}})$ 进入，$\boldsymbol{b} = (b_1, \ldots, b_{17})$ 由问题一配比模型的系数 θ_d 经中心化得到，即 $\boldsymbol{b} = \kappa(\boldsymbol{\theta} - \bar{\theta})$，其中 $\kappa < 0$。中心化的作用有两个：均匀配比成为零点，从而与退化条件相容；同时 $\boldsymbol{b}$ 的整体标度被吸收进系数 B，使比值 b_i/b_j 不依赖该标度，这一点在域间比较中会直接用到。在 B6 半合成网格上，本文另比较了质量的乘性与加性两种规格，二者的 RMSE 相对差为 0.035382，低于 10% 的可区分阈值，数据本身无法在二者之间作出选择。本文据此依形式约束选择乘性写法：加性形式在 $Q = 1$ 处残留一项独立衰减，与退化要求不相容。加性形式作为备用规格保留，其触发条件为 γ 的区间含零或 B7 上不优于基线；本轮两条条件均不成立，该规格保持休眠。

幂律形式本身的普适性不宜预设。已有工作指出标度指数并非先验常数，其取值与数据流形的内在维度和目标的分解方式有关 [18]，因此本文不把 α、β 视为已知常数，而作为待估参数并给出重抽样区间。图 5.1 给出本问的建模与求解流程：多源数据整备、退化检验、参数辨识（联合拟合）、跨源验证与条件化检验五个环节依次衔接，末一环节由参数共享假设的检验结果触发。

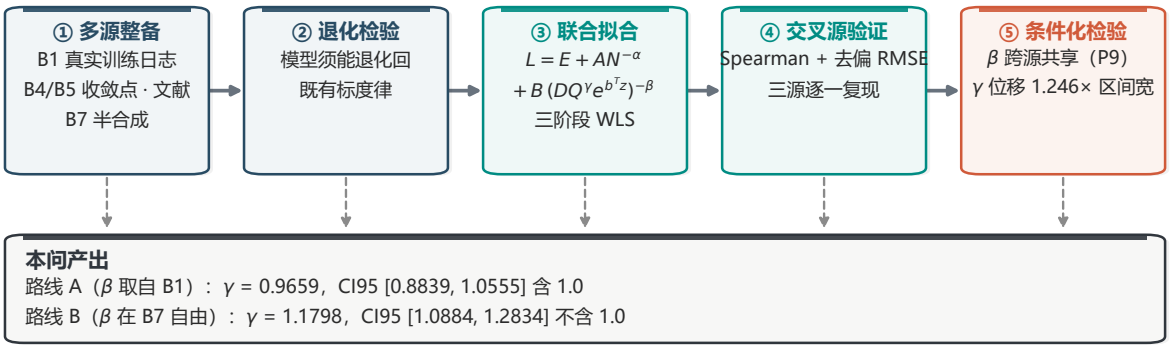


图 5.1：问题二的建模与求解流程。上排五个环节依次为多源数据整备、退化检验、参数辨识（联合拟合）、跨源验证与条件化检验，下方汇文本问在质量指数上的两条路线结论及其区间，两路线的差别仅在于数据量指数的来源假设。

单位方面，N 与 D 均以十亿计，损失以 nats/token 计，Q 无量纲且取值于 $(0, 1]$。数据量的量纲被系数 B 与不可约项 E_s 吸收，二者的数值随单位选择而变，全文固定以十亿为单位报告。

5.2 数据条件与参数辨识顺序

可用数据对参数的支撑并不均衡，这直接决定了估计策略。B1 为 Pythia 的真实训练轨迹 [10]，含 1176 行记录、8 个参数量取值，数据量跨 0.1–299.9B，是附件中唯一同时含有 N、D 变化且来自真实训练的轨迹。质量因子的信息则只存在于 B6–B8 三个因子设计网格，三者均为半合成数据，其中 B7 含质量取值 10 个、记录 450 行、参数量取值 9 个、数据量仅 5 个不同取值。该网格兼具质量变化与半合成两重属性，凡建立在其上的结论都带补充分析的性质。

上述分布造成一项结构性限制：B1 上 $Q \equiv 1$，对 γ 不提供任何信息；B7 上质量在设计网格内变动，但数据量只有 5 个不同取值，且与参数量在设计上相互纠缠。换言之，数据量指数与质量指数无法在同一份数据上同时获得良好辨识。本文因此固定估计顺序：先由真实轨迹 B1 反解数据量指数 β，再在 B7 上以该 β 反解 γ，而各来源的形状参数分别独立估计。该顺序的代价是 γ 的精度部分继承自 β，本文把这一依赖作为独立的可检验命题处理，结果见 §5.4。

表 5.1：广义标度律与基线的参数估计（N、D 以十亿计，损失以 nats/token 计）

参数	基线 M0s（B1）	主方法 M1s（B1 侧）	主方法 M1s（B7 侧）
E_s	1.68979756	1.68979741	1.65423173
A	0.35398032	0.35398032	0.52912380
α	0.33997658	0.33997658	0.28321756
B	1.24030558	1.24030577	1.05387051
β	0.27987813	0.27987806（跨源共享）	
γ	—（不含质量项）	—（B1 上 $Q \equiv 1$）	0.96591294

表 5.1 列出两套参数与基线。基线 M0s 取经典形式 (1.1) 并仅用 B1 拟合。主方法与基线在 B1 侧的形状参数在数值上近乎重合：A 与 α 逐位相同，E_s 与 B 的相对差约 10^{-7}，差异仅出现在第八位有效数字，其原因是质量项与配比项在 $Q = 1$、$\boldsymbol{z_p} = \mathbf{0}$ 处恰取单位元。B7 侧的形状参数与 B1 侧差异明显：A 的比值为 1.4948，B 为 0.8497，α 由 0.33997658 变为 0.28321756。形状参数能否跨源共享因此需要单独检验。强制 A、α、B 跨源共享，会使 γ 位移 0.169104，即其重抽样区间宽度的 0.9850 倍，远超预声明的 50% 阈值，共享在 B7 上另带来 0.015493 的 RMSE 代价。本文据此把形状参数设为来源专属，并如实报告这一结构的后果：在来源专属的形状参数下，加权最小二乘的联合求解在数值上退化为「由 B1 定 β、由 B7 定 γ」的两段式，实测两段式解与联合解在 γ 上相差 1.03×10^{-7}、在 β 上相差 6.86×10^{-8}。权重机制被完整实现，但在该参数结构下不产生可分辨的修正，因此本节不以联合拟合作为估计精度的来源。

分层权重由各来源的拟合残差估计，得 $\sigma_{B1} = 1.465 \times 10^{-4}$、$\sigma_{B7} = 0.076384$，逐点权重比为 3.678×10^{-6}，B7 在联合目标中的总权重份额为 1.408×10^{-6}。需要说明，本轮的分层权重取残差口径，该选择尚未经独立确认；其消融检验（改用另一锚点口径）给出 γ 的位移为 0.000341，小于区间宽度，故结论对权重口径不敏感。

5.3 三项预声明判据与判据的替换

主方法的评价不以拟合优度的直观好坏为准，而以实验前声明的三项判据为准，阈值、实测与结论列于表 5.2。

判据 1 检验退化性质。在 B1 上，主方法与基线的 RMSE 相对差为 1.0122×10^{-8}，低于 10^{-6} 阈值，该量级表明二者的差异已落进数值精度。此处须辨明该判据的角色：它检验的是 $Q = 1$、$\boldsymbol{z_p} = \mathbf{0}$ 时模型是否退回经典形式，而不是主方法相对基线的性能比较。在 B1 上二者本应同形同自由度，任何性能差异都不构成改进的证据，该判据的双重作用在于它同时也是题目所要求的退化性质的依据。

判据 2 检验超越性，在 B7 上进行。不含质量项的基线在该网格上的 RMSE 为 0.118252，主方法为 0.076384，降幅 0.041868，自助 95% 区间 $[0.036236, 0.047781]$ 不含零。该比较的两个对象在 B7 上各自设有来源专属截距，这是不可约损失不可跨源共享的机械后果；若改用 B1 的截距预测 B7，截距失配会被计入质量通道的贡献。判据 3 检验弹性（elasticity）

表 5.2：三项预声明判据的阈值、实测值与结论

判据	预声明阈值	实测	结论
1 退化检验（B1）	RMSE 相对差 $< 10^{-6}$	1.0122×10^{-8}（基线 0.0001464960899 对主方法 0.0001464960914）	通过
2 超越性（B7）	RMSE 降幅的自助 95% 区间不含零	降幅 0.041868，区间 $[0.036236, 0.047781]$（由 0.118252 降至 0.076384）	通过
3 弹性符号	三个弹性均为负	B1 侧与 B7 侧均成立	通过

符号：$\partial L/\partial N$、$\partial L/\partial D$、$\partial L/\partial Q$ 在 B1 侧与 B7 侧均为负，与「增加任一资源要素都降低损失」的机理一致。

判据的形式在代码生成之前经过一次修正，其对象与时序须一并交代。方法卡原预声明的第 1 条判据为「主方法在 B1 留出集上的 RMSE」，但该判据在本数据条件下结构性失效：B1 不含配比列，故 $\boldsymbol{z_p} = \mathbf{0}$、$\exp(\boldsymbol{b}^\top \boldsymbol{z_p}) = 1$；B1 又不含质量变化，故 Q 为常数，Q^γ 并入系数 B。两项叠加，主方法在 B1 上塌缩为与基线同形、同自由度的模型，留出集 RMSE 不可能给出任何关于质量通道的信息。本文因此把第 1 条改为退化检验，把超越性比较移到 B7。该修正发生在代码生成之前，方向是收紧而非放宽：它撤销了原判据本可提供的、形式上更有利但内容为空的比较，并把质量通道的举证责任集中到唯一含质量变化的网格上。该修正的方向与本节其余判据的收紧方向一致，不构成对判据的事后放宽。

5.4 质量指数的双路线结论与参数共享检验

γ 的取值依赖 β 的来源假设，二者不能分开报告。在 B7 的设计刻度上、且 β 取自 B1（0.279878）时，$\gamma = 0.965913$，自助（bootstrap）95% 区间 $[0.883860, 1.055546]$ 含 1.0，据此 $D_{\text{eff}} \approx D\,Q$，质量的相对变化按比例放大有效 token 数。若 β 改在 B7 上自由估计，$\gamma = 1.179781$，区间 $[1.088441, 1.283359]$ 不含 1.0，此时质量的放大作用略强于按比例。两条路线并列见图 5.2。

两条路线的 γ 位移为 0.213868，等于其自助区间宽度的 1.245692 倍，超过预声明的 0.5 阈值，故「β 可跨源共享」这一假设在本文判据下未获通过；与之相伴，两条路线的 β 互不覆盖：B7 自由估计给出 0.083064（区间 $[0.054791, 0.119420]$），而 B1 的 $\beta = 0.279878$ 落在该区间之外。放开 β 还使 B7 的 RMSE 由 0.076384 降到 0.069544，改善约 9%，说明共享 β 是一项真实约束而非平坦方向。

本文仍取 B1 的 β，理由是辨识强度：B1 的 β 区间宽度仅 1.163×10^{-4}，其 1176 行数据的数据量跨 0.1–299.9B；B7 只有 5 个不同的数据量取值，且与参数量在设计上纠缠，β 的独立辨识条件明显更弱。该理由只说明当前取值在估计效率上的依据，并不构成上述检验未发生的理由。该检验未通过这一事实意味着 $\gamma \approx 1$ 是条件性结论而非无条件实测结论，下文凡含 γ 的量都继承该条件。另一种规避条件性的做法是改报乘积 $\beta\gamma$，但条件性并不会因此消失：按两条路线各自的 β 与 γ 计算，该乘积分别为 0.2703 与 0.0980，相差 2.76 倍，其路线依赖比 γ 本身更强，故本节不作此替换。

5.5 边际效用、弹性与等价条件

在同一参照点 $N = 1.0$B、$D = 150.0$B、$Q = 0.5$ 上计算偏导与弹性，结果列于表 5.3。两侧同报是因为数据的支撑性质不同：$\partial L/\partial N$、$\partial L/\partial D$ 及其弹性可由 B1 的真实轨迹支撑，而含 γ 的量（$\partial L/\partial Q$、质量弹性、替代率与等价补偿量）不可避免地依赖半合成网格 B7。

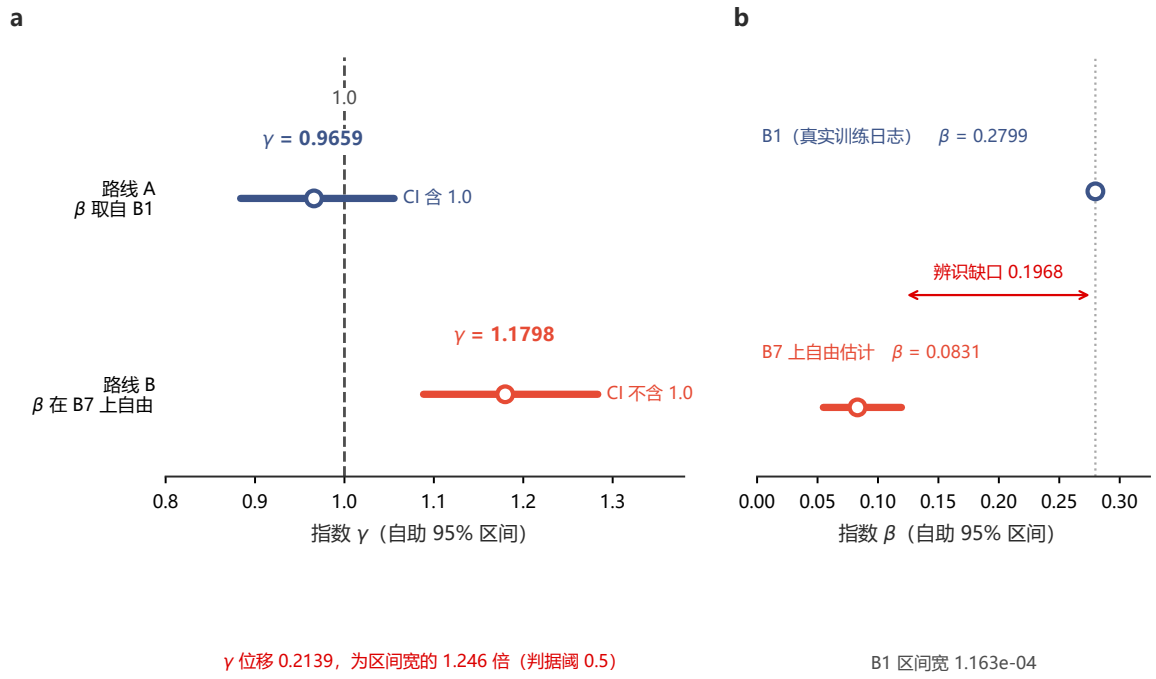


图 5.2：质量指数 γ 的两条路线与数据量指数 β 的辨识缺口。(a) 路线 A（β 取自 B1）与路线 B（β 在 B7 上自由估计）的 γ 点估计与自助 95% 区间，虚线为 $\gamma = 1$；两条区间的交叉与否决定了有效 token 数是否按比例放大。(b) 两条路线下 β 的估计与区间，二者的区间不重叠。横轴为指数取值，纵轴为路线。

两侧量级的相对差为 15.0%–31.8%，该差可视为配比与质量的效应形状跨来源迁移这一假设的代价的量化。

题目要求的等价条件以「质量增加 0.1 所需的参数量补偿」表达。在给定参照点下，B1 侧为 -0.134101B，B7 侧为 -0.094469B；符号为负表示提高质量可以减少所需参数量。该量必须与参照点一同理解：偏导随位置变化，脱离参照点的量级没有意义。就量级而言，该结论与语料治理的已有证据方向一致：在大规模网络语料上做质量筛选后，同等训练预算下的损失明显低于未筛选的对照，筛选带来的收益可与扩大数据规模部分互换 [12]。

弹性之间存在一条恒等式，它决定了哪些替代关系可以谈。在 $D_{\text{eff}} = D\,Q^{\gamma}$ 的设定下，质量弹性与数据量弹性之比恒等于 γ，两侧相对差为 0.0000，实测极差小于 10^{-12}，即该比值随位置保持不变，它只是 γ 的另一种读法。因此在本文模型下，随位置变化的只有 Q 与 N 之间的替代率；Q 与 D 之间的替代率是常数。这一区分影响解读：以质量替换数据量本身不存在位置相关的换算关系，而以质量替换参数量则存在。

5.6 域间关系与跨源迁移验证

$\boldsymbol{b}$ 的绝对量级在附件 B 上不可辨识，实测 RMSE 随标度常数 κ 的变化恰为零。本节因此只报各域相对参照域 `train_the_pile_philpapers` 的比值与符号，17 个域的取值见图 5.3。参照域取值为 1.000000，其损失水平最高；`dm_mathematics` 为 -1.618816，是全表唯一 $|b_i/b_{\text{ref}}| > 1$ 的域；其余 15 个域的绝对值均不超过 1。该比值的语义需要说明：它是中心化权重之比而非有界比例，负值只表示上调该域会降低损失，与参照域方向相反，不能读作损失本身为负。这 17 个域的划分以 Pile 语料的领域定义为基础 [17]，其相对排序与领域间配比优化的已有观察方向一致：领域之间存在结构性差异，最优权重取决于领域的语言性质与目标任务的匹配程度，故配比在较小尺度上的回归预测 [6] 与训练过程中的动态调整 [7] 都以图 5.3 给出的域间排序为共同前提。

表 5.3： 参照点 $N = 1.0\text{B}$、$D = 150.0\text{B}$、$Q = 0.5$ 处的边际效用、弹性与等价条件

量	B1 侧（主）	B7 侧（敏感性）	相对差
$\partial L/\partial N$	-0.120345	-0.149857	0.2452
$\partial L/\partial D$	-0.000687	-0.000583	0.1503
$\partial L/\partial Q$	-0.198978	-0.169069	0.1503
N 的弹性	-0.120345	-0.149857	—
D 的弹性	-0.103000	-0.087518	—
Q 的弹性	-0.099489	-0.084534	—
$Q \to N$ 替代率	-1.653397	-1.128200	0.3176
Q 增 0.1 的 N 补偿量/B	-0.134101	-0.094469	0.2955
Q 弹性与 D 弹性之比	0.96591294	0.96591294	0.0000

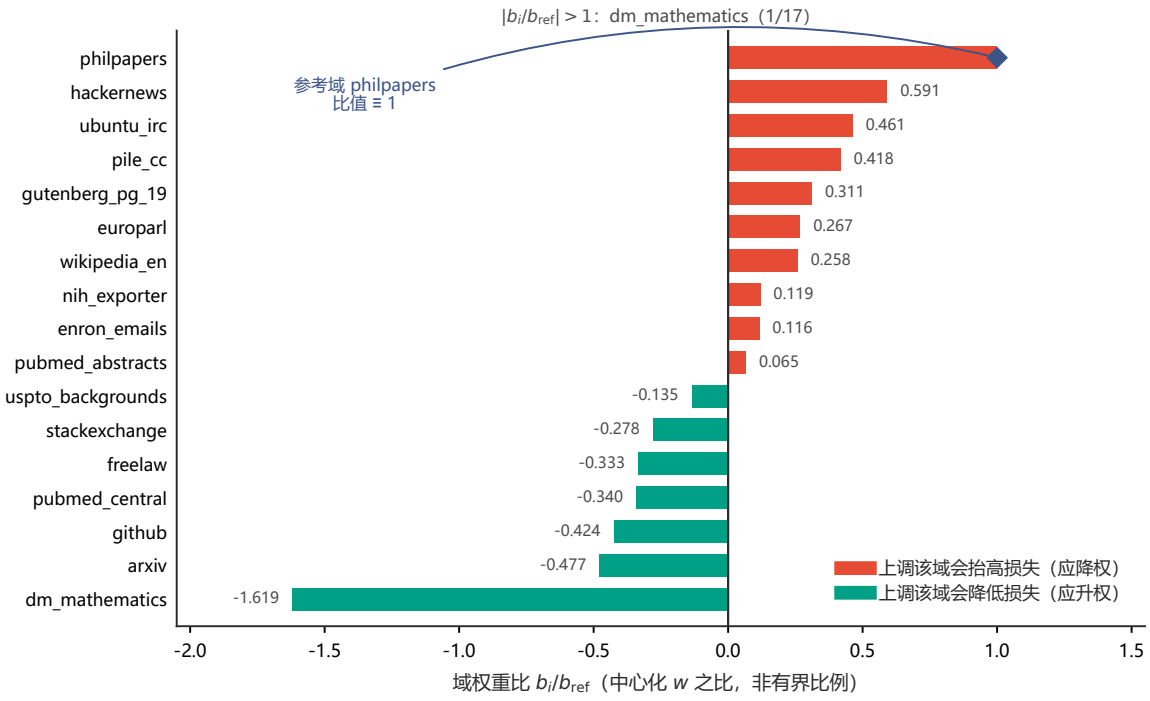


图 5.3： 17 个训练领域相对参照域 `train_the_pile_philpapers` 的权重比 b_i/b_{ref}，按取值降序排列。横轴为中心化权重之比（非有界比例），纵轴为领域名；正负分别对应上调该域会抬高与降低损失。`dm_mathematics` 为唯一绝对值超过 1 的域。

若要把 $\boldsymbol{b}$ 与 N、D、Q 放在同一绝对尺度上比较，则需要引入 κ，而 κ 的取值随参照点变化：在 B1 的 1B 尺度运行内即从 -14.215132 变到 -1.6413，相差 8.7 倍。敏感性臂在数据量参照点 299.893B 上给出 $\kappa = -14.215132$、$\boldsymbol{b}$ 的取值范围 $[-21.626478, 35.009297]$，以及把最低权重域调到最高权重域一个百分点所对应的损失变化 0.039842。这些绝对量级只在对应参照点上成立，不存在普适取值。更准确的表述是：$\boldsymbol{b}$ 内部相比与 κ 无关，$\boldsymbol{b}$ 与 N、D、Q 相比则一定含 κ，这正是配比的绝对效应无法跨源辨识的精确含义。

跨源迁移验证在三个外部来源上独立进行，结果见图 5.4（a）。B4 为跨模型族的收敛点，属真实观测，$n = 57$，去源偏后的秩相关（rank correlation）为 0.982982；B5 为文献报告的标度律数值，属他人发表而非本队观测，$n = 44$，秩相关为 0.958808；B2 为经真实数据校准并注入噪声的半合成轨迹，$n = 1029$，秩相关为 0.788102。三者的去源偏 RMSE 分别为 0.192657、0.199662 与 0.418526。各来源的不可约损失差异悬殊，逐源拟合的 E_s 极差达 1.689798，故跨源未去偏的决定系数没有解释意义，本节只报秩相关与去源偏 RMSE。其中 B2 的秩相关建立在半合成轨迹之上，不构成直接观测的迁移验证；B5 的数值来自已发表文献，与本文实测结果的性质不同。图 5.4（b）另给出各边际效用两侧取值的对照，其中 Q 通道的量明确依赖半合成网格，符号一致性是它们可以承担的全部结论。

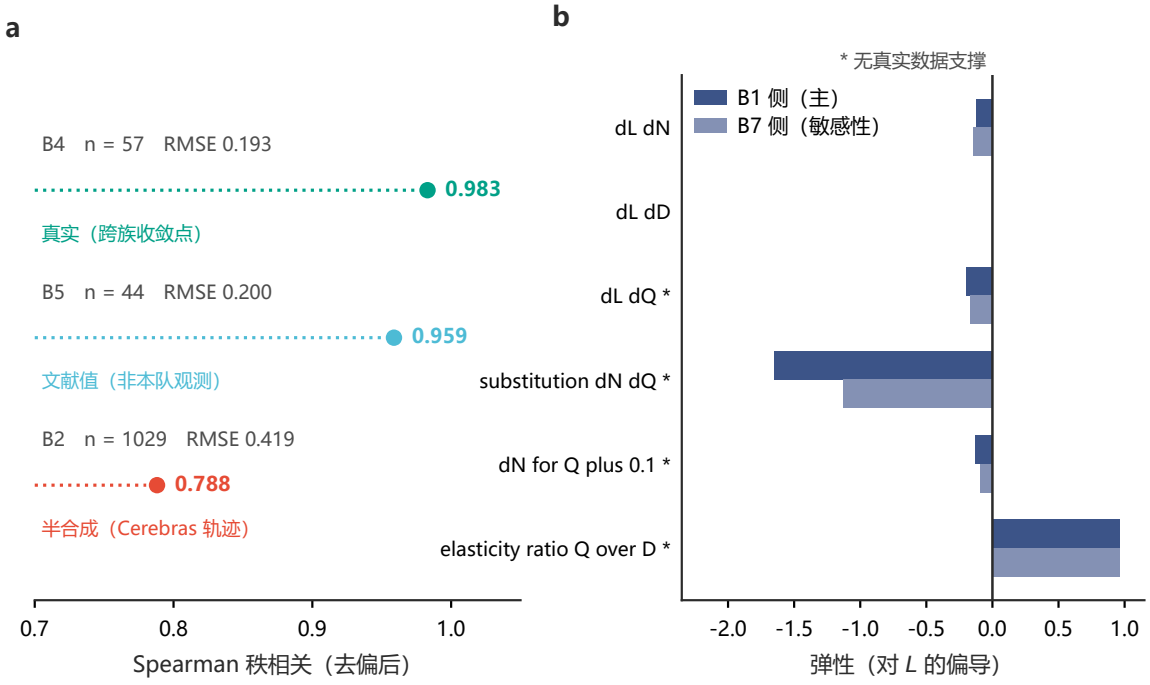


图 5.4：跨源迁移验证与弹性对照。(a) 三个外部来源的去源偏秩相关：B4（真实收敛点，$n = 57$）、B5（已发表文献值，$n = 44$）、B2（半合成轨迹，$n = 1029$），点旁标注各自的去源偏 RMSE，横轴为 Spearman 秩相关。(b) 各边际效用在 B1 侧与 B7 侧的取值对照，星号标出无真实数据支撑、依赖半合成网格的量，横轴为对 L 的偏导。

余下是三项必须在结论中携带的限制。其一，配比效应的可迁移性无法在本数据上检验：全部 11 个 B 类文件中无一含配比列（0/11），因而不存在配比列与 (N, D) 的联合读数；问题一的三个训练尺度中也只有一个落入 B1 的参数量区间 $[0.070542, 11.965825]$B。该假设承重且不可检验，本问关于配比的全部结论都在其下成立。其二，质量刻度的对齐尚未解决：问题一给出的经验域级质量落在 $[0.223306, 0.381496]$，而 B7 的设计网格取值为 $\{0.1, 0.2, \ldots, 1.0\}$，二者不是同一对象。本文不对二者作隐式映射，$\gamma$ 的数值解释因此绑定在 B7 的设计刻度上，不能直接代入问题一的经验质量。其三，B7 的生成过程与质量因子之间是否存在循环性尚未核验，该不确定性一并声明，不影响上述形式结论，但影响 γ 的

绝对解释。

另需说明的是，B1 侧的拟合异常干净，$R^2 = 0.9999998$、RMSE $= 1.465 \times 10^{-4}$，对真实训练日志而言并不寻常。本文对该数据的处理附有一项谨慎要求，相关核验尚未完成，故以 B1 为一侧参照的结论须在该要求下理解。扰动检验显示结论对 B1 权重的依赖有限：把 B1 在联合目标中的整体权重在 0.5 至 2 倍之间变动，γ 的最大位移为 0.039812，约为其区间宽度的 23%；逐组留一数据量分组的 β 极差为 3.535×10^{-5}，小于其区间宽度。这并不替代对 B1 处置方式的判断，只是说明本文结论对该处置不敏感。

6 问题三的建模与求解

问题三把问题二给出的广义标度律由描述工具转为决策工具：N、D、Q 成为待定配置量，损失在算力约束下被最小化。约束一侧要写出三个资源要素各自的算力代价，结论一侧要回答结构性转移是否存在；后者的困难在于「结构」的数学化并不唯一，同一组最优解路径用不同判据去读会得到不同答案。以下依次给出优化模型与分段 KKT 解、锚点解与最优性核验、三种转移定义、成本函数与上下文长度的敏感性、与基线的对照以及配比的边际方向。全节数值一般保留四位小数，转移位置、隐含比值的漂移指数以及残差、预算违反量与乘子另给更多位数。

6.1 优化模型与成本结构

在配比偏离取零（$\boldsymbol{z_p} = \mathbf{0}$）的配置下，由式 (5.1) 得本问的优化问题

$$\min_{N,D,Q} \; E + A\,N^{-\alpha} + B\,(D\,Q^{\gamma})^{-\beta} \qquad \text{s.t.} \qquad k\,ND + D\big[g(Q) - g(Q_0)\big]_+ \le C, \quad Q_0 \le Q \le 1, \tag{6.1}$$

其中 $k = 6 + \eta L_{\text{ctx}}$，约束左端即三项算力开销：训练开销 $C_{\text{train}} = 6ND$、注意力开销 $C_{\text{attn}} = \eta N D L_{\text{ctx}}$ 与质量提升开销 $C_Q = D[g(Q) - g(Q_0)]_+$，前两项合并为 kND。该族模型最初的用途是在参数量与数据量之间分配算力 [1]，本问在其上增加了质量与上下文长度两个成本通道。

三项开销的缩放性质并不对称：C_{train} 与 C_{attn} 随 N、D 同时缩放，C_Q 只随 D 缩放。由此 $C_Q/C_{\text{train}} = \Delta g/(6N)$ 只随 N 反比，质量投入的预算份额随 N^* 增大而被压缩；而 $C_{\text{attn}}/C_{\text{train}} = \eta L_{\text{ctx}}/6$ 与 N、D、Q 无关，上下文长度的影响因此不落在两个规模变量之间的相对配比上。单位约定为：规模项 N、D 以十亿为单位，成本项取绝对量纲（参数量与 token 数分别乘以 10^9，Δg 亦然），故 $C_{\text{train}} = 6N_BD_B \times 10^{18}$ FLOPs；下文公式中的 kN、N_{abs}、D_{abs} 均指绝对量纲。

配比 $\boldsymbol{p}$ 不作寻优变量。它经 $\exp(\boldsymbol{b}^\top \boldsymbol{z_p})$ 线性进入有效 token 数，在单纯形约束下线性目标的最优解必落在顶点;建模阶段单独求解该角点问题,实测最大分量为 0.9999999999999927（全部分给 `dm_mathematics`），已退化到数值精度以内。把配比联立只是重复该角点答案，且该答案对不可辨识的标度常数 κ 敏感。本问据此固定配比，决策变量为 (N, D, Q) 三个，KKT 驻点条件也是三个；领域边际方向在 §6.7 另报。

形状参数全部取自问题二的 B1 侧估计（表 5.1）：$E = 1.6898$、$A = 0.3540$、$\alpha = 0.3400$、$B = 1.2403$、$\beta = 0.2799$、$\gamma = 0.9659$。B1 为 Pythia 的真实训练轨迹 [10]。摘取时逐项核对，最大相对差小于 10^{-15}；截距另行复核，其 B1 侧与 B7 侧取值之差超过 10^{-3}，不存在误取。γ 由附件 B7 的半合成网格反解，含 γ 的读数带补充分析的性质。

题给的三类质量成本函数为指数型 $g = 10^7\mathrm{e}^{6Q}$、幂函数型 $g = 5 \times 10^9 Q^4$ 与对数渐进型 $g = 2 \times 10^9 \ln(1 + 10Q)$。前两者的 $g'(Q)$ 无界递增，对数渐进型的 $g' = cr/(1 + rQ)$ 单调递减并以 c 为上界；这一差别既决定式 (6.3) 下最优质量的取值，也是成本函数敏感性的来源。求解流程见图 6.1，三档锚点取 $C = 10^{19}$、10^{22}、10^{24} FLOPs。

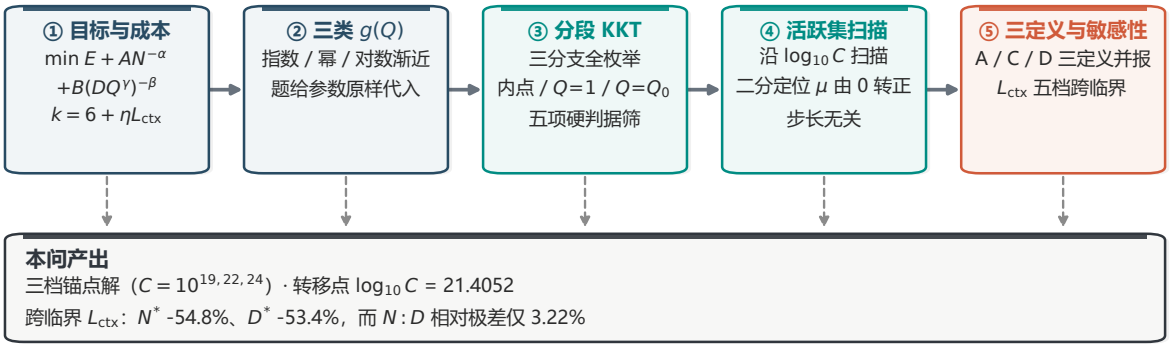


图 6.1：问题三的建模与求解流程。上排五个环节依次为优化目标与成本结构、三类质量成本函数、三分支分段 KKT 求解、沿预算的活跃约束集扫描与转移定位、成本函数与上下文长度的敏感性；下方为本问产出，其中跨临界一行的两个百分数为 L_{ctx} 由 2048 增至 131072 时的规模变化幅度。

6.2 分段 KKT 约减与解析结构

内点一阶条件不能覆盖全部情形：预算充裕时，质量的内点最优会被推过上界 $Q = 1$。实测比例比预期更极端，9 个「预算档 × 成本函数」组合中最优落于内点（$Q_0 < Q^* < 1$）的只有 2 个，即 $C = 10^{19}$ 档的指数型（0.6460）与幂函数型（0.5390），其余 7 个位于上界 $Q^* = 1$。故本问枚举三个分支：内点分支、上界分支（$Q = 1$，Δg 成为常数，未知量降为 (N, D)）与下界分支（$Q = Q_0$，$\Delta g = 0$，即问题二的无质量投入配置）；每档取 KKT 判据全部通过且损失最小者。下界分支在三档中均未被选为最优，其在 $C = 10^{19}$ 档的损失与后文诊断配置 M0o′ 逐位相同。

记 $D_{\mathrm{eff}} \equiv DQ^{\gamma}$。内点段由三个驻点条件消元得

$$\alpha A\, N^{-\alpha}\big(kN + \Delta g\big) = \beta B\, D_{\mathrm{eff}}^{-\beta}\, kN, \tag{6.2}$$

$$\gamma\big(kN + \Delta g\big) = Q\, g'(Q). \tag{6.3}$$

式 (6.2) 由 ∂N 与 ∂D 消去预算乘子 λ 得到，可读作单位成本上的边际损失下降在 N 与 D 之间相等。式 (6.3) 由 ∂D 与 ∂Q 相除得到，相除时公共因子 $\beta B D_{\mathrm{eff}}^{-\beta}/D$ 被约去，λ 与 D 一并消失，故该式只含 (N, Q)，不含预算乘子与数据规模。由此得到两条独立核验路径。λ 可由 ∂N 单独解出，

$$\lambda = \frac{\alpha A\, N^{-\alpha}}{k\, N_{\mathrm{abs}} D_{\mathrm{abs}}}, \tag{6.4}$$

该式不含 Q 与 $g'(Q)$，代回 ∂D 即还原式 (6.2)；实测三档 λ 为 2.4671×10^{-20}、7.4101×10^{-24} 与 3.4636×10^{-26}，与由式 (6.2) 独立解出的取值一致。残差方面，$C = 10^{19}$ 档式 (6.2) 与式 (6.3) 的相对残差为 9.29×10^{-15} 与 0.0，后两档式 (6.2) 为 0.0 与 2.11×10^{-16}；后两档落在边界分支上，式 (6.3) 不再是条件（Q 被钉在 1），其位置由 $dL/dQ \le 0$ 与上界乘子非负的互补松弛取代，残差相应缺省。

式 (6.3) 同时给出最优质量上升至饱和的机制：它是关于 Q 的不动点条件，给定 N，仅当 $\gamma(kN + \Delta g(Q))$ 与 $Q\, g'(Q)$ 在 $(Q_0, 1)$ 内有交点时内点解存在。$Q\, g'(Q)$ 在指数型与幂函数型下随 Q 严格递增，右端随 N 上升，故预算增加使交点右移、Q^* 上升，直至交点越过上界而转入边界分支；对数渐进型的 $Q\, g'(Q)$ 以 c 为上界，更早转入上界分支。边界段的乘子印证了分支归属：$C = 10^{19}$ 档为 3.44×10^{-15}，上界不活跃；高两档为 0.0269 与 0.0303，

上界活跃。三档的预算相对违反量为 2.05×10^{-16}、0.0 与 1.34×10^{-16}，远低于预先设定的 10^{-9} 容差。

6.3 锚点解与最优性核验

上下文长度取附件 C7 的基准值 2048，成本函数取指数型，二者在 §6.5 中另行扰动。三档解列于表 6.1。

表 6.1：三档算力预算下的最优配置（$L_{\text{ctx}}=2048$，指数型成本函数；N^*、D^* 以十亿计，预算违反量取相对形式 $(\text{cost}-C)/C$）

量	$C=10^{19}$	$C=10^{22}$	$C=10^{24}$
分支	内点	上界	上界
活跃约束集	预算	预算、$Q\le1$	预算、$Q\le1$
N^*/B	0.2395	5.6475	40.7555
D^*/B	5.1662	249.0624	3771.0380
Q^*	0.6460	1.0000	1.0000
D^*/N^*	21.5727	44.1017	92.5284
损失	3.1468	2.1511	1.9139
C_{train} 份额	0.7423	0.8439	0.9221
C_Q 份额	0.2070	0.0984	0.0149
C_{attn} 份额	0.0507	0.0576	0.0630
预算违反量	2.05×10^{-16}	0.0	1.34×10^{-16}

表 6.1 中有四项结构性读数。最优质量随预算上升并在 $C=10^{22}$ 档触到上界：$C=10^{19}$ 档 $Q^*=0.6460$ 为内点解，高两档为 1.0000；三档并非都落在上界，最低预算档的最优质量明确小于 1。质量投入的预算份额被单调压缩（0.2070、0.0984、0.0149），与 $C_Q/C_{\text{train}}=\Delta g/(6N)$ 的反比关系一致。D^*/N^* 不是常数（21.5727、44.1017、92.5284），随预算单调上升。注意力开销的份额几乎不变（0.0507、0.0576、0.0630），其微弱上升全部来自 C_Q 份额的下降。

外推性质需单独说明：$C=10^{22}$ 档的 N^* 与 D^* 为附件 B1 观测上界（11.965825B 与 299.9B）的 0.4720 倍与 0.8305 倍，仍在实测取值范围之内；$C=10^{24}$ 档为 3.4060 倍与 12.5743 倍，落在观测范围之外，该档读数应读作相同参数下的外推，不构成可靠预测。

最优性以预先设定的五项判据判定：预算相对违反量不超过 10^{-9}、驻点相对残差小于 10^{-8}、互补松弛、乘子非负、变量界。五项在三档锚点上全部通过；另沿 $\log_{10}C$ 由 18.0 到 25.0 以 0.125 为步长取 57 个点扫描，分支枚举与 KKT 判据全部通过。表 6.2 另列三条相互独立的核验与一次重复性检查。

三条核验落在不同环节：中心差分重建不经过分支枚举的代数约减，其边界段的 $\partial L/\partial Q\le0$ 正是上界乘子非负的等价陈述；邻域采样检验局部最优性；差分进化不依赖驻点条件，其与分支枚举解的损失相对差低于 10^{-13}，若枚举不完备，数值解应更优并出现可分辨的落差，实测没有出现。三档锚点解因此可视为式 (6.1) 在给定参数下的最优解，其沿预算的完整路径见图 6.2。

6.4 结构性转移的三种定义与识别

题目要求给出结构性转移的数学定义与识别方法。「结构」的数学化并不唯一，不同的数学化会给出不同的位置，甚至给出相反的存在性判断。

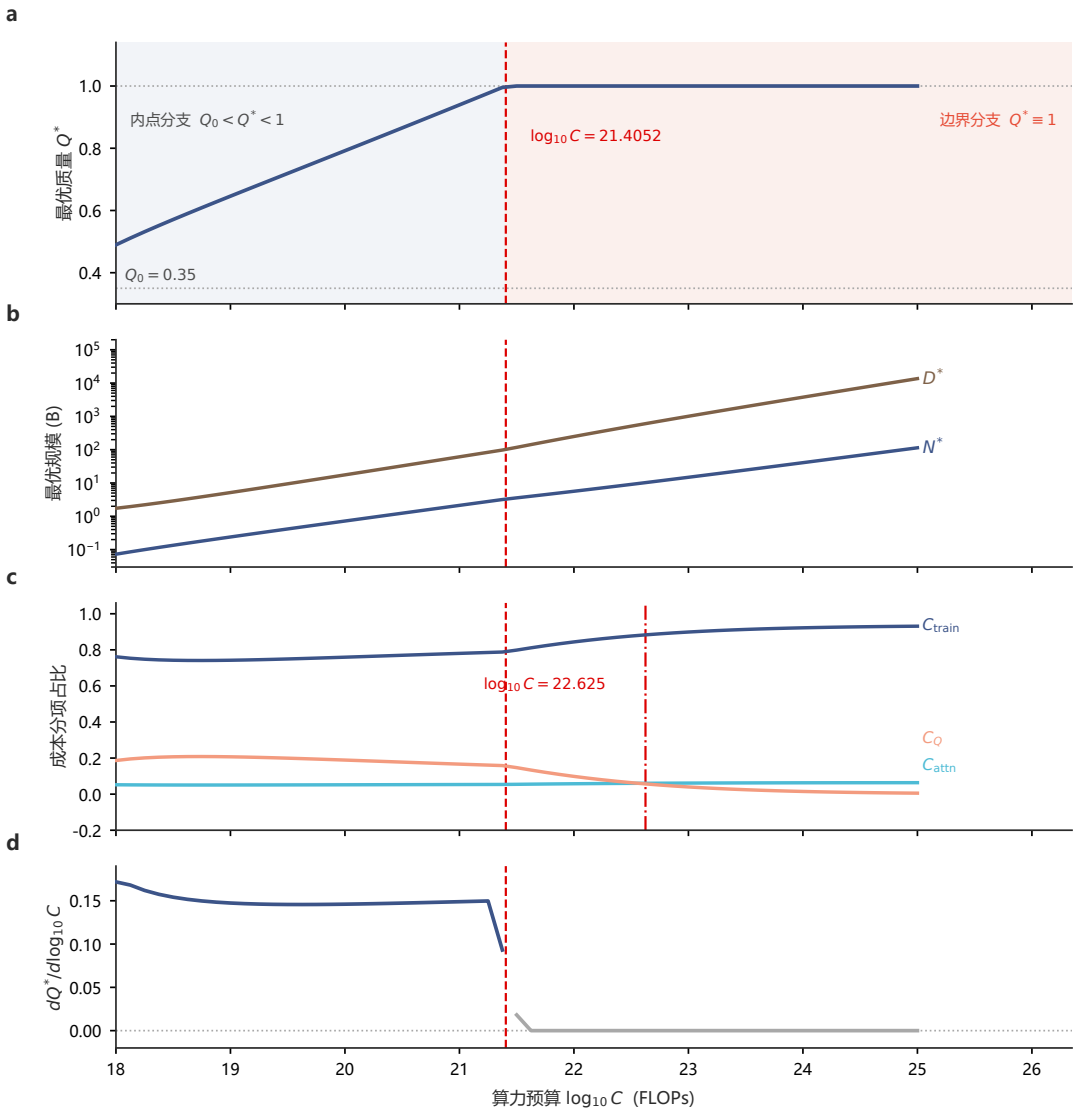


图 6.2：最优配置沿算力预算的路径，四联图共用横轴 $\log_{10} C$（FLOPs，18–25）。(a) 最优质量 Q^*，虚线为 $Q = 1$ 与 $Q_0 = 0.35$，红色竖线为活跃约束集变化的位置 $\log_{10} C = 21.4052$，左右两侧分别为内点分支与上界分支；(b) 最优规模 N^* 与 D^*（B），纵轴为对数刻度；(c) 三项成本占预算的比例，点划线为 C_Q 与 C_{attn} 在 $\log_{10} C = 22.625$ 处的排序翻转；(d) 饱和点附近的导数 $dQ^*/d\log_{10} C$，饱和前约为 0.15，饱和后为零，跨越饱和点的区段以灰线单列。

表 6.2：最优性的独立核验（$\partial L/\partial N$、$\partial L/\partial D$、$\partial L/\partial Q$ 为对拉格朗日函数的中心差分重建结果，差分进化在整个可行域上独立求解同一目标）

核验路径	做法	实测结果
中心差分重建	直接对拉格朗日函数做数值微分，独立重建两个驻点等式，覆盖 9 个「预算档 × 成本函数」组合	$\partial L/\partial N$ 与 $\partial L/\partial D$ 的相对残差均小于 3.3×10^{-8}；内点段 $\partial L/\partial Q=0$，边界段 $\partial L/\partial Q\le 0$
邻域采样	三档锚点邻域各取 4000 个可行点	更优者 0 例
全局数值对照	差分进化独立求解式 (6.1)，与分支枚举解对照	损失的相对差 -1.35×10^{-14}、-2.85×10^{-14}、-6.53×10^{-14}
重复性	同一随机种子下重跑整轮求解	两次运行的输出逐位相同

定义 A 把转移定义为最优解处活跃约束集 $\mathcal{A}(C)$ 的变化。本问中可变的约束元素只有质量的上界 $Q\le 1$，该定义因而等价于问「质量投入是否由内部最优变为顶到上界」。识别方法是沿 $\log_{10}C$ 扫描活跃集与互补松弛乘子 μ，转移点取 μ 由零转正处，实测位置为 $\log_{10}C=21.405181884765625$（区间 $[21.375,21.5]$，二分定位到 10^{-4}），活跃集由「预算」变为「预算、$Q\le1$」。该定义不引入阈值与数值微分，也不依赖扫描步长。

定义 C 把转移定义为成本分项占比的排序变化，实测排序由 $C_{\text{train}}|C_Q|C_{\text{attn}}$ 翻转为 $C_{\text{train}}|C_{\text{attn}}|C_Q$，位置为 $\log_{10}C=22.625$（由 0.125 的网格读出），该点三个份额为 0.8830、0.0567 与 0.0603；该定义不依赖阈值，但位置由步长给出。

定义 D 把转移定义为最优配置的突变，判据为相邻扫描点之间的 $|\Delta Q^*|$ 超过 $\delta=0.05$。实测结论随步长翻转：步长 0.5 时最大 $|\Delta Q^*|$ 为 0.0814、有 7 个点越阈，判为存在；步长 0.25 与 0.125 时为 0.0420 与 0.0215，判为不存在。成因是饱和前 Q^* 光滑上升、斜率稳定在约 $+0.149$，一阶差分约等于斜率与步长之积，与固定阈值比较不是网格不变量。（另一种定义是最优解路径的不可微点，与定义 A 刻画同一事件但需数值微分，故不单列。）

三种定义的结果列于表 6.3，对比见图 6.3。

表 6.3：结构性转移的三种定义与识别结果（δ 为定义 D 的份额突变阈值）

定义	判据	位置 $\log_{10}C$	依赖阈值	依赖步长	结论
A 活跃约束集变化（主）	上界乘子 μ 由零转正	21.405181884765625	否	否	转移存在
C 成本分项占比排序变化	成本分项排序翻转	22.625	否	是	转移存在
D 分配份额突变（步长 0.125）	相邻点 $\lvert\Delta Q^*\rvert>\delta$	—	是	是	无转移
D 分配份额突变（步长 0.5）	相邻点 $\lvert\Delta Q^*\rvert>\delta$	—	是	是	转移存在

定义 A 问约束集是否改变，答曰发生且位置明确；定义 C 问成本结构是否重排，答曰发生，但位置晚于 A 约 1.2 个数量级；定义 D 问是否有突跳，细网格下答曰没有。三者并不冲突，因为所问的对象不同。主定义取 A：它在三种定义中唯一不需要自由参数，且直接对应「质量投入由内部最优变为顶到上界」这一策略层面的变化。定义 D 的翻转另给出一条方法论结论——把转移定义在一阶差分与固定阈值的比较上，结论会成为扫描步长的函数，不宜作为主定义。

合读的结论是转移存在，形态为连续饱和而非突跳。三条读数支持这一形态：饱和前

$dQ^*/d\log_{10}C$ 由 0.1483 升至 0.1500（对应 $\log_{10}C$ 由 20.875 至 21.375），饱和点之后恒为零，即在饱和处导数由正转零；跨越饱和点的 $\log_{10}C \in (21.375, 21.5]$ 区段差商为 0.0363，既不是左导数也不是右导数，不参与符号判定，该区段单列排除后导数序列自 21.625 起严格为零；定义 D 在细网格上判不出突变，与光滑饱和一致。

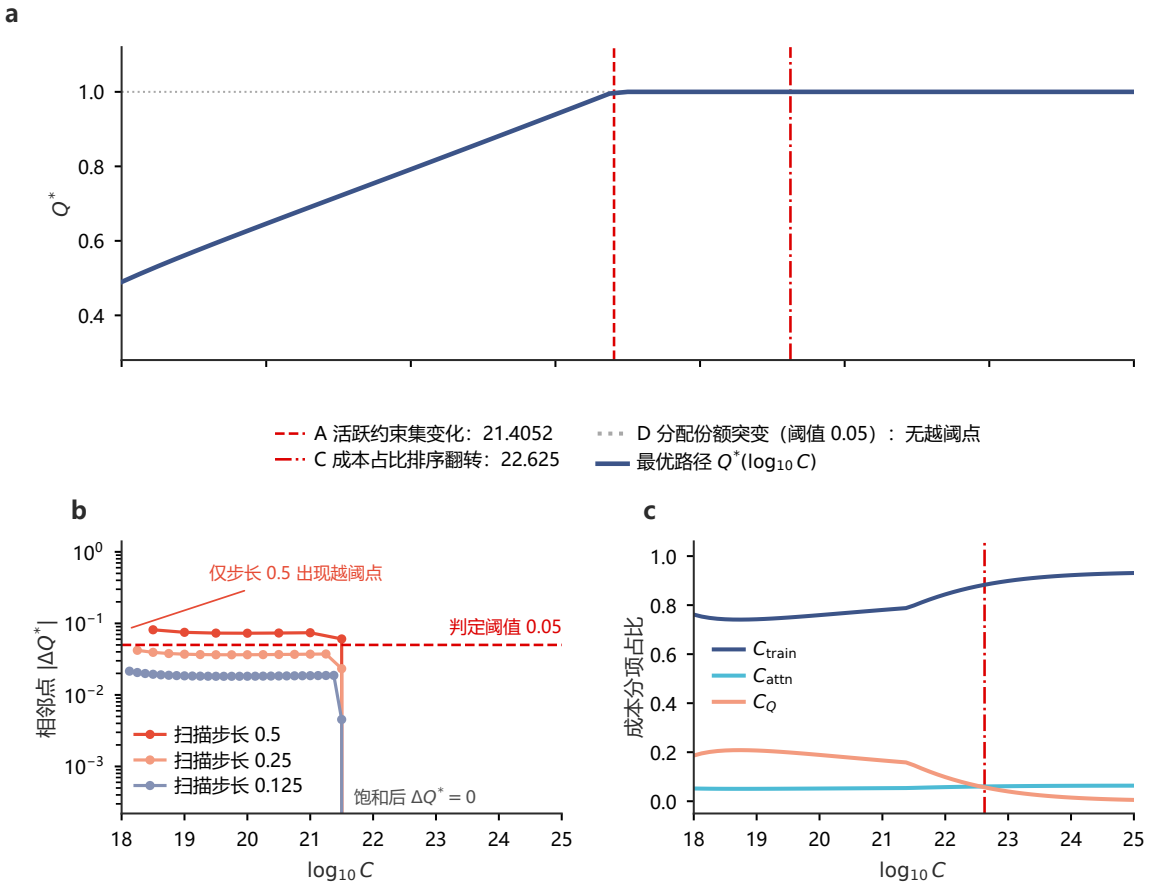


图 6.3：结构性转移的三种定义及其识别结果。(a) 最优质量 Q^* 随 $\log_{10}C$ 的路径；红色虚线为定义 A 的位置 21.4052，红色点划线为定义 C 的翻转位置 22.625，灰色虚线为定义 D 在 $\delta = 0.05$ 下的阈值（细网格上无越阈点）。(b) 三种扫描步长下相邻点的 $|\Delta Q^*|$，横轴为 $\log_{10}C$，纵轴为对数刻度，阈值线为 0.05，仅步长 0.5 出现越阈点。(c) 三项成本占比随 $\log_{10}C$ 的演化，点划线标出 22.625 处 C_Q 与 C_{attn} 的排序翻转。

6.5 成本函数与上下文长度的敏感性

题目要求讨论成本函数 g 的选取对最优解的影响，三类 g 在三个预算档下的最优质量列于表 6.4。

影响集中在预算紧张时。$C = 10^{19}$ 档三类形式给出三种最优质量：指数型 0.6460、幂函数型 0.5390、对数渐进型 1.0000，跨形式极差为 0.4610；而 $C = 10^{22}$ 与 10^{24} 档下三者完全一致，均为 1.0000，分支同为上界分支。差额只出现在最低预算档，而该档恰是唯一存在内点最优的档位。

成因可由式 (6.3) 读出：三类 $Q\,g'(Q)$ 的增长速度不同，幂函数型最快，指数型次之，对数渐进型以 c 为上界；同一预算下三者的 N^* 量级相近、右端相近，故增长越快的形式只能在越低的 Q 处与右端相等。预算上升使右端抬高，三类形式被推向上界的过程彼此靠拢，至 $C \geq 10^{22}$ 时给出相同读数。该比较在题给参数下成立，本节未重新标定三类形式，故不构成关于成本函数形式族的一般结论。质量成本函数的形式携带一层未经本数据检验

表 6.4：三类质量成本函数在各预算档下的最优质量（末行按列给出跨形式极差）

成本函数	$C = 10^{19}$	$C = 10^{22}$	$C = 10^{24}$
指数型 $g = 10^{7}\mathrm{e}^{6Q}$	0.6460	1.0000	1.0000
幂函数型 $g = 5 \times 10^{9} Q^{4}$	0.5390	1.0000	1.0000
对数渐进型 $g = 2 \times 10^{9} \ln(1 + 10Q)$	1.0000	1.0000	1.0000
跨形式极差	0.4610	0.0	0.0

的成分，这一处境与已有观察一致：固定算力下数据筛选比例本身服从标度关系，并非越高越好 [5]，标度指数也并非先验常数 [18]。

题目「或改进 $g(Q)$」部分的分析结果如下。另取饱和指数型 $g = g_{\mathrm{c}}(1 - \mathrm{e}^{-g_{\mathrm{r}}Q})$（$g_{\mathrm{c}} = 10^{7}$，$g_{\mathrm{r}} = 6.0$）、Hill 型 $g = g_{\mathrm{c}} Q^{g_{\mathrm{r}}}/(1 + Q^{g_{\mathrm{r}}})$（同上参数）与二次型 $g = g_{\mathrm{c}} Q^{2}$（$g_{\mathrm{c}} = 4.0343 \times 10^{9}$，$g(1)$ 与指数型相同）。两个有界型的边际成本在高 Q 端趋于零，最优质量恒为上界 1，活跃约束集从不改变，按定义 A 判为无结构性转移；三条扫描各 57 个点的 KKT 判据全部通过，故不是求解失败。二次型给出双侧转移：低预算段 Q^{*} 顶在下界 Q_0，中段为内点，高预算段顶在上界，成本分项占比排序在 $\log_{10} C = 19.125$ 与 22.5 各翻转一次；但定义 A 的识别法只检索 $Q \le 1$ 一个谓词，二分定位不到左事件，且左事件本身是 Q_0 这个人为下界的产物，而 Q_0 尚未经裁定。由这组对照可得有限结论：题给的三类 g 不被上述两个方向的改进所取代——有界方向会使本问的核心发现消失，二次方向会引入依赖未确认参数的左侧事件；该表述限于这两个方向，不足以断言题给的三类 g 是最优选择。

L_{ctx} 经 $k = 6 + \eta L_{\mathrm{ctx}}$ 进入成本。两类成本相等的临界尺度由 $C_{\mathrm{attn}}/C_{\mathrm{train}} = \eta L_{\mathrm{ctx}}/6$ 定出，令其等于 1 得 $L_{\mathrm{ctx}}^{\mathrm{crit}} = 6/\eta = 30000$；该值只是两类开销相等的临界尺度，不是最优上下文长度，本节不把 L_{ctx} 作为寻优变量。五档可行取值取自附件 C7，其中 32768 与 131072 位于临界之上，结果见图 6.4，数值列于附录表 B.8。

跨临界（L_{ctx} 由 2048 增至 131072）的后果可概括为显著压缩可负担规模、几乎不改变相对配比：N^{*} 由 5.6475B 降至 2.5507B，降幅 54.8351%；D^{*} 由 249.0624B 降至 116.1159B，降幅 53.3788%；$N^{*}{:}D^{*}$ 的相对极差仅 3.22%，五档取值始终落在 0.0220 至 0.0227 的窄带内。原因见图 6.4（c）：$C_{\mathrm{attn}}/C_{\mathrm{train}}$ 与三个决策变量均无关，只随 L_{ctx} 由 0.0683 线性升至 4.3691，预算中被注意力开销占去的部分显著增加，可支付的规模因此被压缩，而训练开销与质量开销之间的相对权衡未被重排。两项读数的性质不同，不宜互相替代：配比未重排不等于 L_{ctx} 不重要。一种常见的近似是把 L_{ctx} 视为对有效预算的整体缩放；该近似随 L_{ctx} 增大而失效，本节不采用它解释上述读数，失效的解析原因仍在成本侧的不对称——C_Q 只随 D 缩放而不随 ND 缩放。

6.6 与基线的对照

本文主方法（式 (6.1) 的分支枚举解）记为 M1o，基线记为 M0o，取 Chinchilla 经验配置：D/N 固定为 20（Hoffmann 等 [2] 的 Approach 1/2 给出的约 20 tokens/param），质量固定在 Q_0 即不投入质量提升，N 与 D 由预算约束确定。三档的损失与差距构成列于表 6.5。

三档上主方法的损失均低于基线，报告差距为 0.1070、0.0947 与 0.0563。该差距不能整体归因于质量通道：M0o 的 D/N 被固定为 20，而本律在相同预算下、不投入质量时自身的最优比值随预算漂移，实测为 79.5910、155.5005 与 243.0207（log-log 斜率为 0.0969558），分别为 20 的约 4 倍、8 倍与 12 倍。为分开两部分，另算诊断配置 M0o′：质量同样固定为 Q_0，配比放开为本律自身的最优比值，其损失恰等于主方法在 $Q = Q_0$ 下界分支上的取值，即它就是本律的无质量投入退化解。以它为参照，报告差距分解为「仅质量通道」与「配比口径」两项，后者占报告差距的 32.1032%、27.6584% 与 34.0083%；三个数需同时报出，

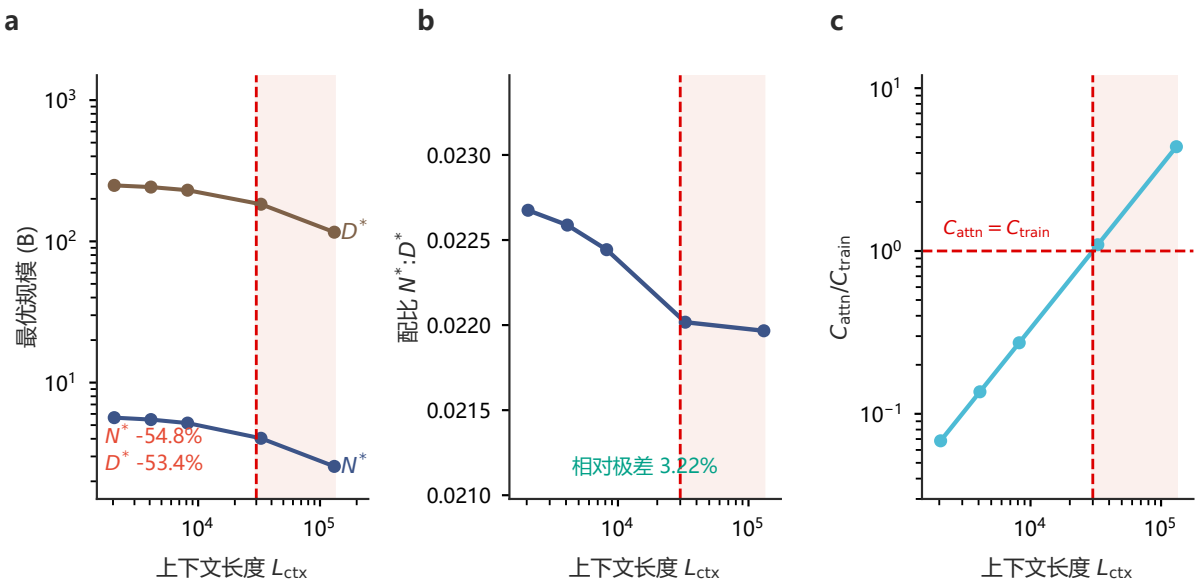


图 6.4：上下文长度跨临界的影响，横轴为 L_{ctx}（token，对数刻度），红色虚线为临界值 30000，右侧阴影为位于临界之上的两档。(a) 最优规模 N^* 与 D^*（B），纵轴为对数刻度，两档的降幅为 54.8351% 与 53.3788%；(b) 最优配比 $N^*{:}D^*$，纵轴为线性刻度，五档的相对极差为 3.22%；(c) 注意力开销与训练开销之比 $C_{\text{attn}}/C_{\text{train}}$，纵轴为对数刻度，红色虚线为两者相等的条件 $L_{\text{ctx}} = 6/\eta = 30000$。

表 6.5：与基线的同口径对照及差距分解（报告差距为 $L(\text{M0o}) - L(\text{M1o})$，仅质量通道差距以诊断配置 M0o′ 为参照，配比口径差距为前两者之差）

预算	M1o 损失	M0o 损失	报告差距	仅质量通道	配比口径	配比口径占比
$C = 10^{19}$	3.1468	3.2538	0.1070	0.0727	0.0344	32.1032%
$C = 10^{22}$	2.1511	2.2457	0.0947	0.0685	0.0262	27.6584%
$C = 10^{24}$	1.9139	1.9702	0.0563	0.0371	0.0191	34.0083%

只报报告差距会把它整体读作质量投入的收益，只报仅质量通道一项则会隐去基线口径本身带来的差距。M0o 不使用本律的参数，是外部经验配置；M0o′ 是本律自身的退化分支，不具备外部性，故本文维持 M0o 为正式基线，M0o′ 只作诊断参照。

把约 20 tokens/param 当作硬判据并不成立。该比例出自 $\alpha \approx \beta \approx 0.5$ 的参数化，此时 D/N 与预算无关；本律的指数组合对应 $\alpha \neq \beta$，D/N 随预算漂移，以常数 20 为判据会拒绝本律自身的真最优解。此外，本律 B1 侧的形状参数与 Chinchilla Approach 3 的常数按十亿单位折算后在数值上几乎同一（相对差 9.4×10^{-6} 至 4.4×10^{-4}），两者是同源参数的不同标定，以 Chinchilla 的数值对照本律因此不构成独立的外部锚点。本节只把 20 列为参照比例，不用作判据；所引比例出自 Hoffmann 等 [2]；该文 Approach 3 的拟合常数（$E = 1.69$、$A = 406.4$、$B = 410.7$、$\alpha = 0.34$、$\beta = 0.28$）载于该文附录 D.2 的式 (10)，本文写作时已对照原文逐项核验。该文正文表 2 给出的是分配系数 $a = 0.46$、$b = 0.54$，与上述指数不是同一组参数。

6.7 配比的边际方向

配比已固定为 $\boldsymbol{z_p} = \mathbf{0}$，但各领域的边际方向可以报出，用于回答「若不改变总算力、只调整领域之间的分配，应向何处倾斜」。配比项对 $\boldsymbol{p}$ 的偏导与 $-b_i$ 成正比（$\kappa < 0$，故 b_i 越大表示上调该域越抬高损失），故

$$\frac{\partial L/\partial p_i}{\partial L/\partial p_j} = \frac{b_i}{b_j}, \tag{6.5}$$

该比值与标度常数 κ 无关，因为 κ 只以整体因子同时进入分子与分母；本问据此只报符号与排序，不报绝对量级，也不报最优配比。参照点取 $C = 10^{22}$ 档的解 $(N^*, D^*, Q^*) = (5.6475,\ 249.0624,\ 1.0000)$，17 个领域按边际损失由大到小的排序列于附录表 B.7：边际损失最大的是 `philpapers`，最小的是 `dm_mathematics`，与 §6.1 中角点解把 0.9999999999999927 的份额给 `dm_mathematics` 的方向一致。该排序与问题二的域比值表同源，二者都由问题一配比模型的系数导出，故不构成对问题二结论的独立佐证，只可作一次内部一致性检查。领域之间确实存在结构性差异，最优权重取决于领域的语言性质与目标任务的匹配程度，配比因而可在较小规模上回归预测 [6]，也可在训练过程中动态调整 [7]。

本节结论的适用条件有三。其一，形状参数取自问题二的 B1 侧，其中 γ 由半合成网格 B7 反解、$\gamma \approx 1$ 是条件性结论；问题二遗留的尺度对齐问题同样适用，最优质量绑定在 B7 的设计刻度上，不能直接代入问题一的经验质量。其二，$Q_0 = 0.35$ 未经裁定；在问题一实测的域级质量范围 $[0.223306, 0.381496]$ 内扫动时，Q^* 的极差为 0.0117、转移位置移动 0.005981（约 0.006 个 $\log_{10}$ 单位），均远小于相应的判别尺度，故在实测范围内 Q_0 不改变本节的结构结论，但其取值未经裁定的状态不变。其三，$C = 10^{24}$ 档为外推，其读数不构成可靠预测。

7 问题四的建模与求解

问题四要求在同一份榜单数据上完成三件相互衔接的工作：把窗口内的能力提升拆分为规模扩张与非规模技术进步两个通道；在算力增长放缓的情景下预测未来前沿并给出不确定性；建立交叉熵损失与多维基准得分之间的映射。三者的顺序由数据条件决定：归因只能在给出参数量标注的投榜记录上进行，故样本口径须先行固定；预测要把损失尺度上的标度律换算到得分尺度，故桥接必须前置，其误差也要一并进入预测区间。

7.1 样本口径与两个核心定义

本节分析的总体是 Open LLM Leaderboard 上的投榜模型（leaderboard submissions），而非开源模型的总体 [11]。投榜由模型方自行决定，进入榜单的记录在参数量分布与评测版

本上不构成随机抽样，榜单自身在测试集污染与版本切换上的已知问题也会一并进入数据[19]，故下文的结论以该投榜样本为范围，不外推到开源模型总体。

样本按三项口径固定。其一为开源筛选，只保留公开权重并给出参数量标注的记录；其二为模型类型，按元数据中的类型字段区分预训练模型（pretrained）与对话微调模型（chat/finetuned），分组分解针对这两族；其三为时间轴，按提交日期把记录归入月份。参数量与类型标注由 C4 元数据经模型名称规范化连接得到，无法匹配的记录按缺失处理；该连接把两个附件的记录视为同一模型，是全节的前提。窗口取 2024 年 6 月至 2025 年 3 月，共 278 天，约合 9.1 个月，覆盖 10 个月度锚点，可用的分解样本为 4561 行。表 7.1 汇总了这些固定设定。

表 7.1：问题四的固定口径与关键设定

项	设定
样本总体	Open LLM Leaderboard 投榜模型（非开源模型总体）
窗口	2024 年 6 月–2025 年 3 月，278 天（约 9.1 个月，10 个月度锚点）
分解样本	4561 行
综合能力 S	C1 的 Average 字段，六项基准等权平均（分）
前沿	每月 S 的 0.90 分位，记作 S_{q90}
规模通道口径	仅参数量，在全样本上估计
预测视界	12 个月（主要视界；24 个月一并报告，仅作附带讨论）

综合能力 S 取 C1 的 Average 字段，即 IFEval、BBH、MATH Level 5、GPQA、MUSR 与 MMLU-PRO 六项基准的等权平均，沿用榜单现有口径，以避免引入无法在数据内检验的权重。前沿（frontier）定义为每月 S 的 0.90 分位，记作 S_{q90}；相应地，每月的参数量 0.90 分位记作 N_{q90}。取分位而非最大值，是因为按月样本量在 173 至 868 之间波动，极值对个别记录过于敏感。规模通道仅以参数量度量，在全样本上估计；训练 token 数与算力字段缺失较多，不进入主口径，其作用见第 7.5 小节。本节的技术路线见图 7.1。

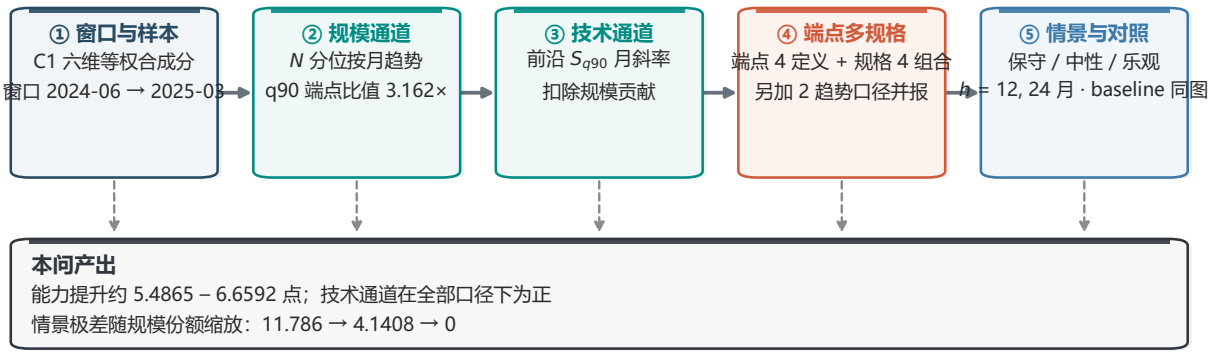


图 7.1：问题四的技术路线。五个环节依次为窗口与样本的固定、规模通道的刻画、技术通道的扣除、端点定义与函数规格的双重扰动，以及情景预测与基线对照；底部为本问的主要产出。

7.2 归因模型的设定与识别性

设模型 i 在月份 $t(i)$ 的综合得分为 S_i，本节采用的加性分解为

$$S_i = f(N_i) + \tau_{t(i)} + \varepsilon_i, \tag{7.1}$$

其中 $f(N)$ 为规模通道函数，τ_t 为第 t 月的技术通道效应，ε 为残差。两通道在窗口内的贡献分别定义为规模项在末月与首月的期望之差，以及技术项在末月与首月之差：

$$\Delta_{\text{scale}} = \mathbb{E}\big[f(N) \mid \text{末月}\big] - \mathbb{E}\big[f(N) \mid \text{首月}\big], \qquad \Delta_{\text{tech}} = \tau_{\text{末月}} - \tau_{\text{首月}}. \tag{7.2}$$

$f(N)$ 的主口径不是 $\log N$ 的线性项，而是 $\log N$ 的十分位虚拟变量。该选择针对窗口内规模分布的形状变化：如第 7.4 小节所示，高分段的参数量在下降而中位数基本不动，十分位虚拟变量把这一形变吸收进各档的截距，不跨分布外推斜率。τ_t 取月度固定效应，每月一个自由参数，首月归一化为零，它因此吸收了规模项之外的全部月度共同变动：数据质量的改善、语料治理与训练工程的经验积累、评测模板的调整，以及模型对榜单基准的过拟合 [19]。本文把该通道统一表述为**非规模技术/数据工程综合进步**，不解释为架构或算法的进步——该通道无法把上述成分彼此分离，窗口内也没有外生变量可供识别。

模型的可分性依赖于时间与规模不共线，这一点在本数据上成立。时间与 $\log N$ 的秩相关为 -0.0615，近乎正交；S 与 $\log N$ 的秩相关为 $+0.6352$，规模项确有解释力。把样本按参数量分成四个档位后分别估计月度效应，四档内 τ 均显著为正，其中 4–10B 档内时间与得分的秩相关为 0.3125，10–30B 档为 0.4827。档内时间与规模已不共线，档间差异由十分位虚拟变量承担，故两通道可以分开估计。

分解的代数性质也在数值上核验过。式 (7.1) 为加性结构，两因子的 Shapley 值与式 (7.2) 恒等，没有交互项需要估计；四种函数规格与四种端点定义下，两通道点数之和均等于合计提升，份额之和恒为 1。份额因此可直接由点数读出，其适用边界见下文。规模通道的写法与经典标度律并不等同：后者描述损失随规模的变化 [1, 2]，以分布形状稳定为前提 [18]，本节只估计规模项在观测分布上的取值。

7.3 分解结果与口径敏感性

主口径（$\log N$ 十分位、月度固定效应、单末月读数）给出规模通道 1.7175 分、技术通道 4.9069 分，合计 6.6244 分。按月内重抽模型的自助区间（重抽 2000 次）为：规模点数 $[0.1314,\ 2.9714]$，技术点数 $[3.7183,\ 6.5857]$。技术通道的点数在重抽样下远离零，规模通道虽为正，其份额并不稳定。

自助区间只重抽模型，不重抽口径选择，在结构上覆盖不了换一个末端定义或换一种 $f(N)$ 规格的摆动，两类扰动的结果列于表 7.2。

规格扰动会使规模通道的符号翻转。线性 $\log N$ 规格给出规模通道 -1.8730 分、技术通道 8.4975 分，规模份额 -0.2827；把月度固定效应换成季度后，线性规格的规模份额进一步降至 -0.4972。该结果不是计算缺陷，而是线性规格的必然产物：窗口内高分段的规模在下降，当 $f(N)$ 的斜率被约束为正时，规模项的末月与首月期望之差必然为负。十分位规格不做这一外推，故给出正号的规模贡献。两种规格的读数差别不影响方向判断，故一并列出。

端点扰动给出同类的结论。把末月的定义由单月改为末两月合并、末三月合并或去掉末月，规模份额依次为 $+0.2593$、$+0.1811$、-0.0282、$+0.2205$，极差 0.2875，并发生一次符号翻转，该极差已大于主口径的规模份额 0.2593 本身。技术份额在四种端点定义下分别为 0.7407、0.8189、1.0282、0.7795，方向始终为正；各口径的两通道贡献见图 7.2。

两类扰动的共同含义是：通道方向稳健，具体比例并不稳健。技术通道在表 7.2 的九种口径下全部为正（最低 0.7407、最高 1.5341），规模通道的份额则随规格与端点变号。主

表 7.2：通道分解对端点定义与函数规格的敏感性（单位：分；份额无量纲）。端点扰动的四个口径分别覆盖 4561、1477、2345 与 4219 行。

通道口径	规模通道	技术通道	合计	规模份额
主口径：$\log N$ 十分位 × 月度 × 单末月	1.7175	4.9069	6.6244	+0.2593
端点：首月对末两月合并	1.2040	5.4438	6.6477	+0.1811
端点：首月对末三月合并	−0.1547	5.6412	5.4865	−0.0282
端点：去掉末月	1.4685	5.1908	6.6592	+0.2205
规格：线性 $\log N$，月度	−1.8730	8.4975	6.6244	−0.2827
规格：$\log N$ 十分位，季度	0.4567	5.0298	5.4865	+0.0832
规格：线性 $\log N$，季度	−2.7280	8.2145	5.4865	−0.4972
趋势法：$\log N$ 十分位（十个月斜率）	0.5175	5.1640	5.6815	+0.0911
趋势法：线性 $\log N$（十个月斜率）	−3.0343	8.7158	5.6815	−0.5341

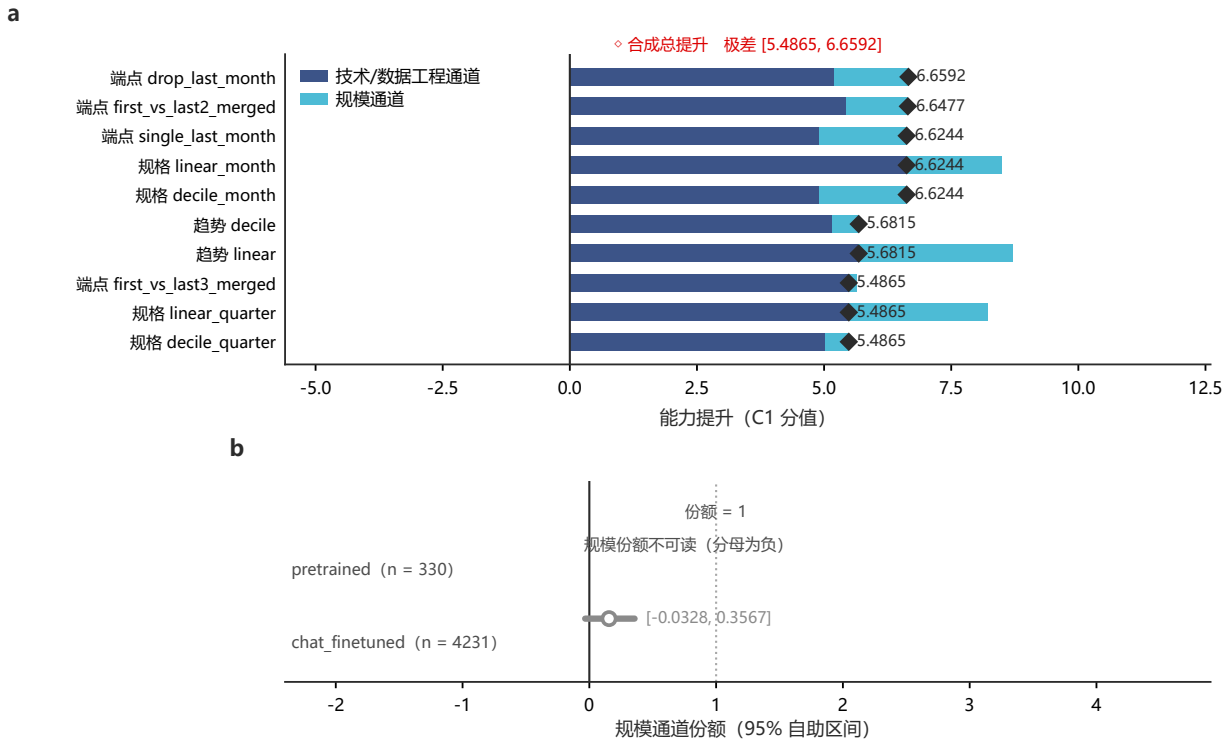


图 7.2：各口径下的通道贡献分解与子组份额。(a) 横轴为能力提升（C1 分值），每个口径一条堆叠条，深色为技术/数据工程通道、浅色为规模通道，菱形为合计提升，四种端点/规格算法给出的极差为 5.4865–6.6592 分，规模通道的条在若干口径下伸向负半轴。(b) 对话微调组的规模通道份额及其 95% 自助区间，竖直虚线为份额等于 1 的位置；预训练组的合计提升为负，其份额的分母为负，该组的份额与区间不在图中给出。

口径的自助区间 [0.0223, 0.4019] 不含零，但它只测「换一批模型」，不测「换一个末端定义」，后者给出的极差已超过主口径的规模份额，故该区间不含零不构成规模贡献显著为正的证据。上述扰动只支持通道方向的结论，不支持任何具体比例。

合计提升在四种端点/规格算法下的极差为 5.4865–6.6592 分。这一区间是这四种算法的极差，而不是全部方法的极差：趋势法只用九个月的 drop-last 变体给出 5.3581 分，略低于下界，相差约 0.13 分，量级上不改变任何结论。

7.4 趋势法读数与规模—前沿的同期走势

端点法只用窗口两端的读数，会把月间波动压缩成一个差值；趋势法改用全部十个月的斜率定义通道贡献，是本节主结论的实际依据。两通道的月斜率分别为 +0.05750 与 +0.57377（均为分/月），后者约为前者的 9.98 倍。按九个月区间累积，规模通道贡献 0.5175 分、技术通道 5.1640 分，合计 5.6815 分。规模份额为 +0.0911，按月分层重抽 1000 次所得的自助 95% 区间为 [−0.1942, +0.2258]，含零。

关键量是斜率比而非份额：技术通道的月斜率比规模通道高一个数量级，规模份额很小且其区间含零。两项读数合起来给出本节的主结论：窗口内的能力提升由非规模技术/数据工程综合进步主导，规模通道的贡献与零不可区分。合计 5.6815 分落在端点法的区间之内，两种口径相互印证。

同期规模与前沿的走势方向相反，这一对比是理解上述结果的前提，见图 7.3。前沿 S_{q90} 由首月的 25.9201 分升至末月的 41.3875 分，对月份做线性拟合的斜率为 +1.5333 分/月。参数量分位则在下降：N_{q90} 由 46.703B 降至 14.770B，端点比值为 3.162，即缩至首月的 1/3.162；$\log_{10} N_{q90}$ 的月斜率为 −0.06281，窗口内累计（9 个月度间隔）−0.5653 dex，按该斜率换算的隐含比值为 $10^{0.5653} = 3.675$。两个比值描述的不是同一口径，其差别来自 N_{q90} 逐月路径的非单调——2024 年 8 月一度回升至 70.554B，其后稳定在 14.77B 附近，斜率不经过端点。

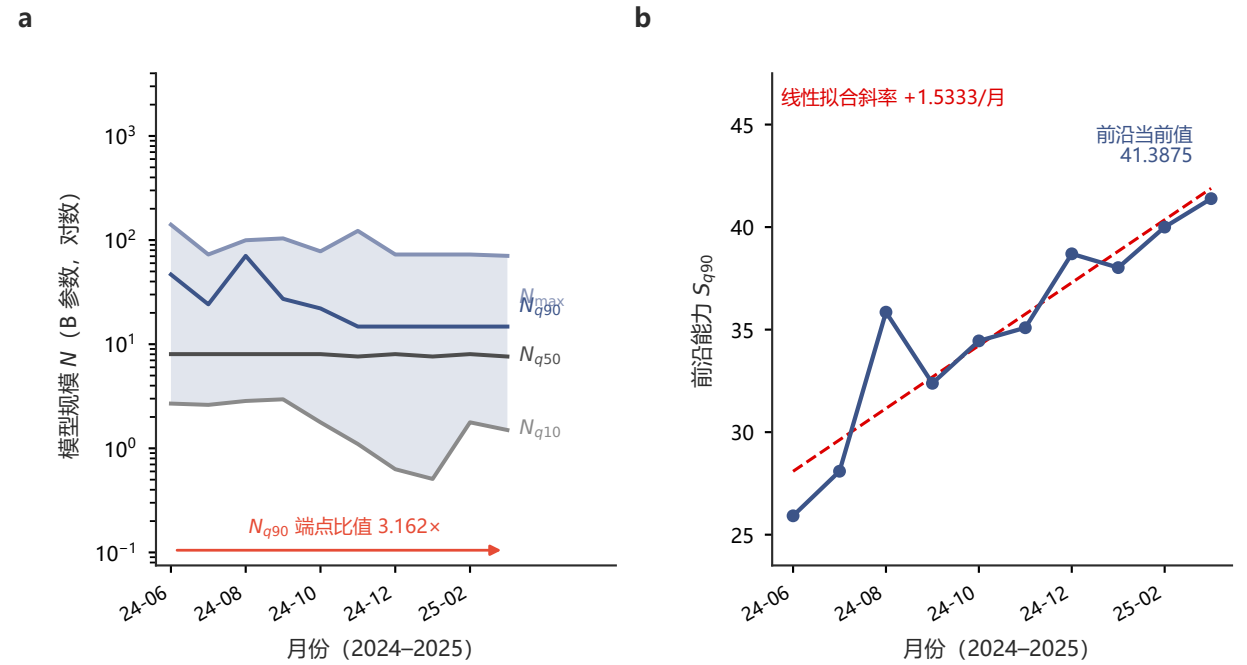


图 7.3：规模与前沿的同期走势。(a) 纵轴为模型参数量（十亿，对数刻度），细线为每月参数量分布的 0.10、0.50 与 0.90 分位及最大值，其中 0.90 分位由 46.703B 降至 14.770B，端点比值为 3.162。(b) 纵轴为前沿能力 S_{q90}（分），红色虚线为线性拟合，斜率 +1.5333 分/月，末月读数为 41.3875 分。

下降集中在高分段。$\log_{10} N$ 中位数的月斜率仅为 -0.00209，即中位规模在整个窗口内基本不动；0.10 分位的月斜率为 -0.05714，0.90 分位为 -0.06281。前沿变强的同时，站上前沿的模型在变小；这与趋势法的分解结果一致——若能力提升主要来自规模扩张，N_{q90} 不应下降。前沿推进的来源可在语料工程一侧找到对应：固定算力下改变数据选择与配比，其收益可以超过单纯扩大规模 [5, 15]；窗口内投榜模型的中位规模基本不变，能力差异更多来自数据与训练过程 [20]。

7.5 子组分解与规模通道的度量口径

题目要求区分预训练与对话/微调两类模型，分组结果列于表 7.3。

表 7.3：按模型类型的子组分解（主口径，单位：分；份额无量纲）。预训练组的合计提升为负，其份额失去解释力，故只报绝对点数与方向。

子组	n	规模通道	技术通道	合计	规模份额（95% 自助区间）
对话微调	4231	1.0921	5.9356	$+7.0278$	0.1554 $[-0.0328,\ 0.3567]$
预训练	330	-5.9745	2.3955	-3.5789	不可读（分母为负）

对话微调组（$n = 4231$）合计提升 $+7.0278$ 分，规模通道 1.0921 分、技术通道 5.9356 分，规模份额 0.1554，其自助 95% 区间 $[-0.0328,\ 0.3567]$ 含零，故该组的规模贡献不能被认定为显著为正。预训练组（$n = 330$）给出方向相反的读数：合计 -3.5789 分，其中规模通道 -5.9745 分、技术通道 $+2.3955$ 分。该组在本窗口内能力是回落的，而非提升的。回落本身是可报告的读数，但其份额不可解释：份额是两个通道之比，分母为负时该比值的符号与量级都失去意义，故对该组只报告绝对点数与方向。预训练组仅占全样本的 7.2%，分组估计的精度低于全体，两组的结论也不能互相推广：对话微调组的正提升不能推断预训练模型在进步，预训练组的回落也不能推断开源前沿在退步。

规模通道的度量口径需要一个对照：主口径只取参数量，另一口径同时纳入参数量、训练 token 数与算力。在同时给出这三项元数据的 66 个模型子集上，仅取参数量的口径给出规模通道 -3.1404 分、技术通道 -1.4083 分，三项并取的口径给出规模通道 -3.3855 分、技术通道 -1.1631 分。两者的规模点数相差 $+0.2451$ 分，技术点数相差 -0.2451 分，精确抵消。

这一对照支持的是机制，而不是方向。省略算力与数据量会在两个通道之间重分配解释力，重分配量约 0.25 分，总量不变；但该子集的合计提升为 -4.5487 分，为负值，两个通道的份额都不可读，点数比较的符号关系不能用来判定偏误方向。该子集的末期（2025 年第一季度）只有 3 个模型，中位 $\log_{10} N$ 降至 0.180、平均得分降至 7.765，其负的合计提升是端点抽样的产物；该子集中预训练模型的占比又远高于全样本，两者并非同一总体。因此这里的 0.2451 分只作机制的量级参考，不构成对全样本口径的修正。

7.6 从损失到得分的桥接与误差传播

预测需要在损失尺度上进行，而问题二的标度律以验证集交叉熵损失为因变量、前沿以基准得分为尺度，两者的换算关系必须由实际观测拟合，不能假定。桥接数据（C6，75 行）同时给出验证集损失与榜单得分，按可比性分为 High 与 Medium 两层，以 3 : 1 的层级权重拟合

$$\text{LB_Average} = 62.7406 - 22.393 \times \text{Val_Loss}, \tag{7.3}$$

验证集损失与榜单得分呈单调递减关系（斜率 -22.393，95% 置信区间 $[-44.481,\ -7.8308]$），均方根误差为 10.9842 分，各项列于表 7.4。

High 层只有 7 个样本，其秩相关 -0.6071（p 值 0.148）与式 (7.3) 方向一致但不显著；

表 7.4：损失到得分的桥接拟合及其分层核验（单位：分）。秩相关为斯皮尔曼系数。

量	值	备注
截距	62.7406	式 (7.3)
斜率	-22.393	95% 置信区间 $[-44.481,\ -7.8308]$
均方根误差	10.9842	与得分本身同量级
映射误差 σ	10.1726	作为独立随机项并入预测
桥接样本	75 行	High 层 7 行、Medium 层 68 行，权重 3 : 1
High 层秩相关	-0.6071	p 值 0.148
Medium 层秩相关	-0.5087	p 值 9.4×10^{-6}

Medium 层 68 个样本的秩相关为 -0.5087（p 值 9.4×10^{-6}）。样本量是 High 层不显著的原因，不能据此认为该层质量更差。残差标准差 10.1726 分与得分本身同一量级，这是 9.1 个月窗口与 75 行桥接样本所能给出的精度；该误差被作为独立随机项并入蒙特卡洛预测，区间因此偏宽，而宽度是数据条件的结果，不是算法上的取舍。桥接也不引入循环论证：用于拟合的损失值全部来自技术报告与训练日志，不含由标度律反推的估计行，式 (7.3) 的输入不包含问题二的结论。

7.7 前沿预测与基线对照

预测以 S_{q90} 为对象。做法是把前沿自身的月斜率按规模份额拆入两个通道，得到技术通道 1.1358 分/月与规模通道 0.3975 分/月（合计 $+1.5333$ 分/月），再对两个通道分别施加情景假设：规模通道随算力增速缩放，技术通道按年衰减率衰减。三个情景的设定为保守（算力 1.5 倍/年，技术衰减 0.50）、中性（2.5 倍/年，0.75）与较高（4.0 倍/年，1.00）。技术趋势斜率、桥接映射误差 $\sigma = 10.1726$ 与桥接斜率的不确定性 $[-44.481,\ -7.8308]$ 三类来源同时抽取，蒙特卡洛重复 4000 次。表 7.5 给出 12 个月视界的结果，并按同口径列出纯趋势基线 M0a（$q90_t = a + bt$，斜率 1.5333 分/月）的对应读数。

表 7.5：12 个月视界的前沿预测与纯趋势基线的同口径对照（单位：分）。当前前沿为 41.3875 分；预声明的预测判据取中性行的 80% 区间下界（43.268 分）。

口径	中位数	80% 区间	95% 区间	95% 宽度
保守（1.5 倍/年，衰减 0.50）	50.249	$[37.246,\ 63.701]$	$[30.237,\ 71.120]$	40.883
中性（2.5 倍/年，衰减 0.75）	56.330	$[43.268,\ 69.699]$	$[35.513,\ 77.449]$	41.935
较高（4.0 倍/年，衰减 1.00）	62.035	$[49.189,\ 75.672]$	$[41.683,\ 82.867]$	41.184
基线 M0a（纯趋势，不分解）	60.290	$[56.448,\ 64.131]$	$[54.415,\ 66.165]$	11.750

中性情景下 12 个月的前沿中位数为 56.330 分，80% 区间 $[43.268,\ 69.699]$，95% 宽度 41.935 分，约等于当前前沿值本身；基线在同一视界上给出 60.290 分，80% 区间 $[56.448,\ 64.131]$，95% 宽度 11.750 分。两者相比，主方法的点值低约 6.6%，95% 区间宽约 3.6 倍。差异来自结构而非随机性：主方法对技术趋势施加了情景衰减，基线不做衰减，且基线不承担桥接环节的映射误差。

预测使用的标度律参数承接问题二，其中质量指数的反解依赖半合成网格（附件 B6–B8），该部分带补充分析的性质，不构成直接实验观测；该标度律的数据量指数可跨源共

享这一前提已在问题二中单独检验并判为不成立（见第 5 节），此处按承重前提使用，其条件性一并继承。该依赖只影响情景读数的具体幅度。

预声明的预测判据为：中性情景下 12 个月的 80% 区间下界高于当前前沿值。实测下界为 43.268 分，高于 41.387 分，裕度 1.881 分。该判据的执行过程有一次次序需要说明。首轮实现把均值层面的技术通道月斜率 0.4675 分直接加到 0.90 分位的前沿水平上，两端对象不一致，使预测系统性偏低，首轮下界为 32.276 分，判据不通过；修正为用前沿自身的斜率按规模份额拆通道之后，下界升至 43.268 分。判据文字自始未改，但缺陷是在看到首轮不通过之后才被发现的，这限制了该判据作为独立验证的分量。

基线也满足同一判据：其 80% 区间下界为 56.448 分，高于当前前沿，就该判据而言主方法不构成对基线的优势。主方法的价值在于给出可按通道拆解、并随算力情景变化的区间，代价是区间更宽、点值更低。

本节以 12 个月为主要视界，24 个月仅作附带讨论。乐观情景的 24 个月中位数为 94.118 分，逼近得分 0–100 的上界，其 95% 宽度 29.236 分反而窄于同情景 12 个月的 41.184 分；这一收窄是截断到上界造成的，不是精度的提高；得分上界的饱和形态在 9.1 个月的窗口内无法检验，24 个月的读数仅在上述限制下具有参考意义。评测指标的取值方式本身会塑造所观察到的能力形态，在指标存在截断或分辨率受限时尤其如此 [21]。

情景极差随规模份额严格缩放，见图 7.4。表 7.5 中的三个情景对应主口径的规模份额 0.2593，其极差为 11.786 分；若改用趋势法的份额 0.0911，极差按同一比例降至 4.1408 分，约为中性中位数的 7.4%；份额趋零时极差亦趋零。算力增长放缓对开源前沿的短期预测影响很小，因为前沿的推进本就不依靠规模扩张 [3]。

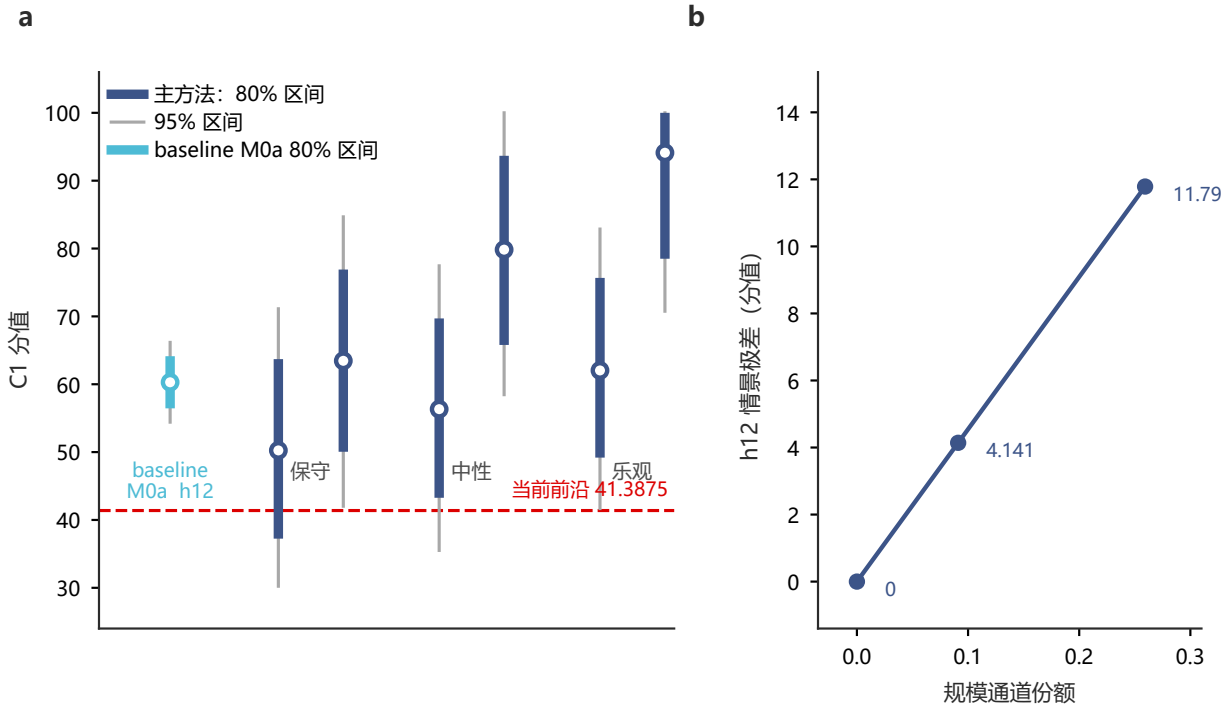


图 7.4：前沿预测与情景缩放。(a) 纵轴为 C1 分值，三个情景各给出 12 个月与 24 个月两个视界的中位数（空心圆）、80% 区间（粗段）与 95% 区间（细线），青色为纯趋势基线 M0a 的 12 个月读数，红色横线为当前前沿 41.3875 分。(b) 横轴为规模通道份额，纵轴为 12 个月视界上的三情景极差；份额为 0.2593、0.0911 与 0 时，极差分别为 11.79、4.141 与 0 分。

7.8 基准内部的逐任务聚合

题目要求在给定基准内部给出逐任务的聚合，不能只用汇总表。C8 提供各模型在 BBH 等基准上的逐任务明细：可解析目录 1860 个，另有 4 个文件因同一次导出事故不可解析；得到任务级记录 65137 条，其中 BBH 含 24 个子任务。

聚合口径为：先在每个子任务内对全部模型做 z 标准化，再按模型对子任务取均值。逐任务标准化的必要性在于 24 个子任务的通过率量纲不同，直接相加会让容易的子任务主导排序。按该口径得到 1860 个模型的 z 分数，均值为 -0.0、标准差 0.8037。子任务之间的难度落差明显：最难的 5 项为 tracking_shuffled_objects_seven_objects（0.1743）、tracking_shuffled_objects_five_objects（0.2033）、geometric_shapes（0.3285）、tracking_shuffled_objects_three_objects（0.3298）与 object_counting（0.3409）；最易的 5 项为 boolean_expressions（0.7640）、sports_understanding（0.6801）、hyperbaton（0.6320）、snarks（0.6026）与 navigate（0.5850）。前者的主体是多步状态追踪与计数，后者以单步布尔判断与常识为主，难度排序与推理步数一致。

缺失基准按可比样本子集口径处理：某个模型在某个子任务上没有记录时，该子任务不参与该模型的均值，也不以零填充——零填充在通过率量纲上等同于「全部答错」，会把记录缺失误读为能力低下。该口径保持了同一模型内部各子任务的可比性，代价是不同模型之间的有效子任务集合并不完全相同，故这些 z 分数适用于模型内部的排序，不宜直接跨模型作绝对水平的比较。

8 模型评价

8.1 模型的优点与创新点

8.1.1 方法层面

把不可检验的前提显式化为条件，而不是把它留在拟合过程里。广义标度律的质量指数只有在数据量指数给定的前提下才可辨识，而跨来源共享数据量指数这一前提在本数据上检验不通过。本文没有回避这一结果，而是在给出质量指数的同时给出该前提不成立时的另一条读数，并说明两条读数各自支持的结论，使读者能够判断结论的适用边界。

用定义的分歧本身作为结论。「预算跨越量级时最优策略是否质变」在缺乏公认定义时不可判定。本文并报三种自然定义并逐一识别，发现其中一种给出明确位置且不依赖任何人为阈值或网格步长，另一种的位置依赖网格步长，第三种则因判据不是网格不变量而无法给出结论。由此得到的判断是：转移存在，但形态是连续饱和而非突变。这一结论比单一定义下的一个位置坐标更为稳健，也解释了几种定义为何不矛盾。

以解析结构替代纯数值求解。优化问题的最优解在多数预算档位触及质量上界，内点条件并不刻画最优解。本文按活跃约束集分支枚举，把内点段与边界降维段分别解析求解，再由一阶条件的约减形式给出两个可供交叉验证的关系式，并用中心差分重建、邻域采样与全局数值优化三条独立路径验证分支枚举的完备性。

把不确定性拆到它真正的来源上。归因分解的点值在端点定义变动下会发生符号翻转，而重抽样区间在结构上不可能覆盖这一来源。本文把端点定义与函数规格两种来源分别扰动并一并报告，由此得出「任何具体百分比分割都不可主张」的判断，并改以方向与量级作为结论。

8.1.2 建模层面

门控式质量合成。质量指标中既有越高越好的价值类，也有越低越好的污染类。本文用价值维度均值乘以污染维度补数的门控形式合成质量评分，使污染指标以乘性方式施加惩罚而非在加权平均中相互抵消，并由此自然给出「同一文本在两类维度上同时取高分」这一冲突的定义。

逐 token 归一化处理长度混淆。按序列求和的质量信号与文档长度高度相关，其表观方向由长度效应主导。本文对这类字段按长度归一化后再参与合成，使其与独立质量指标

的秩相关方向由负转正，避免了因量纲错误而引入的虚假矛盾。

依据约束结构选择求解方式。优化问题的最优解是否落在内点由预算水平决定，本文先以探针确定各档位的分支归属，再据此设计分支枚举，而不是默认内点方法普遍适用。

把预测区间与纯趋势基线同表对照。本文的预测模型在点值与区间宽度上均不优于不含分解结构的纯趋势基线。这一比较如实列出，用以说明结构化分解的价值在于提供可归因、可情景化的区间，而非提高点预测精度。

8.2 模型的缺点与适用范围

8.2.1 数据条件带来的限制

(1) **单一标量质量评分无法同时做到跨域可比与域去混淆。**本文使用的 22 个指标均为面向现代网页文本训练的判别器输出，其中多数指标对本批数据的领域标签具有很高的可分性。这是一个可证的限制：在这批指标上，任何单一标量评分都会部分地编码领域身份。因此本文对领域间的质量比较只在最高一档的集合层面作出，不对档内位次作断言。

(2) **配比效应的形状不可跨源验证。**附件中没有文件同时给出配比与规模、数据量的联合观测，配比系数只能由问题一的模型引入并作为承重前提声明；相应地，本文只报告各领域边际效应的方向与相对排序，不报告绝对量级。

(3) **质量指数的解释绑定在特定刻度上。**问题一给出的经验质量评分落在一个较窄的取值区间内，与半合成网格的设计刻度并非同一对象。本文不做静默的线性映射，质量指数的解释因此限定在设计刻度上。

(4) **部分结论建立在半合成数据上。**广义标度律相对经典形式的改进只能配备质量变化的半合成网格上验证；该结论带补充分析的性质，不能替代真实实验观测。

(5) **高预算档位是外推。**最高档预算对应的最优参数量与数据量分别达到真实观测上界的数倍与十倍以上，其结果不应被理解为可靠预测。

(6) **时间窗口不足。**问题四的密集数据仅覆盖 9.1 个月，而预测视界为 12 至 24 个月。预测区间偏宽是数据条件的结果，而非算法缺陷。

(7) **技术通道不可直接观测。**该通道由规模项之外的月度共同变动构成，同时吸收未观测的数据质量变化与模型对基准的过拟合，因此只能表述为非规模技术与数据工程的综合进步，不能解释为纯粹的算法改进。

(8) **预测未优于基线。**在预声明的预测判据上，纯趋势基线同样满足，且主方法的点值低于基线、区间宽度约为基线的数倍。

8.2.2 方法选择的代价

(1) **质量与数据量的替代关系只在比例意义下成立。**所采用的有效数据量形式使质量与数据量的弹性之比恒等于质量指数，因此本文不主张二者的替代率随配置位置变化；随位置变化的只有质量与参数量之间的替代关系。

(2) **领域配比未参与联合优化。**配比项对配比是线性的，最优解必然落在单纯形顶点。本文因此固定配比、只报告其边际方向与排序，代价是放弃了「配比随预算变化」这一维度。

(3) **基线质量水平未经外部确认。**本文在其合理范围内做扫动并报告结论稳定，但该取值本身仍是一个需要外部依据的参数。

(4) **部分判据在执行后才被发现设计不足。**问题一的目标口径替换检查中，预声明的判据对每个领域系数恒为正，因而无法被证伪；真正有信息量的是系数向量的排序反转。本文如实记录这一判据设计失效，不事后更换判据以改善结论。

8.3 模型的推广

上述方法中不依赖于具体题设的部分可以迁移到相邻问题。

正负向指标并存时的合成。门控形式适用于任何由「越高越好」与「越低越好」两类指标构成的多维评价体系，只要两类指标在语义上可分；此时冲突样本的识别退化为在两类维度上同时取高分的样本筛选，其阈值由分位数锚定，不随样本量漂移。这一构造可直接用于其他语料、其他模态的数据质量治理场景。

转移现象的识别框架。本文对结构性转移给出的三种定义——活跃约束集变化、成本分项占比排序变化、分配份额突变——构成一个可复用的识别框架：当一个问题出现「最优策略是否随参数发生质变」的提问时，可按此框架分别识别，并优先采用不依赖人为阈值与网格步长的那一种作为主定义。该框架不限于算力配置问题，同样适用于其他资源分配与最优控制场景。

不确定性来源的分解。把点值的不稳定性归因到重抽样、函数规格与样本端点三个来源，并分别扰动，是一种可以普遍采用的稳健性做法：它避免了用重抽样区间去覆盖它结构上无法覆盖的变异来源，也避免了在发现脆弱性之后事后放宽判据。

跨尺度映射的误差传播。当两个评价尺度之间只有少量高可比样本时，把映射误差作为独立随机项并入蒙特卡洛预测，可以给出诚实的区间宽度；这一做法可推广到任何需要在中间量尺度与目标量尺度之间转换的外推问题。

进一步工作。若要收紧本文的主要限制，需要补充两类数据：同时给出配比与训练规模配置的实验，用以检验配比效应的可迁移性；以及跨越更长窗口的模型评测记录，用以检验得分上界的饱和形态并压缩预测区间。

参考文献

[1] Jared Kaplan，Sam McCandlish，Tom Henighan，et al.，Scaling Laws for Neural Language Models，https://arxiv.org/abs/2001.08361，2026-09-26。

[2] Jordan Hoffmann，Sebastian Borgeaud，Arthur Mensch，et al.，Training Compute-Optimal Large Language Models，Advances in Neural Information Processing Systems，35：30016–30030，2022。

[3] Niklas Muennighoff，Alexander M. Rush，Boaz Barak，et al.，Scaling Data-Constrained Language Models，Advances in Neural Information Processing Systems，36：50358–50376，2023。

[4] Akari Asai，Jacqueline He，Rulin Shao，Weijia Shi，et al.，Synthesizing Scientific Literature with Retrieval-Augmented Language Models，Nature，650(8103)：857–863，2026。

[5] Sachin Goyal，Pratyush Maini，Zachary C. Lipton，et al.，Scaling Laws for Data Filtering — Data Curation Cannot be Compute Agnostic，https://arxiv.org/abs/2404.07177，2026-09-26。

[6] Qian Liu，Xiaosen Zheng，Niklas Muennighoff，Guangtao Zeng，Longxu Dou，Tianyu Pang，Jing Jiang，Min Lin，RegMix: Data Mixture as Regression for Language Model Pre-training，https://arxiv.org/abs/2407.01492，2026-09-26。

[7] Sang Michael Xie，Hieu Pham，Xuanyi Dong，Nan Du，et al.，DoReMi: Optimizing Data Mixtures Speeds Up Language Model Pretraining，Advances in Neural Information Processing Systems，36：69798–69818，2023。

[8] Mayee F. Chen，Nicholas Roberts，Kush Bhatia，et al.，Skill-It! A Data-Driven Skills Framework for Understanding and Training Language Models，Advances in Neural Information Processing Systems，36：36000–36040，2023。

[9] Alon Albalak，Yanai Elazar，Sang Michael Xie，et al.，A Survey on Data Selection for Language Models，https://arxiv.org/abs/2402.16827，2026-09-26。

[10] Stella Biderman，Hailey Schoelkopf，Quentin Anthony，et al.，Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling，Proceedings of Machine Learning Research，202：2397–2430，2023。

[11] Hugging Face，Open LLM Leaderboard，https://huggingface.co/spaces/open-llm-leaderboard/open_llm_leaderboard，2026-09-26。

[12] Guilherme Penedo，Hynek Kydlíček，Loubna Ben Allal，et al.，The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale，Advances in Neural Information Processing Systems，37：30811–30849，2024。

[13] Benjamin Warner，Antoine Chaffin，Benjamin Clavié，et al.，Smarter, Better, Faster, Longer: A Modern Bidirectional Encoder for Fast, Memory Efficient, and Long Context Finetuning and Inference，Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics，1：2526–2547，2025。

[14] Sang Michael Xie，Shibani Santurkar，Tengyu Ma，Percy Liang，Data Selection for Language Models via Importance Resampling，Advances in Neural Information Processing Systems，36：34201–34227，2023。

[15] Ben Sorscher，Robert Geirhos，Shashank Shekhar，et al.，Beyond neural scaling laws: beating power law scaling via data pruning，Advances in Neural Information Processing Systems，35：19523–19536，2022。

[16] Jack W. Rae，Sebastian Borgeaud，Trevor Cai，et al.，Scaling Language Models: Methods, Analysis & Insights from Training Gopher，https://arxiv.org/abs/2112.11446，2026-09-26。

[17] Leo Gao，Stella Biderman，Sid Black，et al.，The Pile: An 800GB Dataset of Diverse Text for Language Modeling，https://arxiv.org/abs/2101.00027，2026-09-26。

[18] Yasaman Bahri，Ethan Dyer，Jared Kaplan，et al.，Explaining neural scaling laws，Proceedings of the National Academy of Sciences，121(27)：e2311878121，2024。

[19] Hugging Face，Open LLM Leaderboard 说明文档，https://huggingface.co/docs/leaderboards/en/open_llm_leaderboard/about，2026-09-26。

[20] Abhimanyu Dubey，et al.，The Llama 3 Herd of Models，https://arxiv.org/abs/2407.21783，2026-09-26。

[21] Rylan Schaeffer，Brando Miranda，Sanmi Koyejo，Are Emergent Abilities of Large Language Models a Mirage?，Advances in Neural Information Processing Systems，36：55565–55581，2023。

附录 A　图表目录

插图

1.1　附件数据的构成、按问映射与规范化流程。左侧为 40 个原始附件（只读），中部为按子问题划分的输入集，右侧为规范化、清洗与一致性核验环节。 . 6

2.1　全文框架。上排为数据层（附件 A、B、C 三组，按问映射为 18/13/4/8 个文件），中部四列为四个子问题的方法要点与相互依赖，下方为汇总结论与证据链。 7

4.1　问题一的方法流程。□—□ 为依次执行的五个环节：规范化（20 列主口径并剔除缺失行）、语义分组（14 个价值指标归入 V、6 个污染指标归入 P）、门控合成 $Q = V(1 - P)$、冲突判据 CD2（高价值且高污染，分位数锚定）与配比建模（主效应加二阶交互，以岭回归正则化）。下方为本节交付物：领域序及其最高一档、领域级 Q（供问题二对照，其刻度对齐见问题二）、配比到损失的拟合优度，以及域级 Q 增量在三尺度上的实测值与区间。 . . . 13

4.2　门控合成与等权平均的对照。(a) 两法的领域序，虚线为次序不变，红色横线标出唯一互换的一对；(b) 四个聚合估计量下的可分辨域对数，虚线为上限 21；(c) 域级自助半宽对域样本量（双对数），左下角孤点为 book（$n = 171$，半宽 0.0093）；(d) 40 次权重扰动下的域序 Kendall τ 分布，门控合成均值 0.9976、等权平均 0.9595，域序不变的重复比自 0.625 升至 0.975。 16

4.3　四判据与三档锚点下的全局冲突率热力图，横轴为锚点分位数 p_{70}、p_{75}、p_{80}，纵轴为判据，色标为冲突率。(a) 合并总体口径，(b) 按域归一化的消融臂。黑框标出主判据 CD2 在 p_{75} 处的取值 0.041，红框标出取值越出非退化带 $(0.01, 0.50)$ 的格子；两档口径下越界的格子相同，均为「至少三高且至少三低」判据在 p_{70} 处的 0.836 与 0.822。 19

4.4　配比模型的跨尺度表现与质量评分的增量。(a) 三个尺度上两模型的去尺度偏移 R^2，1m 尺度上二阶交互模型 0.983 高于线性模型 0.913，60m 与 1B 两尺度上两者互有高低；(b) 引入域级 Q 后去偏 R^2 的增量与 95% 自助区间，三条区间均跨过零线（虚线），1B 尺度的上界仅 $+1.5 \times 10^{-5}$。 21

5.1　问题二的建模与求解流程。上排五个环节依次为多源数据整备、退化检验、参数辨识（联合拟合）、跨源验证与条件化检验，下方汇文本问在质量指数上的两条路线结论及其区间，两路线的差别仅在于数据量指数的来源假设。 22

5.2　质量指数 γ 的两条路线与数据量指数 β 的辨识缺口。(a) 路线 A（β 取自 B1）与路线 B（β 在 B7 上自由估计）的 γ 点估计与自助 95% 区间，虚线为 $\gamma = 1$；两条区间的交叉与否决定了有效 token 数是否按比例放大。(b) 两条路线下 β 的估计与区间，二者的区间不重叠。横轴为指数取值，纵轴为路线。 . . 25

5.3　17 个训练领域相对参照域 `train_the_pile_philpapers` 的权重比 b_i / b_{ref}，按取值降序排列。横轴为中心化权重之比（非有界比例），纵轴为领域名；正负分别对应上调该域会抬高与降低损失。`dm_mathematics` 为唯一绝对值超过 1 的域。 26

5.4　跨源迁移验证与弹性对照。(a) 三个外部来源的去源偏秩相关：B4（真实收敛点，$n = 57$）、B5（已发表文献值，$n = 44$）、B2（半合成轨迹，$n = 1029$），点旁标注各自的去源偏 RMSE，横轴为 Spearman 秩相关。(b) 各边际效用在 B1 侧与 B7 侧的取值对照，星号标出无真实数据支撑、依赖半合成网格的量，横轴为对 L 的偏导。 27

6.1 问题三的建模与求解流程。上排五个环节依次为优化目标与成本结构、三类质量成本函数、三分支分段 KKT 求解、沿预算的活跃约束集扫描与转移定位、成本函数与上下文长度的敏感性；下方为本问产出，其中跨临界一行的两个百分数为 L_{ctx} 由 2048 增至 131072 时的规模变化幅度。 29
6.2 最优配置沿算力预算的路径，四联图共用横轴 $\log_{10} C$（FLOPs，18–25）。(a) 最优质量 Q^*，虚线为 $Q = 1$ 与 $Q_0 = 0.35$，红色竖线为活跃约束集变化的位置 $\log_{10} C = 21.4052$，左右两侧分别为内点分支与上界分支；(b) 最优规模 N^* 与 D^*（B），纵轴为对数刻度；(c) 三项成本占预算的比例，点划线为 C_Q 与 C_{attn} 在 $\log_{10} C = 22.625$ 处的排序翻转；(d) 饱和点附近的导数 $dQ^*/d\log_{10} C$，饱和前约为 0.15，饱和后为零，跨越饱和点的区段以灰线单列。 31
6.3 结构性转移的三种定义及其识别结果。(a) 最优质量 Q^* 随 $\log_{10} C$ 的路径；红色虚线为定义 A 的位置 21.4052，红色点划线为定义 C 的翻转位置 22.625，灰色虚线为定义 D 在 $\delta = 0.05$ 下的阈值（细网格上无越阈点）。(b) 三种扫描步长下相邻点的 $|\Delta Q^*|$，横轴为 $\log_{10} C$，纵轴为对数刻度，阈值线为 0.05，仅步长 0.5 出现越阈点。(c) 三项成本占比随 $\log_{10} C$ 的演化，点划线标出 22.625 处 C_Q 与 C_{attn} 的排序翻转。 33
6.4 上下文长度跨临界的影响，横轴为 L_{ctx}（token，对数刻度），红色虚线为临界值 30000，右侧阴影为位于临界之上的两档。(a) 最优规模 N^* 与 D^*（B），纵轴为对数刻度，两档的降幅为 54.8351% 与 53.3788%；(b) 最优配比 $N^*{:}D^*$，纵轴为线性刻度，五档的相对极差为 3.22%；(c) 注意力开销与训练开销之比 $C_{\text{attn}}/C_{\text{train}}$，纵轴为对数刻度，红色虚线为两者相等的条件 $L_{\text{ctx}} = 6/\eta = 30000$。 35
7.1 问题四的技术路线。五个环节依次为窗口与样本的固定、规模通道的刻画、技术通道的扣除、端点定义与函数规格的双重扰动，以及情景预测与基线对照；底部为本问的主要产出。 37
7.2 各口径下的通道贡献分解与子组份额。(a) 横轴为能力提升（C1 分值），每个口径一条堆叠条，深色为技术/数据工程通道、浅色为规模通道，菱形为合计提升，四种端点/规格算法给出的极差为 5.4865–6.6592 分，规模通道的条在若干口径下伸向负半轴。(b) 对话微调组的规模通道份额及其 95% 自助区间，竖直虚线为份额等于 1 的位置；预训练组的合计提升为负，其份额的分母为负，该组的份额与区间不在图中给出。 39
7.3 规模与前沿的同期走势。(a) 纵轴为模型参数量（十亿，对数刻度），细线为每月参数量分布的 0.10、0.50 与 0.90 分位及最大值，其中 0.90 分位由 46.703B 降至 14.770B，端点比值为 3.162。(b) 纵轴为前沿能力 S_{q90}（分），红色虚线为线性拟合，斜率 +1.5333 分/月，末月读数为 41.3875 分。 40
7.4 前沿预测与情景缩放。(a) 纵轴为 C1 分值，三个情景各给出 12 个月与 24 个月两个视界的中位数（空心圆）、80% 区间（粗段）与 95% 区间（细线），青色为纯趋势基线 M0a 的 12 个月读数，红色横线为当前前沿 41.3875 分。(b) 横轴为规模通道份额，纵轴为 12 个月视界上的三情景极差；份额为 0.2593、0.0911 与 0 时，极差分别为 11.79、4.141 与 0 分。 43

表格

2.1 四个子问题的主要难点与本文的应对方式 9
3.1 全文通用符号与单位 10
3.2 正文使用的简称对照 12

4.1 22 个质量指标的方向统一与规范化处置。列数按原始字段计，DSIR 三列合并后主口径为 20 列；V、P 为合成时的语义分组。 14
4.2 七个领域的质量评分 Q 与 95% 自助区间（$B_{\text{boot}} = 400$，Huber M 估计，合并总体分位数口径）。n 为域内样本量。表中数值保留四位小数，与自助样本的蒙特卡洛精度相称。 15
4.3 冲突判据的锚点敏感性（上半，合并总体口径的全局冲突率）与主判据的域级冲突率（下半，合并总体口径；p_{75} 锚点下取 CD2 与「至少三高且至少三低」两者，第二列取 CD1 在固定参考阈 0.25 处的衔接对照版，其取值与锚点无关）。上半部分末行为「至少三高且至少三低」判据，在 p_{70} 下已把 83.57% 的样本判为冲突；下半部分用以显示异常度判据的域级退化。 . . . 18
4.4 配比模型的跨尺度验证与质量评分的增量检验。上半部分为两个模型在三个尺度上的去尺度偏移 R^2、秩相关，以及基线模型的原始 R^2 与偏差占均方根误差之比；下半部分为在 17 维配比之上引入域级 Q 后的去偏 R^2 与增量区间（$B_{\text{boot}} = 400$，「仅 p」与「$p + Q$」在同一 507 行子集上拟合与评估）。增量与区间端点保留五位小数，1B 尺度区间改以科学计数法书写以保留其有效数字。 20
5.1 广义标度律与基线的参数估计（N、D 以十亿计，损失以 nats/token 计） . 23
5.2 三项预声明判据的阈值、实测值与结论 24
5.3 参照点 $N = 1.0$B、$D = 150.0$B、$Q = 0.5$ 处的边际效用、弹性与等价条件 . 26
6.1 三档算力预算下的最优配置（$L_{\text{ctx}} = 2048$，指数型成本函数；N^*、D^* 以十亿计，预算违反量取相对形式 $(\text{cost} - C)/C$） 30
6.2 最优性的独立核验（$\partial L/\partial N$、$\partial L/\partial D$、$\partial L/\partial Q$ 为对拉格朗日函数的中心差分重建结果，差分进化在整个可行域上独立求解同一目标） 32
6.3 结构性转移的三种定义与识别结果（δ 为定义 D 的份额突变阈值） 32
6.4 三类质量成本函数在各预算档下的最优质量（末行按列给出跨形式极差） . 34
6.5 与基线的同口径对照及差距分解（报告差距为 $L(\text{M0o}) - L(\text{M1o})$，仅质量通道差距以诊断配置 M0o′ 为参照，配比口径差距为前两者之差） 35
7.1 问题四的固定口径与关键设定 37
7.2 通道分解对端点定义与函数规格的敏感性（单位：分；份额无量纲）。端点扰动的四个口径分别覆盖 4561、1477、2345 与 4219 行。 39
7.3 按模型类型的子组分解（主口径，单位：分；份额无量纲）。预训练组的合计提升为负，其份额失去解释力，故只报绝对点数与方向。 41
7.4 损失到得分的桥接拟合及其分层核验（单位：分）。秩相关为斯皮尔曼系数。 42
7.5 12 个月视界的前沿预测与纯趋势基线的同口径对照（单位：分）。当前前沿为 41.3875 分；预声明的预测判据取中性行的 80% 区间下界（43.268 分）。 42
B.1 领域级质量评分（pooled 口径，Huber M 估计与自助 95% 区间） 52
B.2 冲突率：五种判据 × 三个锚点 × 两种归一化总体 53
B.3 配比模型的跨尺度验证（原始 R^2、去尺度偏移后 R^2、秩相关与误差分解） 54
B.4 各领域相对参照领域的配比系数比值 b_i/b_{ref}（按比值降序，参照领域为 philpapers） 55
B.5 跨源迁移验证（只报秩相关与去源偏后的均方根误差） 55
B.6 三类质量成本函数在三个预算档位下的最优解 56
B.7 领域配比的边际损失排序（1 为边际损失最大） 56
B.8 上下文长度敏感性（附件 C7 的五档可行取值，后两档跨越临界值 30000） 57
B.9 逐月样本量与规模分位、能力前沿（N 单位为十亿参数，S 为六维等权得分） 58
B.10 三种算力情景下 12 个月与 24 个月的前沿预测（中位数与 80%/95% 区间） 58
B.11 按模型类型的子组分解（份额可读性取决于总点数是否为正） 58

算法

附录 B　结果数据

本附录给出各问的完整数值结果，与正文中的摘要表互为补充。全部数值由建模代码在附件数据上算出并落盘，此处直接读取，未经人工转录；为便于排版，数值统一四舍五入到六位有效数字，完整精度见随附的程序与结果文件。

B.1　问题一：领域级质量评分与冲突率

表 B.1：领域级质量评分（pooled 口径，Huber M 估计与自助 95% 区间）

领域	n	Q（等权平均）	95% 区间	Q（门控合成）	95% 区间
arxiv	18942	0.64939	[0.6490, 0.6498]	0.38150	[0.3807, 0.3823]
c4	10000	0.60188	[0.6000, 0.6036]	0.36380	[0.3619, 0.3658]
commoncrawl	9636	0.60130	[0.5999, 0.6027]	0.34794	[0.3464, 0.3498]
stackexchange	10000	0.58302	[0.5819, 0.5842]	0.29429	[0.2929, 0.2958]
wikipedia	9986	0.53256	[0.5310, 0.5343]	0.25564	[0.2542, 0.2572]
book	171	0.52638	[0.5170, 0.5356]	0.26677	[0.2584, 0.2753]
github	213751	0.47365	[0.4733, 0.4740]	0.22331	[0.2230, 0.2236]

表 B.2：冲突率：五种判据 × 三个锚点 × 两种归一化总体

冲突判据	锚点	归一化总体	冲突率
高价值 ∧ 高污染	p70	pooled	0.06872
指标离差（分位数锚定）	p70	pooled	0.3000
指标离差（固定阈 0.25）	p70	pooled	0.3031
≥ 5 项高且 ≥ 5 项低	p70	pooled	0.3951
≥ 3 项高且 ≥ 3 项低	p70	pooled	0.8357
高价值 ∧ 高污染	p75	pooled	0.04082
指标离差（分位数锚定）	p75	pooled	0.2500
指标离差（固定阈 0.25）	p75	pooled	0.3031
≥ 5 项高且 ≥ 5 项低	p75	pooled	0.2181
≥ 3 项高且 ≥ 3 项低	p75	pooled	0.6561
高价值 ∧ 高污染	p80	pooled	0.02083
指标离差（分位数锚定）	p80	pooled	0.2000
指标离差（固定阈 0.25）	p80	pooled	0.3031
≥ 5 项高且 ≥ 5 项低	p80	pooled	0.1152
≥ 3 项高且 ≥ 3 项低	p80	pooled	0.4688
高价值 ∧ 高污染	p70	per_domain	0.08457
指标离差（分位数锚定）	p70	per_domain	0.3000
指标离差（固定阈 0.25）	p70	per_domain	0.3050
≥ 5 项高且 ≥ 5 项低	p70	per_domain	0.4314
≥ 3 项高且 ≥ 3 项低	p70	per_domain	0.8225
高价值 ∧ 高污染	p75	per_domain	0.05503
指标离差（分位数锚定）	p75	per_domain	0.2500
指标离差（固定阈 0.25）	p75	per_domain	0.3050
≥ 5 项高且 ≥ 5 项低	p75	per_domain	0.2558
≥ 3 项高且 ≥ 3 项低	p75	per_domain	0.6677
高价值 ∧ 高污染	p80	per_domain	0.03170
指标离差（分位数锚定）	p80	per_domain	0.2000
指标离差（固定阈 0.25）	p80	per_domain	0.3050
≥ 5 项高且 ≥ 5 项低	p80	per_domain	0.1411
≥ 3 项高且 ≥ 3 项低	p80	per_domain	0.4810

表 B.3：配比模型的跨尺度验证（原始 R^2、去尺度偏移后 R^2、秩相关与误差分解）

方法	尺度	原始 R^2	去偏 R^2	Spearman	RMSE	偏移占比
M0c	1m	0.9130	0.9131	0.9531	0.09594	0.03461
M0c	60m	−8.412	0.7706	0.9221	1.358	0.9877
M0c	1B	−173.1	0.7047	0.8872	2.410	0.9991
M0c	外推 10b	−180.6	−0.6561	0.5470	2.939	0.9954
M0c	外推 70b	−282.3	−1.224	0.4762	3.255	0.9961
M1c	1m	0.9812	0.9834	0.9903	0.04457	0.3396
M1c	60m	−8.579	0.7656	0.9018	1.370	0.9877
M1c	1B	−197.8	0.6583	0.8488	2.575	0.9991
M1c	外推 10b	−180.5	−0.2590	0.6636	2.938	0.9965
M1c	外推 70b	−282.3	−0.7763	0.5987	3.255	0.9969

B.2 问题二：领域比值与跨源验证

表 B.4：各领域相对参照领域的配比系数比值 b_i/b_{ref}（按比值降序，参照领域为 philpapers）

序	领域	b_i/b_{ref}	$\lvert b_i/b_{\text{ref}}\rvert > 1$
1	philpapers	1.000	否
2	hackernews	0.5909	否
3	ubuntu_irc	0.4615	否
4	pile_cc	0.4179	否
5	gutenberg_pg_19	0.3106	否
6	europarl	0.2674	否
7	wikipedia_en	0.2577	否
8	nih_exporter	0.1193	否
9	enron_emails	0.1156	否
10	pubmed_abstracts	0.06546	否
11	uspto_backgrounds	−0.1347	否
12	stackexchange	−0.2781	否
13	freelaw	−0.3331	否
14	pubmed_central	−0.3404	否
15	github	−0.4242	否
16	arxiv	−0.4769	否
17	dm_mathematics	−1.619	是

表 B.5：跨源迁移验证（只报秩相关与去源偏后的均方根误差）

来源	n	Spearman	p 值	去源偏 RMSE	数据性质
B4	57	0.9830	3.660e-42	0.1927	真实（跨族收敛点）
B5	44	0.9588	1.406e-24	0.1997	文献值（他人发表）
B2	1029	0.7881	1.171e-218	0.4185	半合成（对标轨迹）

B.3　问题三：成本函数对照与配比边际方向

表 B.6：三类质量成本函数在三个预算档位下的最优解

预算	成本函数	Q^*	N^*/B	D^*/B	损失	分支
$C = 10^{19}$	指数型	0.6460	0.2395	5.166	3.1468	内点
$C = 10^{19}$	幂函数型	0.5390	0.2186	5.720	3.1831	内点
$C = 10^{19}$	对数渐进型	1.000	0.4062	2.277	3.1558	$Q = 1$
$C = 10^{22}$	指数型	1.000	5.647	249.1	2.1511	$Q = 1$
$C = 10^{22}$	幂函数型	1.000	5.787	238.0	2.1528	$Q = 1$
$C = 10^{22}$	对数渐进型	1.000	5.313	279.0	2.1469	$Q = 1$
$C = 10^{24}$	指数型	1.000	40.76	3771	1.9139	$Q = 1$
$C = 10^{24}$	幂函数型	1.000	40.93	3742	1.9140	$Q = 1$
$C = 10^{24}$	对数渐进型	1.000	40.37	3838	1.9136	$Q = 1$

表 B.7：领域配比的边际损失排序（1 为边际损失最大）

序	领域
1	philpapers
2	hackernews
3	ubuntu_irc
4	pile_cc
5	gutenberg_pg_19
6	europarl
7	wikipedia_en
8	nih_exporter
9	enron_emails
10	pubmed_abstracts
11	uspto_backgrounds
12	stackexchange
13	freelaw
14	pubmed_central
15	github
16	arxiv
17	dm_mathematics

表 B.8：上下文长度敏感性（附件 C7 的五档可行取值，后两档跨越临界值 30000）

L_{ctx}	跨临界	Q^{*}	N^{*}/B	D^{*}/B	$N{:}D$	损失	$C_{\mathrm{attn}}/C_{\mathrm{train}}$
2048	否	1.000	5.647	249.1	0.0226749	2.1511	0.06827
4096	否	1.000	5.473	242.3	0.0225878	2.1552	0.1365
8192	否	1.000	5.168	230.3	0.0224432	2.1630	0.2731
32768	是	1.000	4.033	183.2	0.0220170	2.1987	1.092
131072	是	1.000	2.551	116.1	0.0219666	2.2751	4.369

B.4 问题四：逐月轨迹、情景与子组分解

表 B.9：逐月样本量与规模分位、能力前沿（N 单位为十亿参数，S 为六维等权得分）

月份	n	N_{q10}	N_{q50}	N_{q90}	$N_{\max}$	S_{q90}	$\bar{S}$
2024-06	443	2.690	8.030	46.70	140.6	25.920	17.297
2024-07	173	2.614	8.030	24.15	72.71	28.094	19.200
2024-08	207	2.850	8.030	70.55	99.65	35.851	21.639
2024-09	459	2.956	8.030	27.23	103.8	32.382	20.955
2024-10	432	1.777	8.030	22.05	77.97	34.450	20.629
2024-11	374	1.100	7.616	14.77	122.6	35.092	21.673
2024-12	571	0.6300	8.030	14.77	72.71	38.697	24.754
2025-01	868	0.5080	7.616	14.77	72.71	38.024	21.400
2025-02	692	1.777	8.030	14.77	72.71	40.001	23.956
2025-03	342	1.498	7.616	14.77	70.55	41.388	23.921

表 B.10：三种算力情景下 12 个月与 24 个月的前沿预测（中位数与 80%/95% 区间）

情景	视界/月	中位数	80% 区间	95% 区间	95% 宽度
保守	12	50.249	[37.25, 63.70]	[30.24, 71.12]	40.883
保守	24	63.455	[50.05, 76.90]	[42.02, 84.67]	42.642
中性	12	56.330	[43.27, 69.70]	[35.51, 77.45]	41.935
中性	24	79.836	[65.79, 93.67]	[58.46, 100.0]	41.536
较高	12	62.035	[49.19, 75.67]	[41.68, 82.87]	41.184
较高	24	94.118	[78.50, 100.0]	[70.76, 100.0]	29.236

表 B.11：按模型类型的子组分解（份额可读性取决于总点数是否为正）

组	n	规模点数	技术点数	总点数	规模份额 95% 区间	份额可读
对话微调	4231	1.092	5.936	7.028	[-0.0328, 0.3567]	是
预训练基础	330	−5.974	2.396	−3.579	[0.7253, 4.1625]	否

附录 C　核心算法程序

本节按子问题列出建模与求解的核心程序，由 scratch/build_appendix_code.py 从实际运行的源文件中按符号抽取，未经人工转录。省略的部分为输入输出装配、绘图与结果落盘代码，其路径在各问的方法说明中给出；行内注释保留原样。

C.1　问题一：质量指标规范化与门控合成

指标方向表（三层可信度）（DIRECTION）

```
DIRECTION: dict[str, tuple[int, str, str]] = {
    "fineweb_edu": (+1, "A", "赛题正文明示：教育价值越高越好"),
    "ad_en_margin": (+1, "A", "原文核验：margin 最低 6/6 条为广告文案，最高端为论
    坛/新闻 → margin 度量非广告性"),
    "fluency_en_margin": (+1, "A", "原文核验：margin 最低端为 SEO 垃圾/机翻乱码，
    最高端为通顺散文 → margin 度量流畅度"),
    "modernbert_cleanliness": (+1, "A", "6 类有序 logits 的 softmax 期望类别，与
    fineweb_edu pearson +0.302"),
    "modernbert_readability": (+1, "A", "期望类别与 fineweb_edu pearson +0.331")
    ,
    "modernbert_reasoning": (+1, "A", "期望类别与 fineweb_edu spearman +0.485"),
    "modernbert_professionalism": (+1, "A", "期望类别与 fineweb_edu spearman
    +0.368"),
    "qurater": (+1, "A", "4 个准则与 fineweb_edu 全为正相关 +0.24~+0.61"),
    # dsir: G2 补充探针证实原始字段为"按 token 求和"的对数似然比，被长度主导
    # （log(-dsir) ~ log(word_count) 的 Pearson = 0.937~0.939）。逐 token 归一化
    后
    # 与 fineweb_edu 的 Spearman 由 -0.499 转为 +0.374，dsir_books 上 book 域由第
     7 升至第 1。
    # 故方向依据由"建模判断"升级为"数据可证"，tier C -> B。逐 token 化是使用该字段的
    前置条件。
    "dsir_books": (+1, "B", "逐 token 归一化后的 DSIR 对数似然比；归一化后与
    fineweb_edu Spearman +0.374，book 域在 book 相似度上升至第 1（原始字段下为第 7
    ）"),
    "dsir_wiki": (+1, "B", "同上；与 dsir_books 逐 token 后互相关 0.99966，
    canonical 规格下合并"),
    "dsir_math": (+1, "B", "同上；与 dsir_books 逐 token 后互相关 0.99623，
    canonical 规格下合并"),
    # 长度类：非单调。Gopher / RedPajama-v2 过滤器以区间方式使用长度，两端皆劣。
    "rps_doc_word_count": (0, "C", "文档长度对质量非单调（Gopher/RPv2 按区间过
    滤）；AUC=0.987 近乎纯域标签。按到域内中位数距离处理"),
    "rps_doc_num_sentences": (0, "C", "句数对质量非单调；AUC=0.947。按到域内中位数
    距离处理"),
    "rps_doc_unigram_entropy": (+1, "B", "一元词熵 = 词汇多样性，低熵对应重复/模板
    文本"),
    "rps_doc_frac_unique_words": (+1, "B", "唯一词占比高 = 重复度低"),
    "rps_doc_frac_no_alph_words": (-1, "B", "非字母词占比高 = 符号/数字噪声，
    Gopher 过滤视为劣质"),
    "rps_doc_frac_chars_top_2gram": (-1, "B", "最高频 2-gram 字符占比高 = 模板化
    重复"),
    "rps_doc_frac_chars_top_3gram": (-1, "B", "最高频 3-gram 字符占比高 = 模板化
    重复"),
    "rps_lines_uppercase_letter_fraction": (-1, "B", "大写字母占比高 = 标题堆砌/
    全大写喊话"),
```

```
    "rps_lines_ending_with_terminal_punctution_mark": (+1, "B", "C4 规则保留以终
    止标点结尾的行，句子完整性"),
    "rps_lines_numerical_chars_fraction": (-1, "B", "数字字符占比高 = 表格/清单残
    渣"),
    "rps_doc_mean_word_length": (0, "C", "非单调：Gopher 过滤保留区间约 [3,10]，
    过短为乱码、过长为连写/编码残渣（本库 max=83）"),
}
```

经验分位数归一化（normalize）

```
def normalize(X: np.ndarray, dom_idx: np.ndarray, population: str,
              scheme: str = "ecdf", ref_mask: np.ndarray | None = None) -> np.
    ndarray:
    """归一化到 [0,1]，不含方向统一。

    population: 'pooled' 合并全体 | 'per_domain' 按域分别 | 'ref_A1' 以 A1 分布为
    参照
    scheme:     'ecdf' 经验分位数 | 'winsor_minmax' 1%-99% 截尾后 Min-Max
    """
    fn = _ecdf_rank if scheme == "ecdf" else _winsor_minmax
    Z = np.empty_like(X)
    if population == "per_domain":
        for d in np.unique(dom_idx):
            m = dom_idx == d
            for j in range(X.shape[1]):
                Z[m, j] = fn(X[m, j])
    elif population == "ref_A1":
        if ref_mask is None:
            raise ValueError("ref_A1 需要 ref_mask 指明 A1 行")
        for j in range(X.shape[1]):
            if scheme == "ecdf":
                Z[:, j] = _ecdf_rank(X[:, j], ref=X[ref_mask, j])
            else:
                lo, hi = np.quantile(X[ref_mask, j], [0.01, 0.99])
                Z[:, j] = np.full(X.shape[0], 0.5) if hi <= lo else \
                    np.clip((X[:, j] - lo) / (hi - lo), 0.0, 1.0)
    elif population == "pooled":
        for j in range(X.shape[1]):
            Z[:, j] = fn(X[:, j])
    else:
        raise ValueError(population)
    return Z
```

方向统一（apply_direction）

```
def apply_direction(Z: np.ndarray, columns: list[str],
                    tier_c_override: dict[str, int] | None = None,
                    nonmonotone_as_distance: bool = True) -> np.ndarray:
    """把已归一化的 Z 统一为"越高越好"。

    tier_c_override: 覆写 tier C 指标的方向（+1/-1/0），用于敏感性分析。
    nonmonotone_as_distance: sign=0 的非单调指标按"到域内中位数的距离"取反处理，
```

```
        即 1-2*|z-0.5|，两端劣、中间优；False 时退化为 sign=+1。
    """
    U = Z.copy()
    ov = tier_c_override or {}
    for j, c in enumerate(columns):
        sign = ov.get(c, DIRECTION[c][0])
        if sign == -1:
            U[:, j] = 1.0 - U[:, j]
        elif sign == 0:
            if nonmonotone_as_distance:
                U[:, j] = 1.0 - 2.0 * np.abs(U[:, j] - 0.5)
    return U
```

dsir 逐 token 归一化（per_token_dsir）

```
def per_token_dsir(X: np.ndarray, columns: list[str]) -> np.ndarray:
    """dsir 三列各除以词数。修正"按 token 求和"导致的长度主导。"""
    Xo = X.copy()
    wc = X[:, columns.index("rps_doc_word_count")]
    for c in DSIR_COLS:
        Xo[:, columns.index(c)] = X[:, columns.index(c)] / np.maximum(wc, 1.0)
    return Xo
```

dsir 三列合一（collapse_dsir）

```
def collapse_dsir(U: np.ndarray, columns: list[str]) -> tuple[np.ndarray, list[
    str]]:
    """把逐 token 后互相关仍达 0.996 的 dsir 三列合为 1 个代表量。"""
    ids = [columns.index(c) for c in DSIR_COLS]
    keep = [j for j in range(len(columns)) if j not in ids]
    rep = U[:, ids].mean(1, keepdims=True)
    return np.hstack([U[:, keep], rep]), [columns[j] for j in keep] + [DSIR_REP
    ]
```

规范化主入口（build_canonical）

```
def build_canonical(X: np.ndarray, dom_idx: np.ndarray, columns: list[str],
                    ref_mask: np.ndarray | None = None,
                    population: str | None = None) -> tuple[np.ndarray, list[
    str]]:
    """按 G2.5 决策规格产出方向统一后的指标矩阵（默认 20 列）。

    population 缺省取 CANONICAL['population_primary']；传 'per_domain' 得到消融
    臂。
    """
    pop = population or CANONICAL["population_primary"]
    Xp = per_token_dsir(X, columns) if CANONICAL["dsir_per_token"] else X
    Z = normalize(Xp, dom_idx, pop, scheme=CANONICAL["scheme"], ref_mask=
    ref_mask)
    U = apply_direction(Z, columns)
    if CANONICAL["dsir_collapse"]:
```

```
        U, columns = collapse_dsir(U, columns)
    return U, columns
```

价值组 / 污染组划分（vp_split）

```
def vp_split(cols: list[str]) -> tuple[list[int], list[int]]:
    """语义分组。P = 污染组 6 列，V = 其余 14 列（canonical 20 列口径）。

    注意：风险探针里的『价值组 16 列』是 22 列口径；dsir 三合一后为 14 列。
    分组是语义划分，不得声称由相关结构导出（组内相关 0.051/0.026 与组间 0.016 同量
    级）。
    """
    poll = set(qf.POLLUTION_COLS)
    p_idx = [j for j, c in enumerate(cols) if c in poll]
    v_idx = [j for j, c in enumerate(cols) if c not in poll]
    assert len(p_idx) == 6, f"污染组应为 6 列，实得 {len(p_idx)}"
    assert len(v_idx) == len(cols) - 6
    return v_idx, p_idx
```

门控合成 Q = V • (1−P)（gated）

```
def gated(U: np.ndarray, w: np.ndarray, v_idx: list[int], p_idx: list[int]) ->
    np.ndarray:
    """门控合成。w 为 20 列权重（扰动用），组内按 w 重新归一化。"""
    wv, wp = w[v_idx], w[p_idx]
    V = U[:, v_idx] @ (wv / wv.sum())
    P = (1.0 - U[:, p_idx]) @ (wp / wp.sum())
    return V * (1.0 - P)
```

冲突判据与冲突率（conflict_rates）

```
def conflict_rates(U: np.ndarray, V: np.ndarray, P: np.ndarray) -> dict:
    """判据 × 三个锚点，全部分位数锚定。绝对阈版不实现（冲突率恰为 0.0）。

    决策 q1b_conflict_criterion = CD2@p75 为主报，CD1/CD3 为已声明的敏感性臂。
    CD1 的固定阈 0.25 对锚点零响应（评审 F1），按决策的 required_fix 改为 MAD 自身
    分位数锚定；同时保留固定阈版作对照，以便与首轮及探针数值衔接。
    """
    out = {}
    mad = np.abs(U - np.median(U, axis=1, keepdims=True)).mean(1)
    for a in ANCHORS:
        qv, qp = np.quantile(V, a / 100), np.quantile(P, a / 100)
        n_hi = (U >= np.quantile(U, a / 100, axis=0)).sum(1)
        n_lo = (U <= np.quantile(U, 1 - a / 100, axis=0)).sum(1)
        out[f"p{a}"] = {
            "CD2_high_value_and_high_pollution": float(np.mean((V > qv) & (P >
    qp))),
            "CD1_indicator_MAD_anchored": float(np.mean(mad > np.quantile(mad,
    a / 100))),
            "CD1_indicator_MAD_gt_0.25_fixed_ref": float(np.mean(mad > 0.25)),
            "CD3_ge5_high_and_ge5_low": float(np.mean((n_hi >= 5) & (n_lo >= 5)
```

```
    )),
            "CD3_ge3_high_and_ge3_low": float(np.mean((n_hi >= 3) & (n_lo >= 3)
    )),
        }
    return out
```

域级 Huber M 估计（huber_mean）

```
def huber_mean(v: np.ndarray, k: float = 1.345, iters: int = 30) -> float:
    """Huber M 估计。与 probe_q1_quality.huber_mean 同参数，保证与探针数值可比。""
    "
    mu = float(np.median(v))
    s = float(np.median(np.abs(v - mu))) * 1.4826
    if s <= 0:
        return mu
    for _ in range(iters):
        r = (v - mu) / s
        w = np.where(np.abs(r) <= k, 1.0, k / np.maximum(np.abs(r), 1e-12))
        new = float(np.sum(w * v) / np.sum(w))
        if abs(new - mu) < 1e-12:
            break
        mu = new
    return mu
```

域级质量到配比域的跨体系映射（build_Q_corpus）

```
def build_Q_corpus(P: np.ndarray, pcols: list[str], domain_Q: dict[str, float],
                   mapping: dict[str, str]) -> tuple[np.ndarray, dict]:
    """语料级 Q = Σ_{i mapped} p_i · Q_i / Σ_{i mapped} p_i（6 域重归一化）。

    17 配方域中仅 6 个有质量域对应（11 个 inferred 全为 (none)）。
    """
    idx, qv = [], []
    for j, c in enumerate(pcols):
        dom = c.removeprefix("train_the_pile_")
        if dom in mapping and mapping[dom] in domain_Q:
            idx.append(j)
            qv.append(domain_Q[mapping[dom]])
    idx = np.array(idx)
    qv = np.array(qv)
    w = P[:, idx]
    mass = w.sum(1)
    valid = mass > 1e-12
    Qc = np.where(valid, (w @ qv) / np.maximum(mass, 1e-12), np.nan)
    info = {"n_mapped_domains": int(len(idx)),
            "mapped": [pcols[j].removeprefix("train_the_pile_") for j in idx],
            "mapped_mass_median": float(np.median(mass)),
            "mapped_mass_min": float(mass.min()), "mapped_mass_max": float(mass
    .max()),
            "n_rows_with_zero_mapped_mass": int((~valid).sum()),
            "n_rows_total": int(len(mass)),
            "zero_mass_handling": ("该类行在 6 个映射域上配比质量全为 0，无任何质量
```

```
    信息；"
                                        "不作插补，嵌套检验限定在 mass>0 的同一子集上（A
    /B 同行，保持可比）")}
    return Qc, valid, info
```

C.2 问题二：广义标度律的参数估计

经典标度律拟合（baseline）（fit_classic）

```
def fit_classic(N, D, L, seed=SEED):
    """M0s: L = E + A*N^-alpha + B*D^-beta"""
    def resid(th):
        E, A, a, Bc, b = th
        return E + A * N ** (-a) + Bc * D ** (-b) - L
    r = _multistart(resid, [0, 0, 1e-4, 0, 1e-4], [5, 50, 2, 50, 2], seed=seed)
    p = dict(zip(["E", "A", "alpha", "B", "beta"], map(float, r.x)))
    p["rmse"] = float(np.sqrt(np.mean(r.fun ** 2)))
    return p
```

给定 β 后由 B7 反解 γ（fit_gamma_on_b7）

```
def fit_gamma_on_b7(N, D, Q, L, beta_fixed, seed=SEED):
    """M1s 阶段 2: beta 固定（由 B1 钉住），估 gamma 与 B7 专属 E/A/alpha/B。

    L = E_B7 + A'*N^-alpha' + B'*(D*Q^gamma)^-beta
    z_p = 0（B7 无配比列） exp(b^T z_p) = 1，该因子不参与本阶段。
    """
    def resid(th):
        E, A, a, Bc, g = th
        return E + A * N ** (-a) + Bc * (D * Q ** g) ** (-beta_fixed) - L
    r = _multistart(resid, [0, 0, 1e-4, 0, 1e-4], [5, 50, 2, 50, 10], seed=seed
    )
    p = dict(zip(["E_B7", "A", "alpha", "B", "gamma"], map(float, r.x)))
    p["beta_fixed"] = float(beta_fixed)
    p["rmse"] = float(np.sqrt(np.mean(r.fun ** 2)))
    return p
```

联合加权最小二乘（fit_joint_wls）

```
def fit_joint_wls(b1, b7, sigma_b1, sigma_b7, with_Q: bool, seed=SEED):
    """联合拟合，来源专属 E_s（P1），形状参数共享。

    with_Q=True  -> M1s_joint: 参数 (E_B1, E_B7, A, alpha, B, beta, gamma)
    with_Q=False -> M0s_joint: 参数 (E_B1, E_B7, A, alpha, B, beta)，无 Q 通道
                    （B7 上加自有截距，使与 M1s 成嵌套比较、仅差 gamma 一个参数；
                    这是 P1『E 跨源不可共享』的机械后果，不是建模选择）
    B1 上 Q 恒为 1（无 Q 变化） Q^gamma = 1，gamma 不受 B1 约束。
    """
    n1, n7 = b1["n"], b7["n"]
    w1, w7 = 1.0 / sigma_b1 ** 2, 1.0 / sigma_b7 ** 2
```

```
    def resid(th):
        if with_Q:
            E1, E7, A, a, Bc, b, g = th
        else:
            E1, E7, A, a, Bc, b = th
            g = 0.0
        r1 = E1 + A * b1["N"] ** (-a) + Bc * b1["D"] ** (-b) - b1["L"]
        Deff7 = b7["D"] * (b7["Q"] ** g if with_Q else 1.0)
        r7 = E7 + A * b7["N"] ** (-a) + Bc * Deff7 ** (-b) - b7["L"]
        return np.concatenate([r1 * np.sqrt(w1), r7 * np.sqrt(w7)])

    lo = [0, 0, 0, 1e-4, 0, 1e-4] + ([1e-4] if with_Q else [])
    hi = [5, 5, 50, 2, 50, 2] + ([10] if with_Q else [])
    r = _multistart(resid, lo, hi, seed=seed)
    keys = ["E_B1", "E_B7", "A", "alpha", "B", "beta"] + (["gamma"] if with_Q
   else [])
    p = dict(zip(keys, map(float, r.x)))
    if not with_Q:
        p["gamma"] = 0.0
    p["beta_fixed"] = p["beta"]
    # 分源未加权 RMSE（可比口径）
    p["rmse_B1"] = float(np.sqrt(np.mean((
        p["E_B1"] + p["A"] * b1["N"] ** (-p["alpha"]) + p["B"] * b1["D"] ** (-p
   ["beta"]) - b1["L"]) ** 2)))
    Deff7 = b7["D"] * (b7["Q"] ** p["gamma"] if with_Q else 1.0)
    p["rmse_B7"] = float(np.sqrt(np.mean((
        p["E_B7"] + p["A"] * b7["N"] ** (-p["alpha"]) + p["B"] * Deff7 ** (-p["
   beta"]) - b7["L"]) ** 2)))
    p["n_B1"], p["n_B7"] = n1, n7
    return p
```

跨源迁移验证（validate_transfer）

```
def validate_transfer(p, codes=("B4", "B5", "B2")) -> dict:
    """真实/轨迹数据上的迁移验证。P1：禁止报跨源未去偏 R²，用 Spearman。"""
    out = {}
    for code in codes:
        d = C.load_nd(code)
        # 用共享形状参数 + 该源自有截距（去源偏）：E_s 由该源残差中位数吸收
        # 用 B1 侧形状参数（真实数据支撑）+ 该源自有截距（去源偏）
        core = p["A_B1"] * d["N"] ** (-p["alpha_B1"]) + p["B_B1"] * d["D"] **
   (-p["beta"])
        E_s = float(np.median(d["L"] - core))
        pred = E_s + core
        rho, pv = spearmanr(pred, d["L"])
        out[code] = {
            "n": d["n"], "E_s_deoffset": E_s,
            "spearman": float(rho), "spearman_p": float(pv),
            "rmse_after_deoffset": float(np.sqrt(np.mean((pred - d["L"]) ** 2))
   ),
            "note": "禁止报跨源未去偏 R²（P1：E 极差 1.6898）；此处仅报秩相关与去源
   偏后 RMSE",
        }
```

```
    return out
```

C.3 问题三：分段 KKT 求解与结构性转移识别

三类质量成本函数 g(Q)（g_value）

```
def g_value(q, form):
    c, r = G_SPECS[form]["g_coef"], G_SPECS[form]["g_rate"]
    if form == "exponential":
        return c * np.exp(r * q)
    if form == "power":
        return c * q ** r
    return c * np.log1p(r * q)
```

g 的导数（g_prime）

```
def g_prime(q, form):
    c, r = G_SPECS[form]["g_coef"], G_SPECS[form]["g_rate"]
    if form == "exponential":
        return c * r * np.exp(r * q)
    if form == "power":
        return c * r * q ** (r - 1.0)
    return c * r / (1.0 + r * q)
```

目标函数（loss）

```
def loss(self, N_B, D_B, Q):
    return self.E + self.A * N_B ** (-self.al) + self.B * (D_B * Q ** self.ga)
   ** (-self.be)
```

三类算力开销分解（cost_parts）

```
def cost_parts(self, N_B, D_B, Q):
    N, D = N_B * 1e9, D_B * 1e9
    return {"C_train": 6.0 * N * D,
            "C_Q": D * self.dg(Q),
            "C_attn": ETA * N * D * self.L_ctx}
```

KKT 约减式 (R1)（R1）

```
def R1(self, N_B, D_B, Q):
    """ •A•N^- •(k•N + Δg) -  •B•S^- •k•N = 0,单位:N,Δg 均为 FLOPs/token 量
   纲。"""
    S = D_B * Q ** self.ga
    kN = self.k * N_B * 1e9
    lhs = self.al * self.A * N_B ** (-self.al) * (kN + self.dg(Q))
    rhs = self.be * self.B * S ** (-self.be) * kN
    return lhs - rhs
```

KKT 约减式 (R2)（R2）

```
def R2(self, N_B, Q):
    """ •(k•N + Δg) - Q•g'(Q) = 0。  与 D 全消,故只含 (N,Q)。"""
    return self.ga * (self.k * N_B * 1e9 + self.dg(Q)) - Q * g_prime(Q, self.
    form)
```

内点分支 Q < 1（branch_interior）

```
def branch_interior(self, C, n_grid=400):
    """分支 I:Q0 < Q < 1。R2 给 N(Q),预算给 D(Q),R1 成为 Q 的单变量方程。"""
    def F(Q):
        N_B = self.N_from_R2(Q)
        if N_B is None:
            return np.nan
        D_B = self.D_from_budget(N_B, Q, C)
        if D_B is None or D_B <= 0:
            return np.nan
        return self.R1(N_B, D_B, Q)

    lo, hi = self.Q0 + 1e-9, 1.0 - 1e-12
    qs = np.linspace(lo, hi, n_grid)
    vals = np.array([F(q) for q in qs])
    out = []
    for i in range(len(qs) - 1):
        a, b = vals[i], vals[i + 1]
        if np.isnan(a) or np.isnan(b) or a == 0.0 or a * b > 0:
            continue
        try:
            q = brentq(F, qs[i], qs[i + 1], xtol=1e-14, rtol=1e-15, maxiter
    =300)
        except Exception:
            continue
        N_B = self.N_from_R2(q)
        r = self._pack(N_B, self.D_from_budget(N_B, q, C), q, "interior", C)
        if r:
            out.append(r)
    return out
```

边界分支 Q = 1（branch_upper）

```
def branch_upper(self, C):
    return self._solve_fixed_Q(C, 1.0, "upper_Q_eq_1")
```

KKT 五项硬判据（kkt_audit）

```
def kkt_audit(self, r, C):
    """五项硬判据。返回 (全过?, 逐项结果)。"""
    b, m = r["branch"], r["multipliers"]
    checks = {
        "budget_feasible": r["budget_violation_rel"] <= self.TOL_FEAS,
```

```
        "stationarity_R1": r["R1_residual_rel"] < self.TOL_STAT,
        "stationarity_R2": (r["R2_residual_rel"] < self.TOL_STAT
                            if b == "interior" else None),
        "complementary_slackness": None,
        "lambda_positive": m["lambda"] > 0.0,
        "bounds_ok": (self.Q0 - 1e-12 <= r["Q"] <= 1.0 + 1e-12
                      and r["N_B"] > 0 and r["D_B"] > 0),
    }
    # 互补松弛:预算紧(已由构造保证等式),Q 侧按分支判乘子符号
    if b == "interior":
        # 内点  Q 的两个界都非活跃  mu 与 nu 均须为 0。
        # 该项同时交叉验证 lambda(由 N 得)与 R2(由 Q÷D 得)的一致性。
        denom = max(abs(m["mu_upper"]), abs(m["nu_lower"]),
                    self.be * self.ga * self.B, 1e-300)
        checks["complementary_slackness"] = abs(m["mu_upper"]) / denom < 1e-6
    elif b == "upper_Q_eq_1":
        checks["complementary_slackness"] = m["mu_upper"] >= -self.TOL_MULT
    else:
        checks["complementary_slackness"] = m["nu_lower"] >= -self.TOL_MULT
    passed = all(v for v in checks.values() if v is not None)
    return passed, checks
```

活跃约束集（active_set）

```
def active_set(self, r):
    """活跃约束集(裁定2=A 的主定义所依赖的对象)。预算恒活跃。"""
    s = ["budget"]
    if r["branch"] == "upper_Q_eq_1":
        s.append("Q_le_1")
    elif r["branch"] == "lower_Q_eq_Q0":
        s.append("Q_ge_Q0")
    return s
```

分支枚举与最优分支选择（solve_kkt）

```
def solve_kkt(self, C):
    """三分支全枚举 → 丢弃不可行/乘子符号错 → 取 Loss 最小。"""
    cands = self.branch_interior(C) + self.branch_upper(C) + self.branch_lower(
    C)
    for r in cands:
        ok, checks = self.kkt_audit(r, C)
        r["kkt_passed"], r["kkt_checks"] = ok, checks
        r["active_set"] = self.active_set(r)
    valid = [r for r in cands if r["kkt_passed"]]
    pool, degraded = (valid, False) if valid else (
        [r for r in cands if r["budget_violation_rel"] <= 1e-6], True)
    if not pool:
        return None, cands
    best = min(pool, key=lambda r: r["loss"])
    best["selected_from_degraded_pool"] = degraded
    best["n_branch_candidates"] = len(cands)
    return best, cands
```

转移点二分定位（locate_active_set_change）

```
def locate_active_set_change(model: Model, lo: float, hi: float, tol=1e-4) ->
    float:
    """二分定位活跃约束集变化点(裁定2 主定义 A 的识别方法)。

    判别函数取「Q_le_1 是否在活跃集内」,离散  用二分而非数值微分。
    """
    def has_upper(lc):
        best, _ = model.solve_kkt(10.0 ** lc)
        return best is not None and "Q_le_1" in best["active_set"]

    a, b = lo, hi
    if has_upper(a) == has_upper(b):
        return float("nan")
    while b - a > tol:
        m = 0.5 * (a + b)
        if has_upper(m) == has_upper(a):
            a = m
        else:
            b = m
    return float(0.5 * (a + b))
```

定义 D 的步长敏感性（definition_D）

```
def definition_D(model: Model, steps=SWEEP_STEPS) -> dict:
    """分配份额突变(一阶差分超阈)。**结论随步长翻转,故不作主定义。**"""
    table, cache = [], {}
    for st in steps:
        pts = sweep(model, st, 18.0, 22.0)      # 与 AI 意见支撑算例同范围,便于核
    对
        cache[st] = pts
        q = np.array([p["Q"] for p in pts])
        dq = np.abs(np.diff(q)) if len(q) > 1 else np.array([0.0])
        i = int(dq.argmax())
        table.append({"step": st, "n_points": len(pts),
                      "max_abs_dQ": float(dq.max()),
                      "at_log10_C": pts[i + 1]["log10_C"] if len(pts) > i + 1
    else None,
                      "n_jumps_over_threshold": int((dq > D_THRESHOLD).sum()),
                      "verdict": ("TRANSITION_EXISTS" if dq.max() > D_THRESHOLD
                                  else "NO_TRANSITION")})
    return {
        "definition": f"若相邻扫描点间 |ΔQ*| 超过阈值 delta = {D_THRESHOLD},则判
    发生转移",
        "threshold": D_THRESHOLD,
        "grid_sensitivity_table": table,
        "verdict_at_main_step": next(
            (t["verdict"] for t in table if t["step"] == SWEEP_MAIN_STEP), None
    ),
        "why_not_main_definition": (
            "结论是扫描步长的函数:饱和前 Q* 光滑上升且斜率稳定(约 +0.149),"
            "一阶差分  斜率 × 步长,与固定阈值比较不是网格不变量"),
```

```
    }, cache
```

饱和点导数符号（derivative_at_saturation）

```
def derivative_at_saturation(pts: list, sat_log10_C: float, window=0.6) -> dict
    :
    """饱和点附近 dQ*/dlogC 的序列与符号(计划 §6.4:上游写成『由负转零』是符号错误)。
    """
    seq = []
    for i in range(1, len(pts)):
        lo_i, hi_i = pts[i - 1]["log10_C"], pts[i]["log10_C"]
        if not np.isnan(sat_log10_C) and abs(hi_i - sat_log10_C) > window:
            continue
        d = (pts[i]["Q"] - pts[i - 1]["Q"]) / (hi_i - lo_i)
        # 跨越饱和点的区间:差商既非左导数也非右导数,须单列不参与符号判定
        straddles = (not np.isnan(sat_log10_C)) and (lo_i < sat_log10_C < hi_i)
        seq.append({"log10_C": hi_i, "Q": pts[i]["Q"], "dQ_dlogC": float(d),
                    "interval": [lo_i, hi_i], "straddles_saturation": bool(
    straddles)})
    before = [s["dQ_dlogC"] for s in seq
              if not s["straddles_saturation"] and s["interval"][1] <=
    sat_log10_C]
    after = [s["dQ_dlogC"] for s in seq
             if not s["straddles_saturation"] and s["interval"][0] >=
    sat_log10_C]
    sign = "undetermined"
    if before and after:
        if min(before) > 0 and max(np.abs(np.array(after))) < 1e-12:
            sign = "positive_to_zero"
        elif max(before) < 0 and max(np.abs(np.array(after))) < 1e-12:
            sign = "negative_to_zero"
    return {"sequence": seq, "sign_at_saturation": sign,
            "left_derivative_range": [float(min(before)), float(max(before))]
    if before else None,
            "right_derivative_max_abs": float(max(np.abs(np.array(after)))) if
    after else None,
            "straddling_interval_excluded": next(
                (s for s in seq if s["straddles_saturation"]), None),
            "upstream_card_said": "negative_to_zero",
            "upstream_card_is_wrong": sign == "positive_to_zero",
            "note": ("方法卡与选择卡称『由负转零』;实测为由正转零。论文不得沿用错误
    表述。"
                     "跨越饱和点的那个区间(部分步长差商)已单列排除,不参与符号判定")}
```

baseline 差距三数分解（gap_decomposition）

```
def gap_decomposition(loss_M1o: float, m0o: dict, m0o_p: dict | None) -> dict:
    """差距分解(计划 §5.3):三个数必须同时报,不得只报 gap_reported。"""
    out = {
        "gap_reported": float(m0o["loss"] - loss_M1o),
        "gap_quality_only": None,
        "gap_ratio_handicap": None,
```

```
        "handicap_share_of_reported_pct": None,
        "why": ("HD-2 为相对 baseline 制。M0o 的 D/N 被强制为 20,而本律自身的无质
    量投入最优比值不同,"
                "故 gap_reported 含一部分与质量通道无关的虚增"),
        "status": "M0o 定义未改动;是否改动属使用者未裁定项",
    }
    if m0o_p is not None:
        out["gap_quality_only"] = float(m0o_p["loss"] - loss_M1o)
        out["gap_ratio_handicap"] = float(m0o["loss"] - m0o_p["loss"])
        if out["gap_reported"] != 0.0:
            out["handicap_share_of_reported_pct"] = float(
                out["gap_ratio_handicap"] / out["gap_reported"] * 100.0)
    return out
```

C.4 问题四：演进分解、桥接与前沿预测

规模通道 / 技术通道分解（decompose）

```
def decompose(df: pd.DataFrame, scale_cols: list[str], time_key: str,
              fn_spec: str = "decile", n_bins: int = 10) -> dict:
    """S = f(scale) + tau_t + eps 的加性分解。

    fn_spec='decile'  主口径:第一个 scale 列取十分位 dummy,其余列线性进入
    fn_spec='linear'  敏感性:全部 scale 列线性进入

    加性结构   两因子 Shapley 与本分解恒等,无交互项,份额和恒为 1。
    """
    d = df.copy()
    if fn_spec == "decile":
        d["_nb"] = pd.qcut(d[scale_cols[0]], n_bins, labels=False, duplicates="
    drop")
        Xs, _ = _dummies(d["_nb"])
        extra = [d[[c]].to_numpy(float) for c in scale_cols[1:]]
        Xs = np.hstack([Xs] + extra) if extra else Xs
    else:
        Xs = d[scale_cols].to_numpy(float)

    Xt, t_levels = _dummies(d[time_key])
    X = np.hstack([np.ones((len(d), 1)), Xs, Xt])
    y = d["S"].to_numpy(float)
    beta, *_ = np.linalg.lstsq(X, y, rcond=None)

    n_s = Xs.shape[1]
    b_s, b_t = beta[1:1 + n_s], beta[1 + n_s:]
    periods = sorted(d[time_key].unique())
    first, last = periods[0], periods[-1]
    tau = dict(zip(t_levels, b_t))
    tau_first, tau_last = 0.0, float(tau.get(last, 0.0))

    d["_f"] = Xs @ b_s
    f_first = float(d.loc[d[time_key] == first, "_f"].mean())
    f_last = float(d.loc[d[time_key] == last, "_f"].mean())
```

```
    scale_pts, tech_pts = f_last - f_first, tau_last - tau_first
    total = scale_pts + tech_pts
    return {
        "fn_spec": fn_spec,
        "scale_points": scale_pts,
        "tech_points": tech_pts,
        "total_points": total,
        "scale_share": scale_pts / total if total != 0 else float("nan"),
        "tech_share": tech_pts / total if total != 0 else float("nan"),
        "share_interpretable": bool(total > 0),
        "first_period": str(first),
        "last_period": str(last),
        "n": int(len(d)),
        "tau_path": {str(k): round(float(v), 6) for k, v in tau.items()},
    }
```

主口径归因（m1a_attribution）

```
def m1a_attribution(c1: pd.DataFrame, rng: np.random.Generator) -> dict:
    """主口径 A(十分位 dummy) + 规格敏感性 B(线性 log N)，裁定 C 要求两者都报。"""
    main = decompose(c1, ["logN"], "ym", "decile")
    boot = bootstrap_decompose(c1, ["logN"], "ym", "decile", rng, B_BOOT)
    sens = decompose(c1, ["logN"], "ym", "linear")

    cq = c1.copy()
    cq["yq"] = cq["date"].dt.to_period("Q")
    specs = {
        "decile_month": main,
        "linear_month": sens,
        "decile_quarter": decompose(cq, ["logN"], "yq", "decile"),
        "linear_quarter": decompose(cq, ["logN"], "yq", "linear"),
    }

    # 分组:题目硬性要求区分 pretrained 与 chat/finetuned
    groups = {}
    for g, sub in c1.groupby("type_group"):
        if len(sub) < 100 or sub["ym"].nunique() < 3:
            groups[g] = {"n": int(len(sub)), "note": "样本或月份不足，不单独分解"
    }
            continue
        r = decompose(sub, ["logN"], "ym", "decile")
        rb = bootstrap_decompose(sub, ["logN"], "ym", "decile", rng, 400)
        groups[g] = {**r, **rb}

    m2a_triggered = bool(boot["scale_share_ci95"] and boot["scale_share_ci95"
    ][0] < 0)
    return {
        "method_id": "M1a",
        "role": "main",
        "approved_spec": "C_main_spec_A",
        "main_spec_decile_month": {**main, **boot},
        "sensitivity_specs": {k: {"scale_share": round(v["scale_share"], 4),
                                  "tech_share": round(v["tech_share"], 4),
```

```
                                    "scale_points": round(v["scale_points"], 4),
                                    "tech_points": round(v["tech_points"], 4),
                                    "total_points": round(v["total_points"], 4),
                                    "share_interpretable": v["share_interpretable
"]}
                                for k, v in specs.items()},
        "by_type_group": groups,
        "m2a_fallback_triggered": m2a_triggered,
        "m2a_note": ("未触发，占比口径成立" if not m2a_triggered else
                     "已触发：scale_share 区间下界 < 0，须改报绝对点数与方向"),
        "wording_red_line": "tau_t 只能表述为「非规模技术/数据工程综合进步」，不得
写成架构/算法进步",
    }
```

Loss → Benchmark 桥接（`fit_bridge`）

```
def fit_bridge(rng: np.random.Generator) -> dict:
    """分层桥接 Score = g(Loss)。High 层作主锚,Medium 层降权,报映射误差。"""
    br = load_bridge()
    out: dict = {"n_total": int(len(br)), "tiers": {}}
    for tier, sub in br.groupby("tier"):
        r, p = spearmanr(sub["Val_Loss"], sub["LB_Average"])
        out["tiers"][tier] = {"n": int(len(sub)), "spearman": round(float(r),
    4),
                              "p_value": float(p)}

    # 主拟合:线性(单调约束由斜率符号检查代替),High 层加权
    w = np.where(br["tier"].to_numpy() == "High", 3.0, 1.0)
    X = np.vstack([np.ones(len(br)), br["Val_Loss"].to_numpy(float)]).T
    y = br["LB_Average"].to_numpy(float)
    W = np.diag(w)
    coef = np.linalg.lstsq(W @ X, W @ y, rcond=None)[0]
    pred = X @ coef
    resid = y - pred
    rmse = float(np.sqrt((resid ** 2).mean()))

    boot = []
    idx_all = np.arange(len(br))
    for _ in range(B_BOOT):
        idx = rng.choice(idx_all, size=len(idx_all), replace=True)
        try:
            c = np.linalg.lstsq(W[np.ix_(idx, idx)] @ X[idx], W[np.ix_(idx, idx
    )] @ y[idx],
                                rcond=None)[0]
            boot.append(c)
        except Exception:
            continue
    boot_a = np.asarray(boot)
    return {
        **out,
        "form": "LB_Average = a + b * Val_Loss（High 层权重 3:1）",
        "intercept": round(float(coef[0]), 4),
        "slope": round(float(coef[1]), 4),
```

```
        "slope_ci95": [round(float(np.quantile(boot_a[:, 1], 0.025)), 4),
                       round(float(np.quantile(boot_a[:, 1], 0.975)), 4)] if
    len(boot_a) else None,
        "monotone_decreasing": bool(coef[1] < 0),
        "rmse": round(rmse, 4),
        "mapping_error_sigma": round(float(resid.std(ddof=2)), 4),
        "high_tier_caveat": (
            "High 层 n=7，方向正确但 p 不显著（样本量所致）。"
            "按 F10 纪律：不得据此认为 High 层质量更差。映射误差作独立随机项传播。"
        ),
        "no_circularity": "Loss_Source 全为技术报告/训练日志，无标度律估算行（B4
    PASS）",
    }
```

前沿预测蒙特卡洛（frontier_mc）

```
def frontier_mc(c1: pd.DataFrame, bridge: dict, attribution: dict, q2: dict,
                rng: np.random.Generator, n_mc: int = 4000) -> dict:
    """三情景 × 蒙特卡洛,同时抽:技术趋势斜率、桥接映射误差、标度律参数。

    技术通道:用 M1a 的 tau 路径月度斜率 × 情景衰减。
    规模通道:算力年增速经 Q2 标度律折成 Loss 下降,再经桥接折成 Score 增益。
    """
    # 对象一致性:前沿是 q90 水平,故须用 q90 自身的斜率,再按归因份额拆成两通道。
    # 直接把 tau(全样本均值层面,0.545/月)加到 q90 水平上是对象不一致,会系统性低估
    # (q90 实际 1.53/月)。该缺陷在首轮实现中出现过,已修。
    tau = attribution["main_spec_decile_month"]["tau_path"]
    ks = sorted(tau.keys())
    tv = np.array([tau[k] for k in ks], float)
    x_t = np.arange(len(tv), dtype=float)
    tau_slope_mean_level, _ = np.polyfit(x_t, tv, 1)

    q = c1.groupby("ym")["S"].quantile(FRONTIER_Q)
    cur = float(q.to_numpy()[-1])
    xq = np.arange(len(q), dtype=float)
    yq = q.to_numpy(float)
    q_slope, q_int = np.polyfit(xq, yq, 1)
    q_resid = yq - (q_slope * xq + q_int)
    q_slope_se = float(q_resid.std(ddof=2) / np.sqrt(((xq - xq.mean()) ** 2).
    sum()))

    # 按主口径归因份额把前沿斜率拆为两通道
    sh_tech = attribution["main_spec_decile_month"]["tech_share"]
    sh_scale = attribution["main_spec_decile_month"]["scale_share"]
    slope_tech = float(q_slope * sh_tech)
    slope_scale = float(q_slope * sh_scale)

    b_slope = bridge["slope"]
    b_sig = bridge["mapping_error_sigma"]
    E, A, al, B, be = q2["E"], q2["A"], q2["alpha"], q2["B"], q2["beta"]

    def loss_at(mult: float) -> float:
        """算力放大 mult 倍时的 Loss(按 Chinchilla 比例同步放大 N,D)。"""
```

```
    n0, d0 = 10.0, 300.0
    s = np.sqrt(mult)
    return E + A * (n0 * s) ** -al + B * (d0 * s) ** -be

out: dict = {"current_frontier": round(cur, 3), "n_mc": n_mc,
             "frontier_slope_per_month": round(float(q_slope), 4),
             "frontier_slope_se": round(q_slope_se, 4),
             "slope_tech_channel": round(slope_tech, 4),
             "slope_scale_channel": round(slope_scale, 4),
             "tau_slope_mean_level_for_reference": round(float(
tau_slope_mean_level), 4),
             "object_consistency_note": (
                 "前沿为 q90 水平，故用 q90 自身斜率按归因份额拆通道；"
                 "tau 的均值层面斜率仅作参照，不直接加到 q90 上"
             ),
             "scenarios": {}}

# 规模通道的情景弹性:以中性情景的算力增速为基准做相对缩放
g_ref = SCENARIOS["neutral"]["compute_growth_per_year"]
dloss_ref = loss_at(g_ref) - loss_at(1.0)

for name, cfg in SCENARIOS.items():
    g, decay = cfg["compute_growth_per_year"], cfg["tech_decay"]
    per_h = {}
    for h in (12, 24):
        draws = np.empty(n_mc)
        mult = g ** (h / 12.0)
        dloss = loss_at(mult) - loss_at(1.0)
        # 规模通道:相对中性情景的 Loss 降幅比,缩放该通道的历史斜率贡献
        scale_factor = (dloss / dloss_ref) if dloss_ref != 0 else 1.0
        for i in range(n_mc):
            st = (slope_tech + rng.normal(0, q_slope_se * abs(sh_tech))) *
decay
            ss = (slope_scale + rng.normal(0, q_slope_se * abs(sh_scale)))
* scale_factor
            b_i = b_slope + rng.normal(0, abs(b_slope) * 0.15)
            bridge_noise = rng.normal(0, b_sig) * (b_i / b_slope if b_slope
 else 1.0)
            draws[i] = cur + (st + ss) * h + bridge_noise
        draws = np.clip(draws, 0, 100)
        per_h[f"h{h}"] = {
            "median": round(float(np.median(draws)), 3),
            "lo80": round(float(np.quantile(draws, 0.10)), 3),
            "hi80": round(float(np.quantile(draws, 0.90)), 3),
            "lo95": round(float(np.quantile(draws, 0.025)), 3),
            "hi95": round(float(np.quantile(draws, 0.975)), 3),
            "width95": round(float(np.quantile(draws, 0.975) - np.quantile(
draws, 0.025)), 3),
        }
    out["scenarios"][name] = {"config": cfg, **per_h}

neu12 = out["scenarios"]["neutral"]["h12"]
out["user_criterion"] = {
    "statement": "中性情景下 12 个月的 80% 区间下界 > 当前前沿值",
```

```
        "lo80": neu12["lo80"],
        "current_frontier": round(cur, 3),
        "passed": bool(neu12["lo80"] > cur),
        "width95_reported_not_gated": neu12["width95"],
    }
    out["uncertainty_sources"] = ["技术趋势斜率", "桥接映射误差", "桥接斜率不确定
    性"]
    out["horizon_note"] = (
        f"被判定视界为 {HORIZON_MONTHS} 个月。24 个月一并列出但未经裁定作主报；"
        "饱和形态(得分 0-100 上界)在 9.1 个月窗口内不可检验，该假设不可验证。"
    )
    return out
```

趋势法月斜率与份额（trend）

```
def trend(d, spec):
    d, bt, tl = fit(d, spec, "ym")
    ms = sorted(d["ym"].unique())
    x = np.arange(len(ms), dtype=float)
    tau = np.array([0.0] + [dict(zip(tl, bt))[m] for m in ms[1:]])
    fb = np.array([d.loc[d["ym"] == m, "_f"].mean() for m in ms])
    sf = float(np.polyfit(x, fb, 1)[0])
    st = float(np.polyfit(x, tau, 1)[0])
    span = len(ms) - 1
    sc, tc = sf * span, st * span
    tot = sc + tc
    return dict(slope_f=sf, slope_tau=st, slope_ratio=st / sf if sf else float(
    "nan"),
                scale_points=sc, tech_points=tc, total_points=tot,
                scale_share=sc / tot, tech_share=tc / tot, n_months=len(ms))
```